

第四章 隐马尔可夫模型与贝叶斯网络

苏智勇

可视计算研究组

南京理工大学

suzhiyong@njust.edu.cn

<https://zhiyongsu.github.io>

主要内容

4.1 贝叶斯网络的基本概念

4.2 隐马尔可夫模型 (HMM)

4.3 朴素贝叶斯分类器

4.1 贝叶斯网络的基本概念

- 随机变量
- 随机变量的条件独立性
 - 两个随机变量 x 和 y 独立, 当且仅当 $p(x, y) = p(x)p(y)$
 - 随机变量间的条件独立性: 如果随机变量 x, y, z 满足 $p(x, y | z) = p(x | z)p(y | z)$, 则称 x 和 y 关于 z 条件独立,

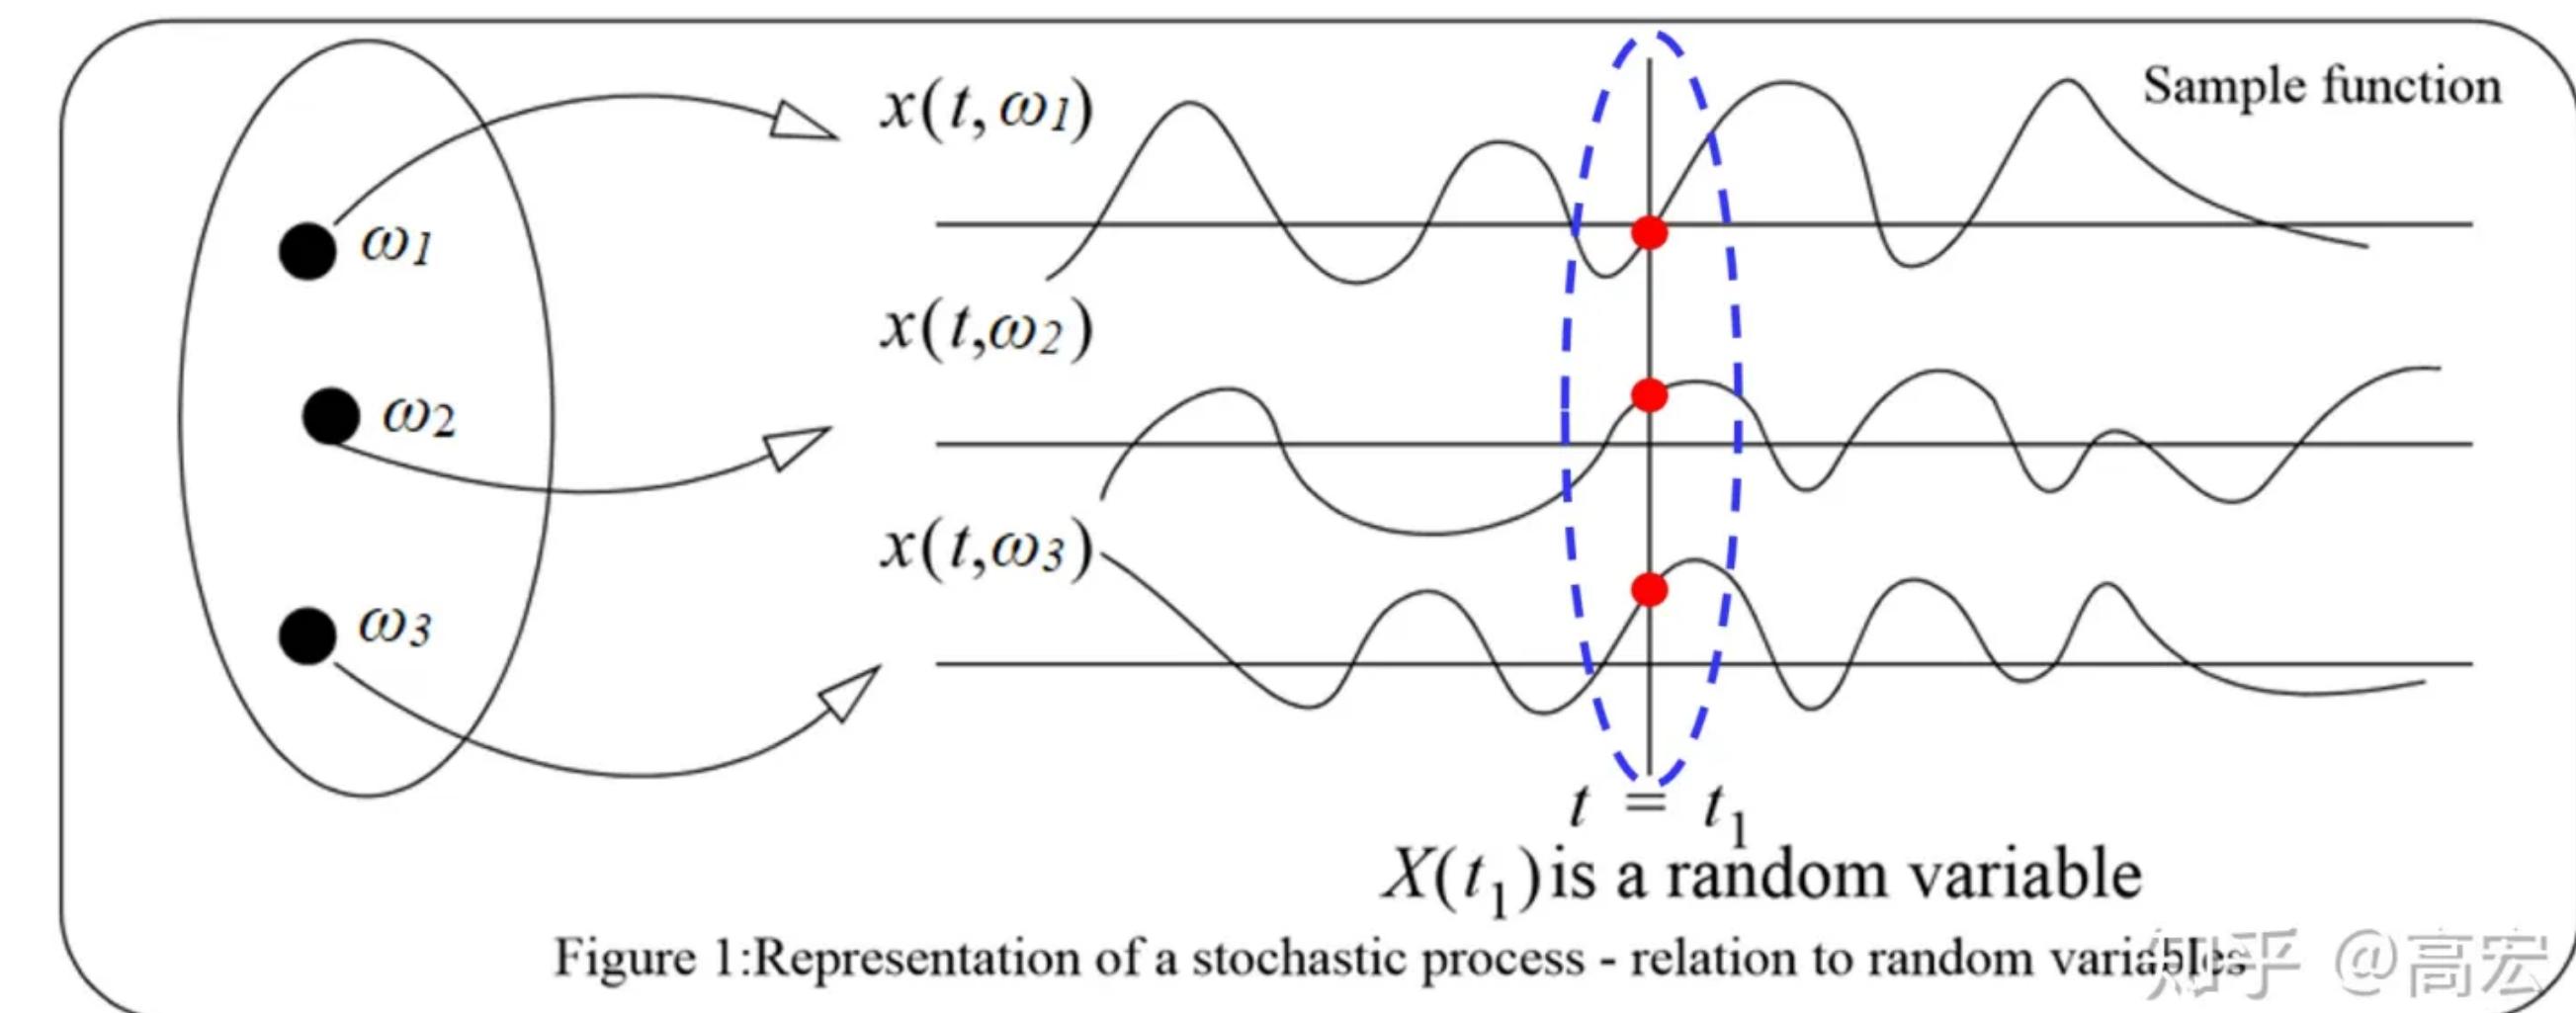
$$p(x | y, z) = \frac{p(x, y, z)}{p(y, z)} = \frac{p(x, y | z)p(z)}{p(y | z)p(z)} = p(x | z)$$

4.1 贝叶斯网络的基本概念

- 随机过程
 - 分布（联合分布）是对一个随机变量（随机向量）的刻画，而过程是对一族随机变量的刻画！
 - 定义：随机过程是定义在 $\Omega \times T$ 上的二元函数 $X(\omega, t)$ 。对于固定的时间 t , $X(\omega, t)$ 为随机变量，简记为 $X(t)$ 或 X_t ；对于固定的 ω , $X(\omega, t)$ 为时间 t 的一般函数，称为样本函数或样本轨道，简记为 $x(t)$ 。
 - 随机变量和样本函数是两个具有不同定义域和值域的单值函数。
 - 随机过程既可看成是“所有随机变量的集合”，也可看成为“所有样本函数的集合”。

4.1 贝叶斯网络的基本概念

- 随机过程
 - 随机过程示意图
 - 随机变量 $X(t)$: 对于固定时间 t , 蓝色虚线圈圈表示随机变量
 - 样本函数 $X(\omega, t)$: 对于固定的 ω , $X(\omega, t)$ 为时间 t 的样本函数 (3个)
 - 股票的涨跌过程
 - 今天红-明天红-后天绿
 - 今天绿-明天绿-后天绿
 - ...



4.1 贝叶斯网络的基本概念

- 马尔科夫性质
 - 也叫做无后效性、无记忆性，即过去只能影响现在，不能影响将来。
 - 如果 $X(t)$, $t > 0$ 为一个随机过程，则马科夫性质可以符号化成如下形式：

$$Pr[X(t + h) = y | X(s) = x(s), s \leq t] = Pr[X(t + h) = y | X(t) = x(t)], \forall h > 0$$

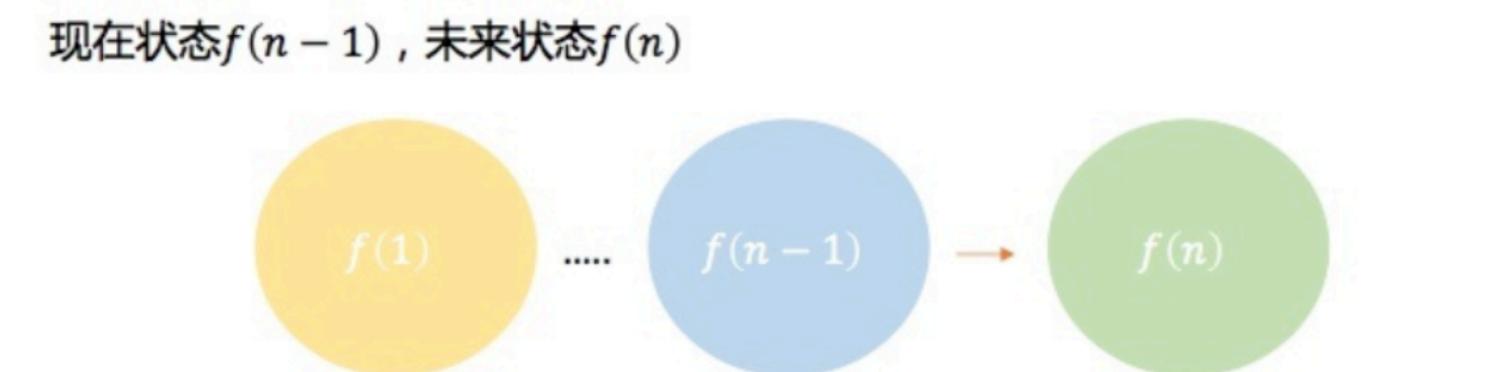
- 过去(s)并不影响将来($t + h$)的状态，但当前状态蕴含着以往所有的状态信息。

4.1 贝叶斯网络的基本概念

- 马尔科夫模型（链）

定义：具有马尔可夫性质、并以随机过程为基础模型的随机过程/随机模型被统称为马尔可夫模型（链）。

- 任性的过程：它将来的状态分布只取决于现在，跟过去无关！（一阶）
- Life is like a Markov chain, your future only depends on what you are doing now, and independent of your past.

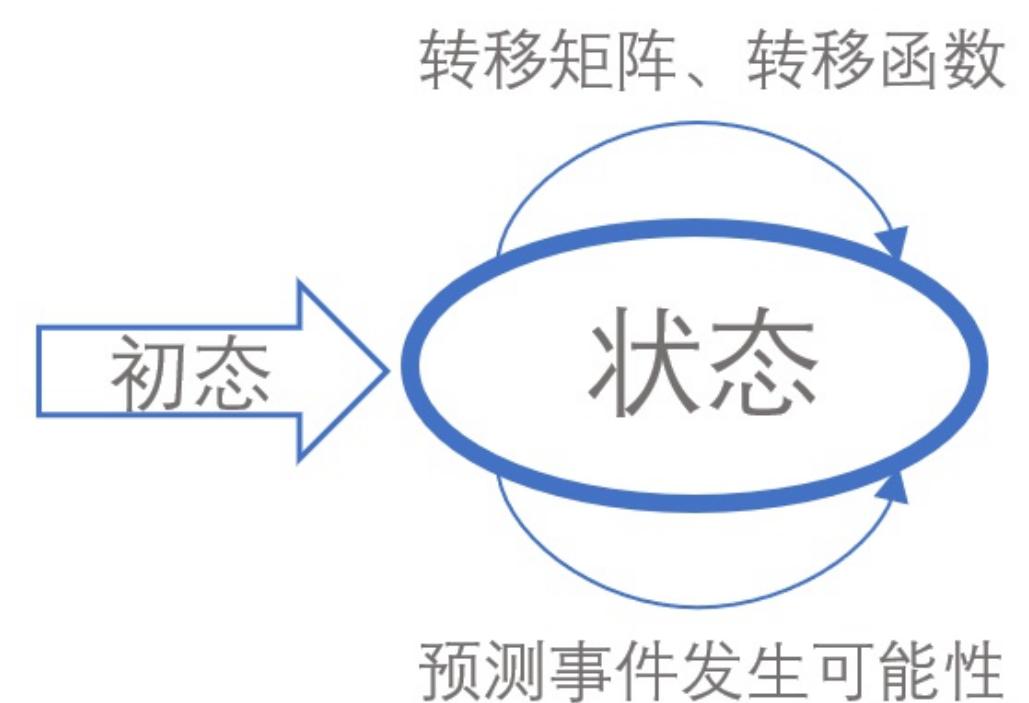


现在决定未来

4.1 贝叶斯网络的基本概念

- 马尔科夫模型（链）基本要素
 - 状态空间： $X_n = i$ 表示随机过程在 n 时刻处在 i 状态，所有状态的取值构成的集合称为“状态空间”，以符号 I 表示
 - 转移概率：把在当前时刻状态到下一时刻某状态的条件概率称作转移概率

$$P_{ij} = P(X_n = j | X_{n-1} = i)$$



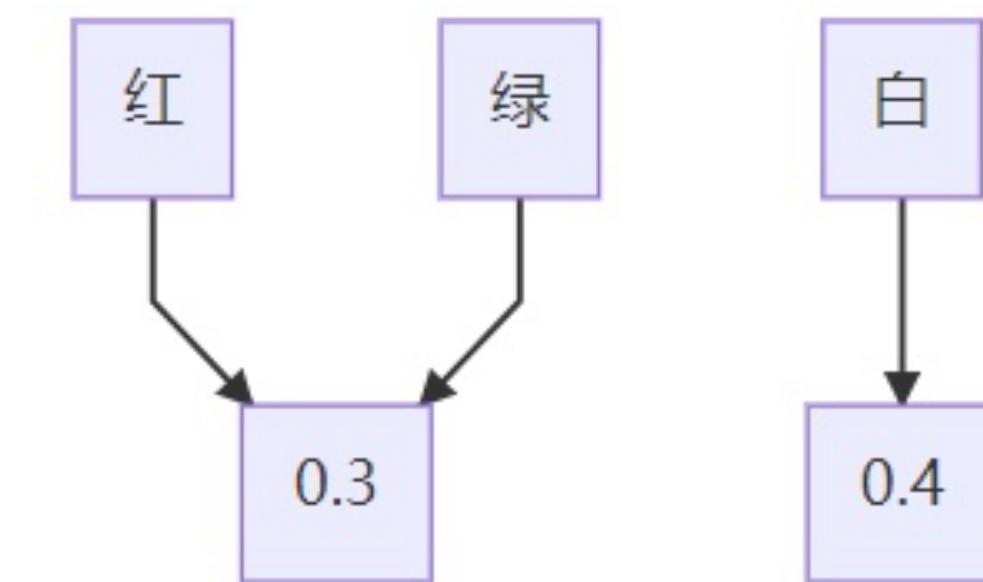
知乎 @马克波罗的鸡腿

4.1 贝叶斯网络的基本概念

- 马尔科夫模型（链）基本要素

- 转移概率矩阵：所有状态之间的转移概率组成一个矩阵。状态转移矩阵不随时间的变化。

$$P = \begin{Bmatrix} p_{11} & p_{12} & \cdots & p_{1I} \\ p_{21} & p_{22} & \cdots & p_{2I} \\ \vdots & \vdots & \ddots & \vdots \\ p_{I1} & p_{I2} & \cdots & p_{II} \end{Bmatrix}$$



知乎 @马克波罗的鸡腿

- 初始状态：即初始分布

- $p_0 = (p_0(1), p_0(2), p_0(3)) = (0.3, 0.4, 0.3)$
 - $p_n(j) = P(X_n = j), j = 1, 2, 3$

4.1 贝叶斯网络的基本概念

- 马尔科夫模型（链）基本要素
 - 转移方程：对于 m 步转移，则有转移方程如下

$$p_{ij}^{(n+m)} = \sum_{k=1}^I p_{ik}^{(n)} p_{kj}^{(m)}$$

- 今天： $p_0 = (0.3, 0.4, 0.3)$
- 明天： $p_1 = p_0 \times P^1$
- 后天： $p_2 = p_1 \times P = p_0 \times P^2$



4.1 贝叶斯网络的基本概念

- 链式法则

$$P(AB) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$

- 高维随机变量（随机向量）的联合分布：

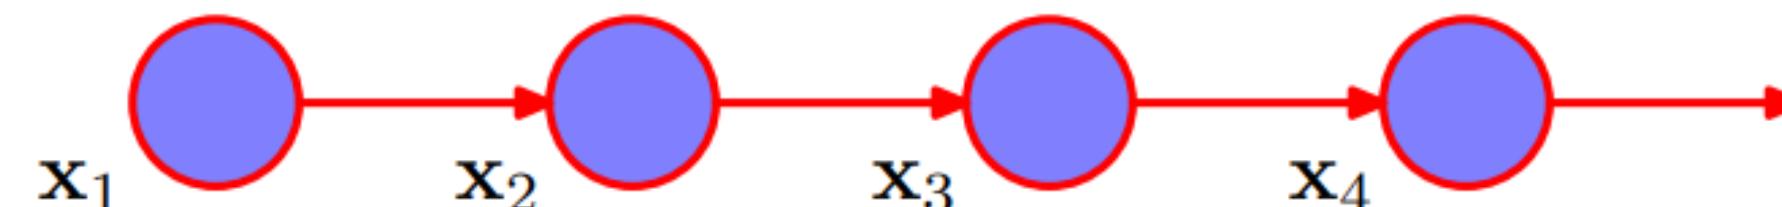
$$p(x_1, x_2, \dots, x_d) = p(x_1, x_2, \dots, x_{d-1})p(x_d | x_1, x_2, \dots, x_{d-1})$$

$$p(x_1, x_2, \dots, x_d) = p(x_1)p(x_2 | x_1)p(x_3 | x_1, x_2) \dots p(x_d | x_1, x_2, \dots, x_{d-1})$$

$$p(x_1, \dots, x_d) = p(x_1) \prod_{n=2}^d p(x_n | x_1, \dots, x_{n-1})$$

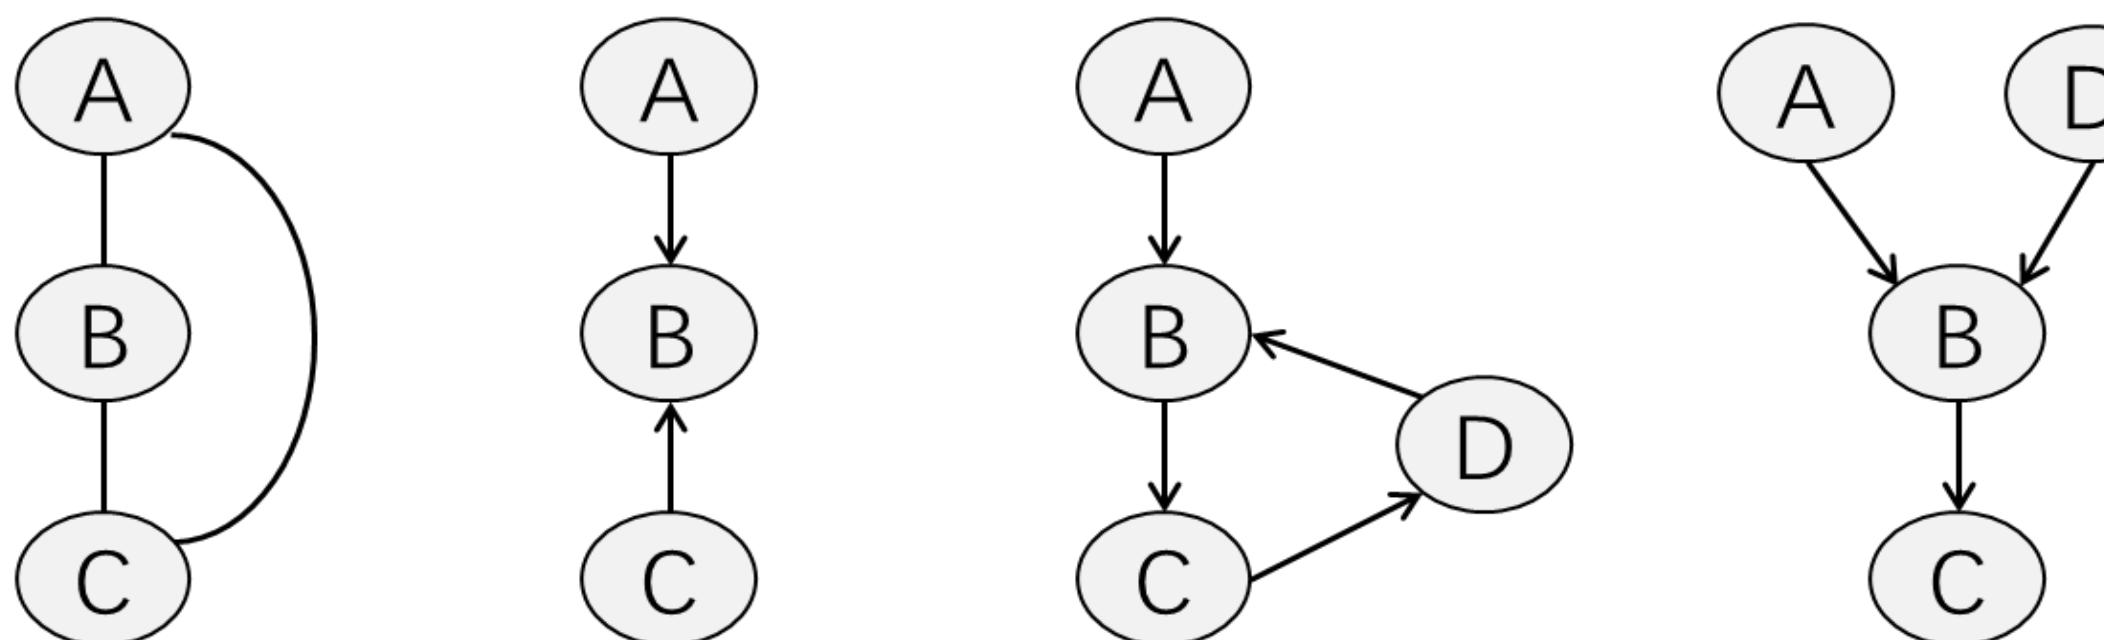
- 如果 x_{t+1} 与 x_1, x_2, \dots, x_{t-1} 关于 x_t 条件独立，则上式可以简化为

$$p(x_1, \dots, x_d) = p(x_1) \prod_{n=2}^d p(x_n | x_{n-1})$$



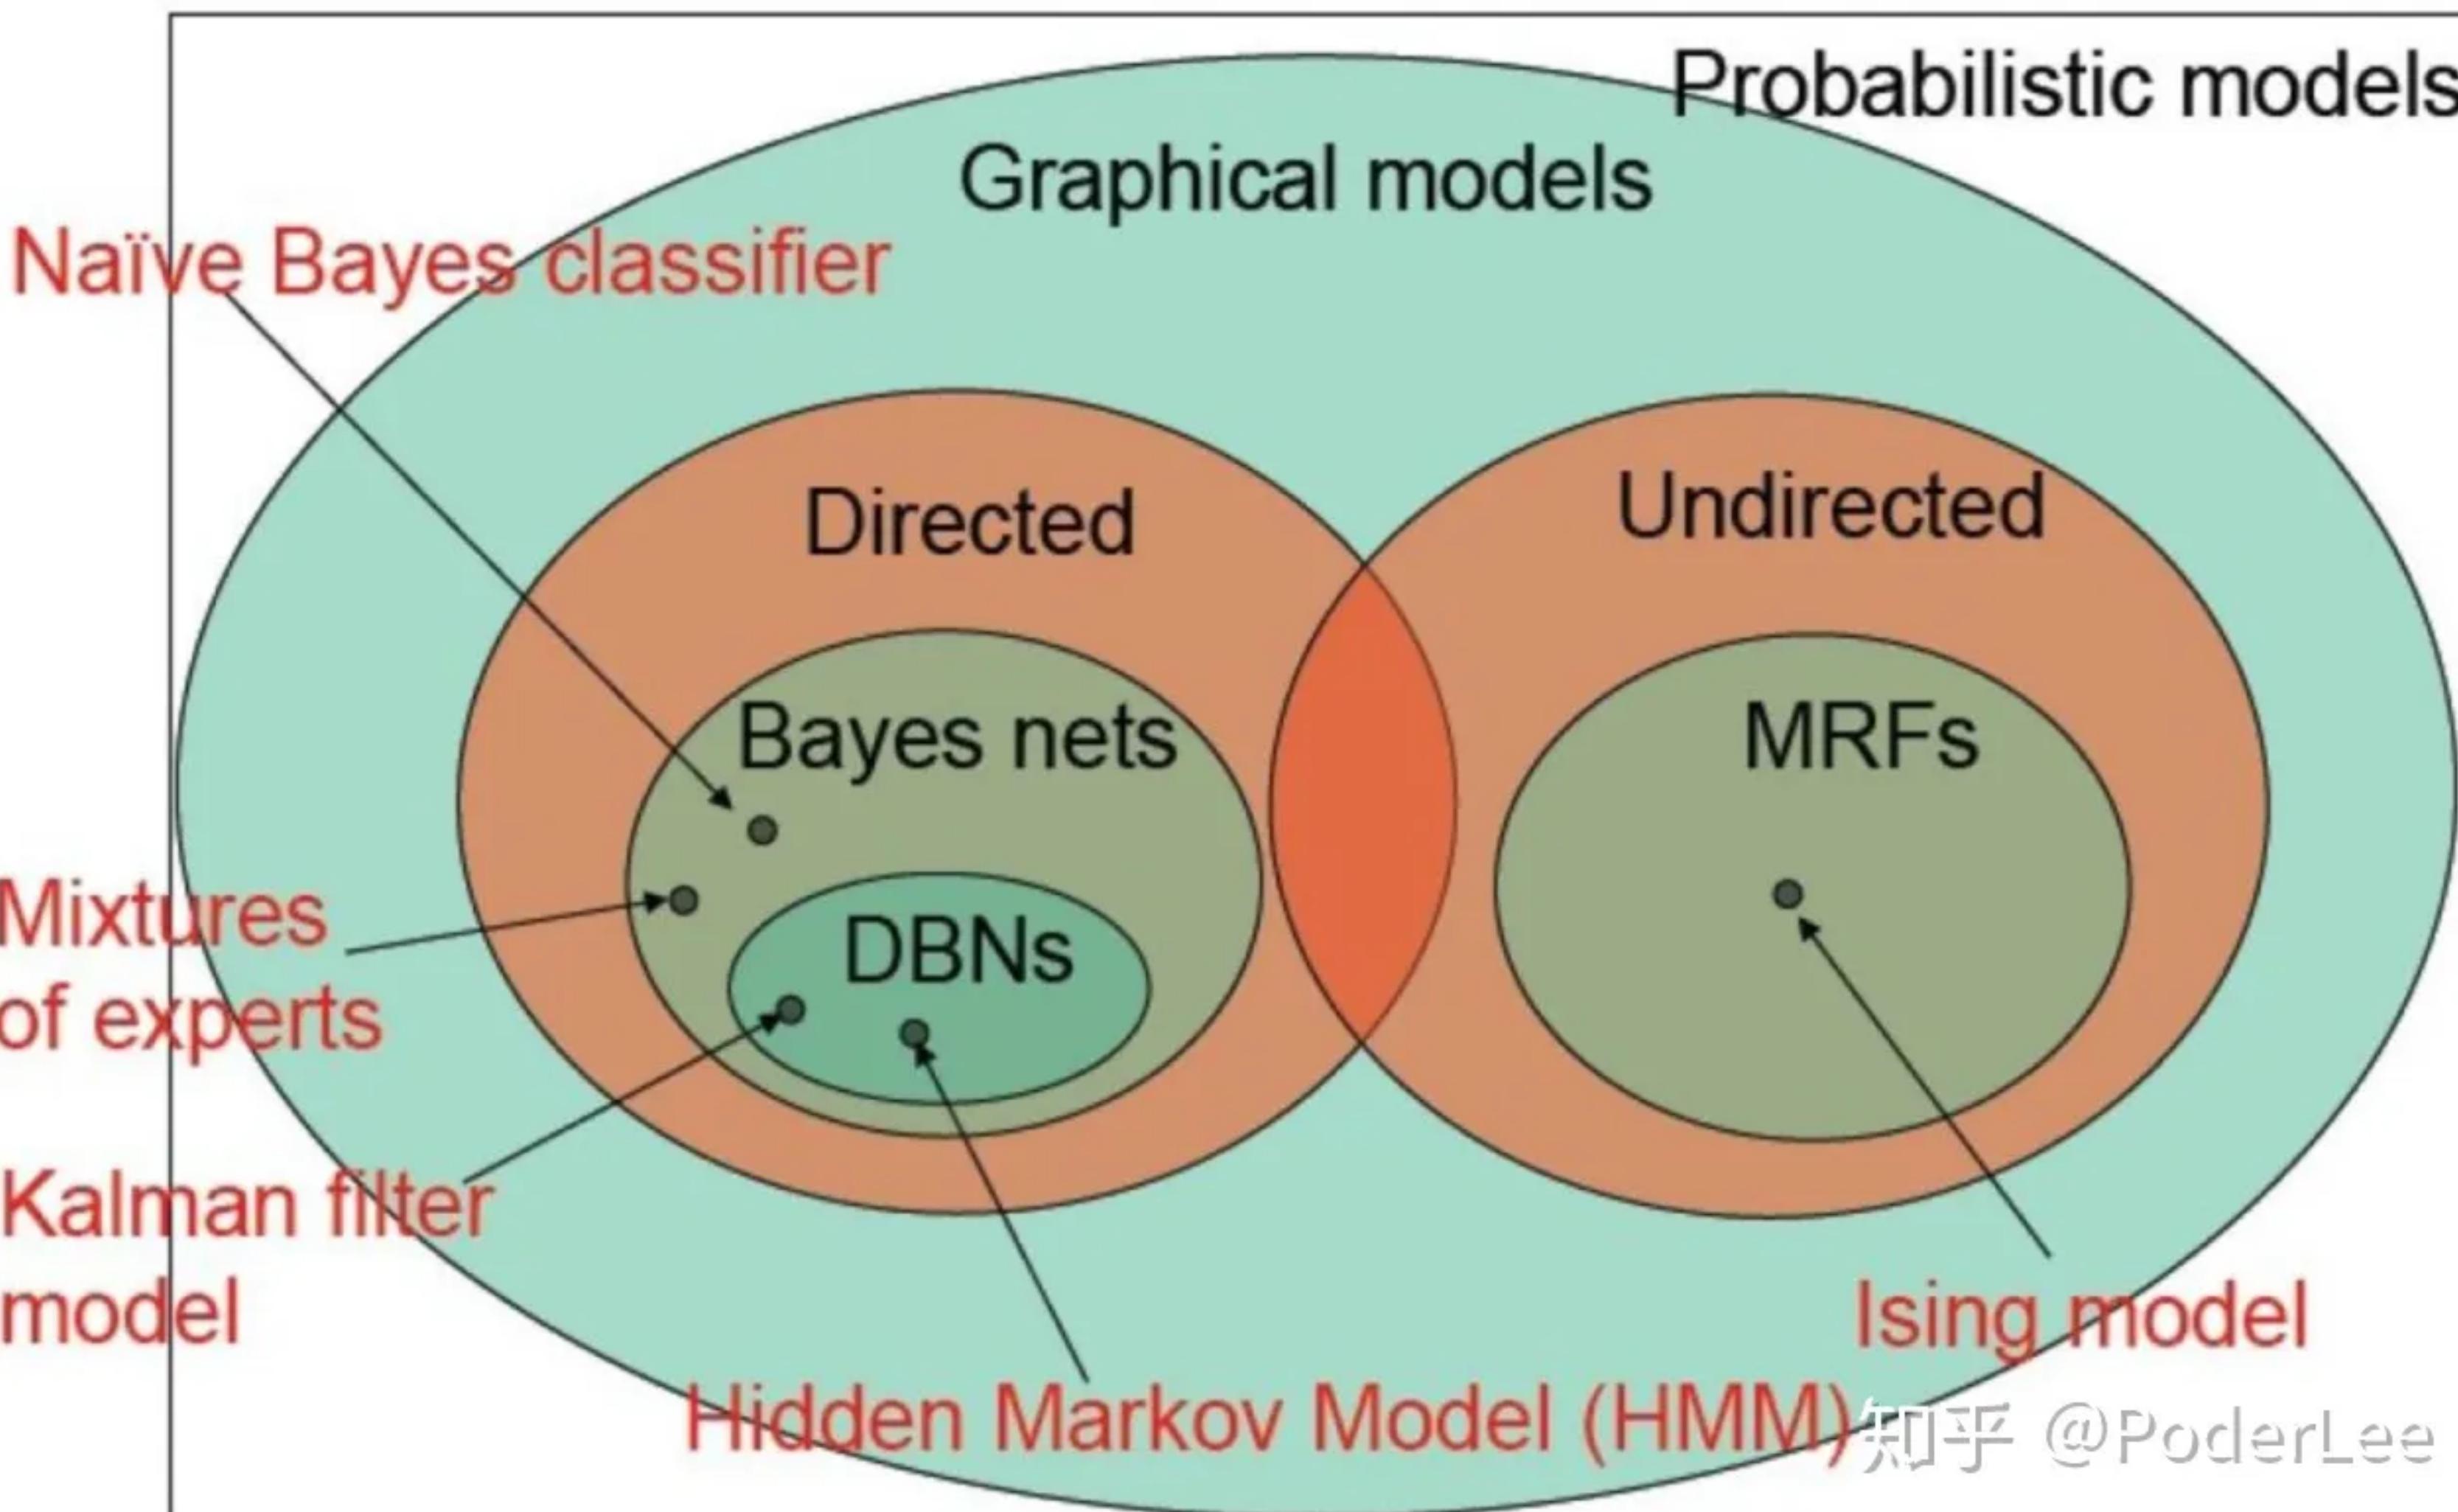
4.1 贝叶斯网络的基本概念

- 条件概率的图表示
 - 图的基本概念
 - 节点、边；有向图、无向图；有环图、无环图
 - 条件概率 $P(X = a | Y = b)$ 、联合概率 $P(X = a, Y = b)$ 、边缘概率 $P(X = a)$



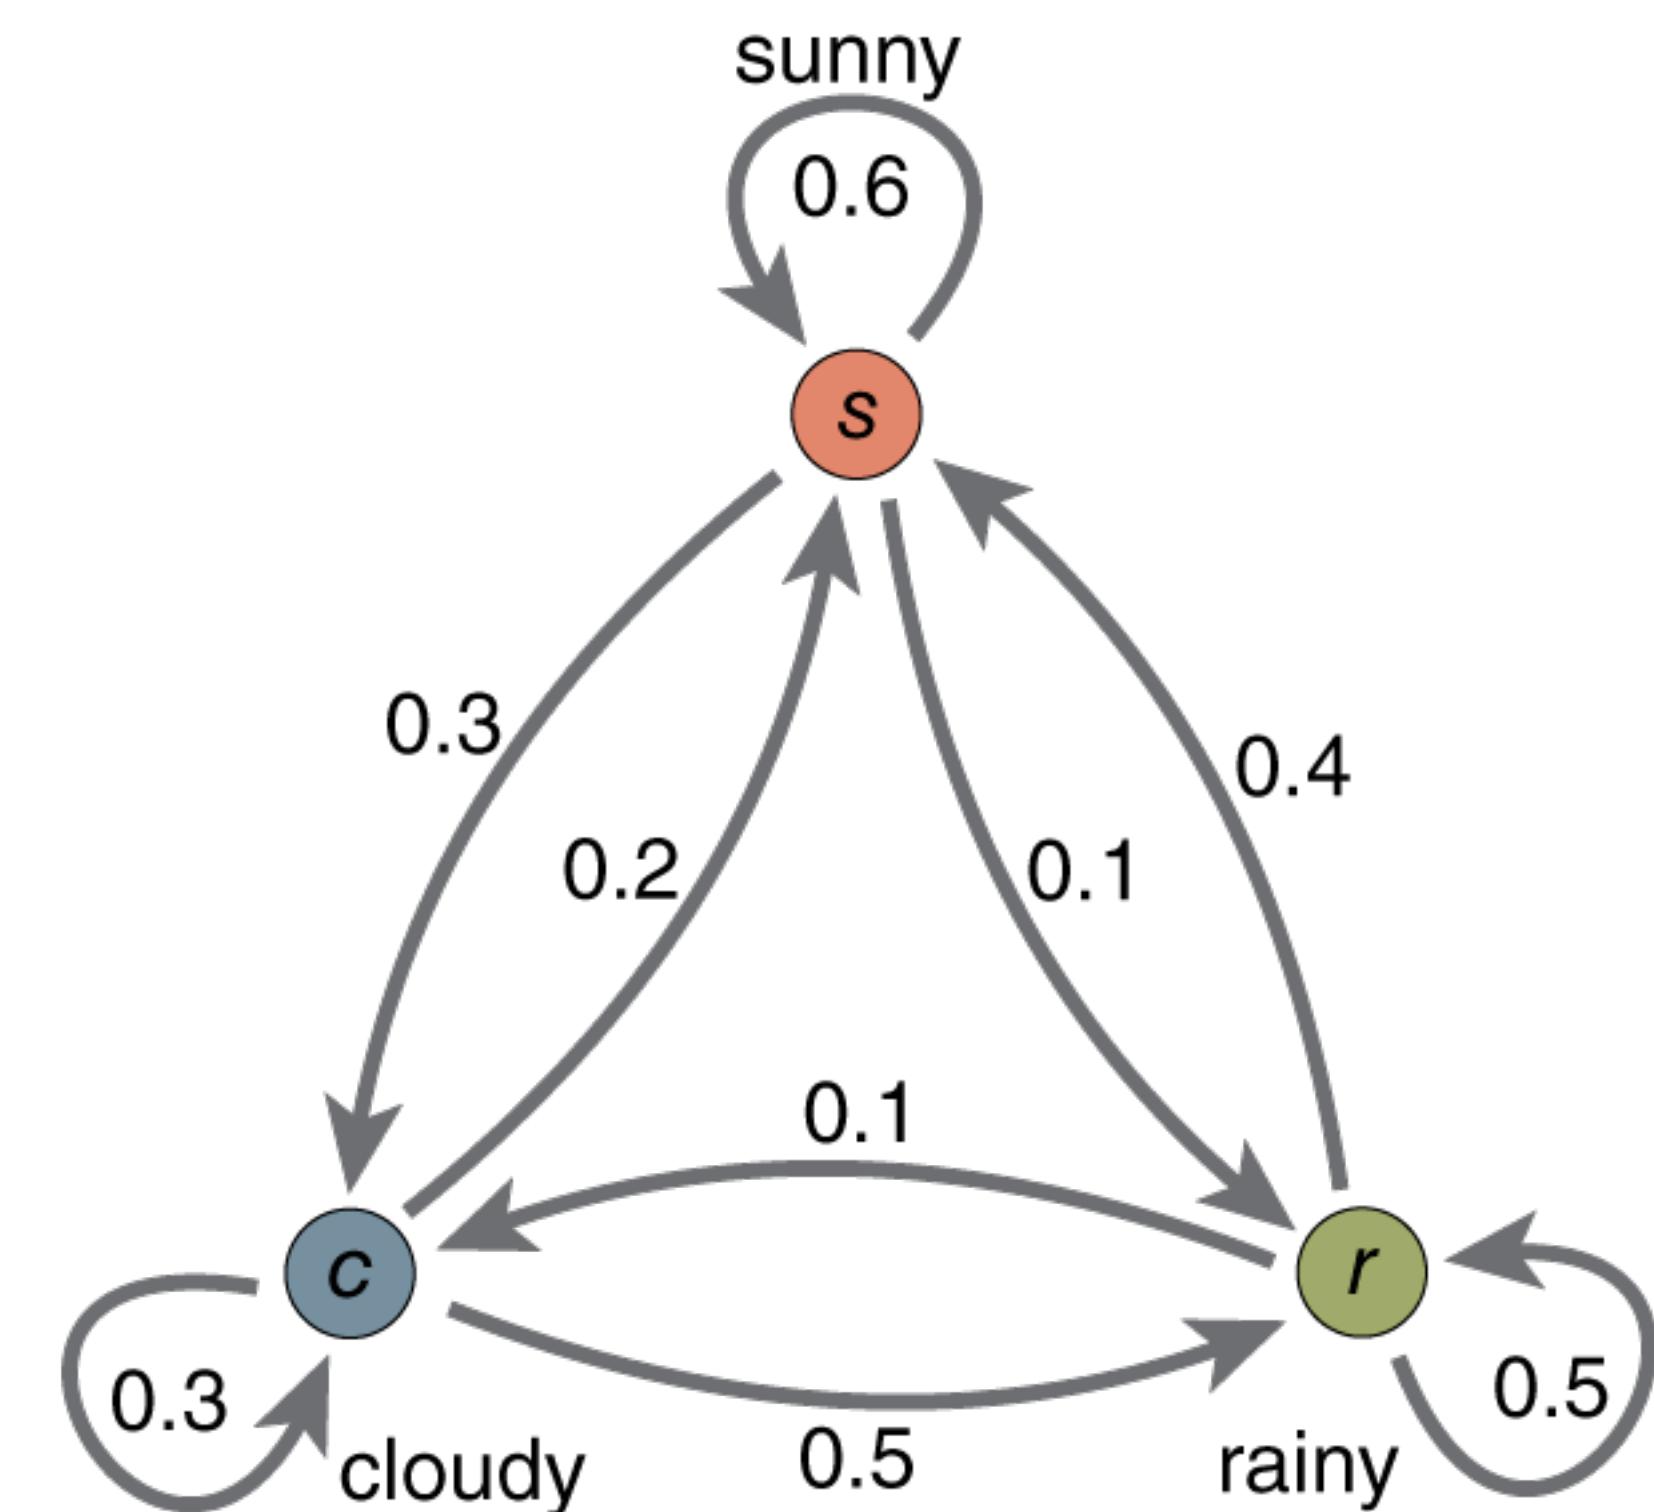
4.1 贝叶斯网络的基本概念

- 贝叶斯网
 - 一种用概率有向网工作的模型
 - 无向网的因子模型
 - 通过图模型的计算



4.2 隐马尔科夫模型

- 一种特殊的动态贝叶斯网络
- HMM案例
 - 已知:
 - 天气: 状态空间 (Sunny, Rainy, Cloudy) 、天气转移概率
 - 行为: 散步、购物、内务
 - A、B跨国恋, A的对象B通过A的行为猜测可能的天气状态



4.2 隐马尔科夫模型

- HMM案例

- 条件:

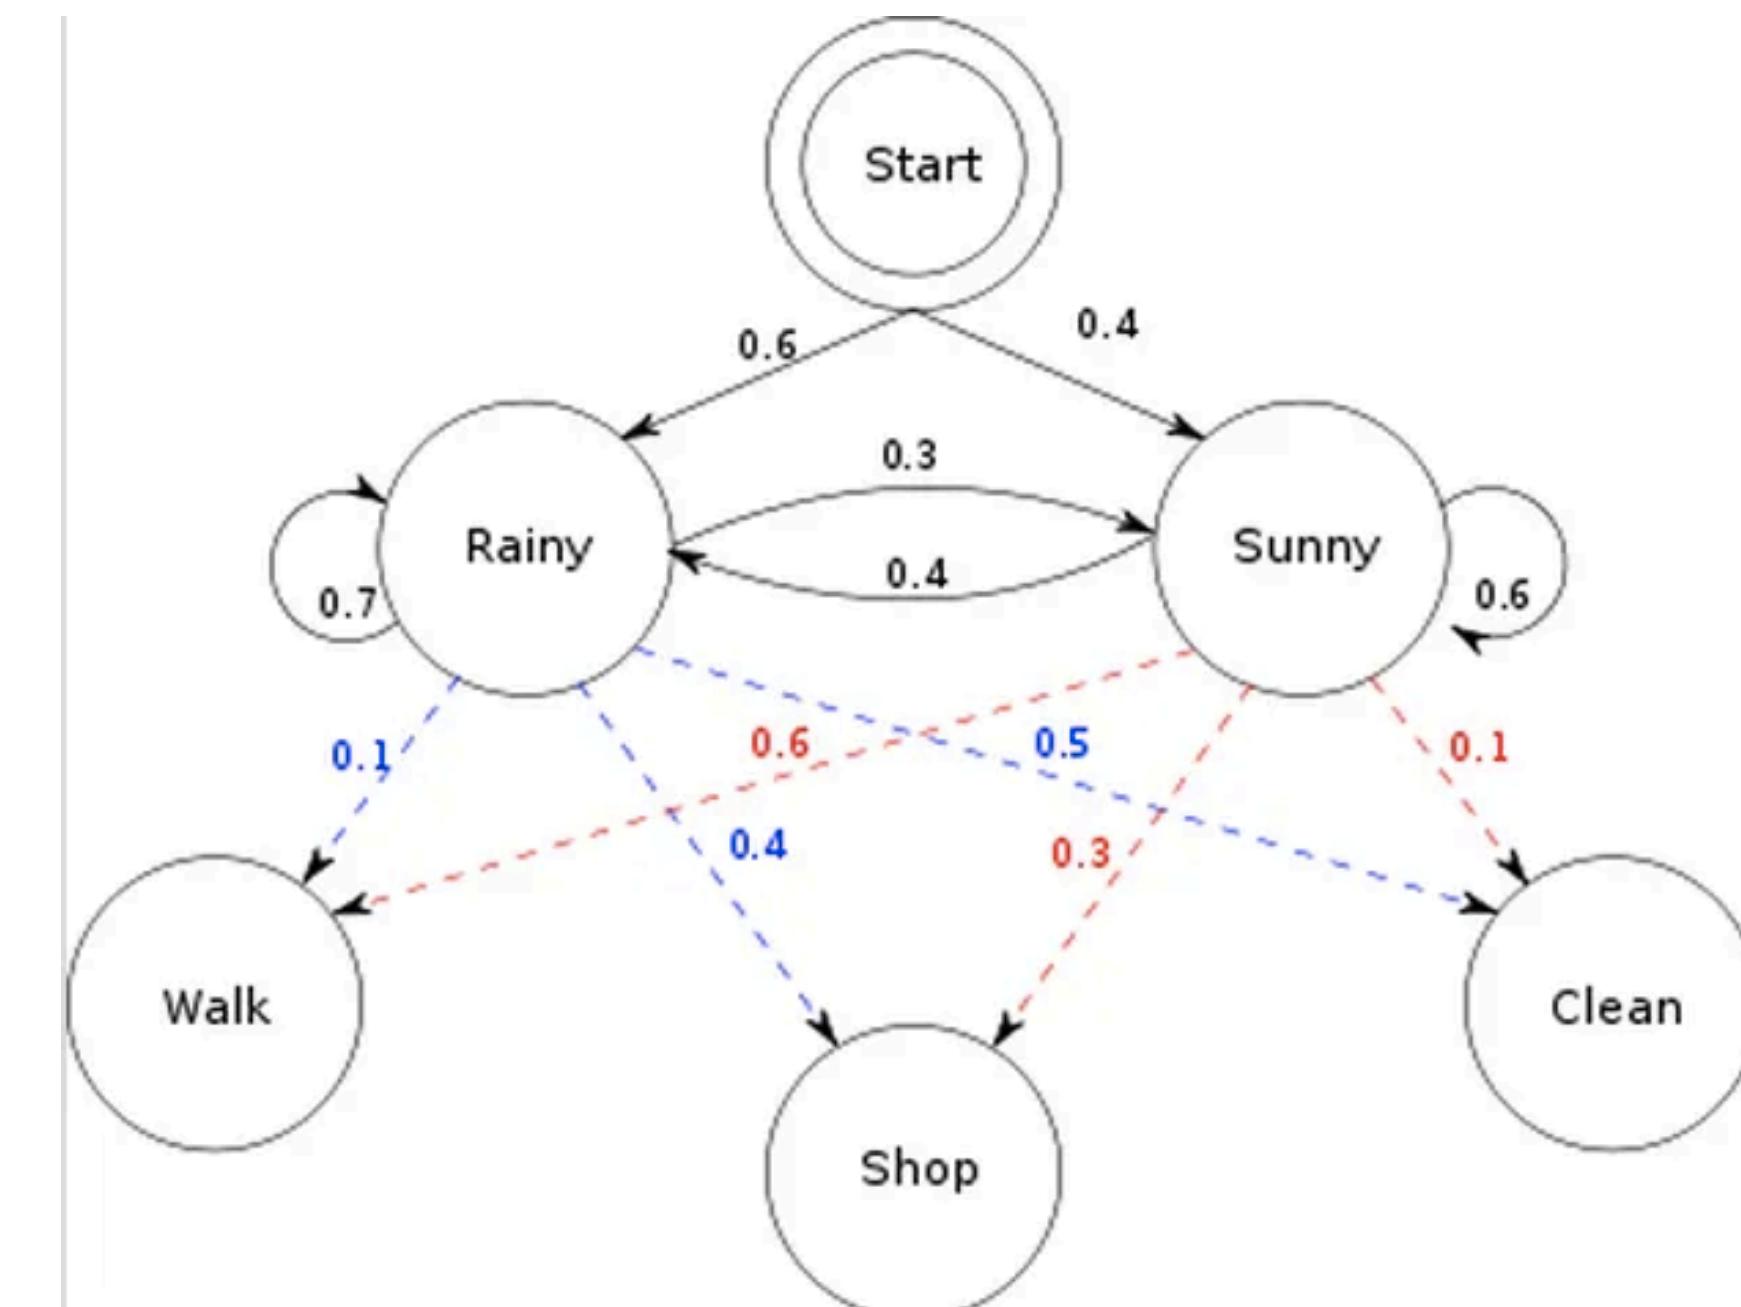
- 隐状态序列: 天气状况 (B无法直接观测到)

- 观测序列: A的行为 (A告知B)

- 行为概率: 以晴天和雨天两种情况为例

- ◆ 晴天: 散步, 购物, 内务的概率分别是0.6, 0.3, 0.1

- ◆ 雨天: 散步, 购物, 内务的概率分别是0.1, 0.4, 0.5



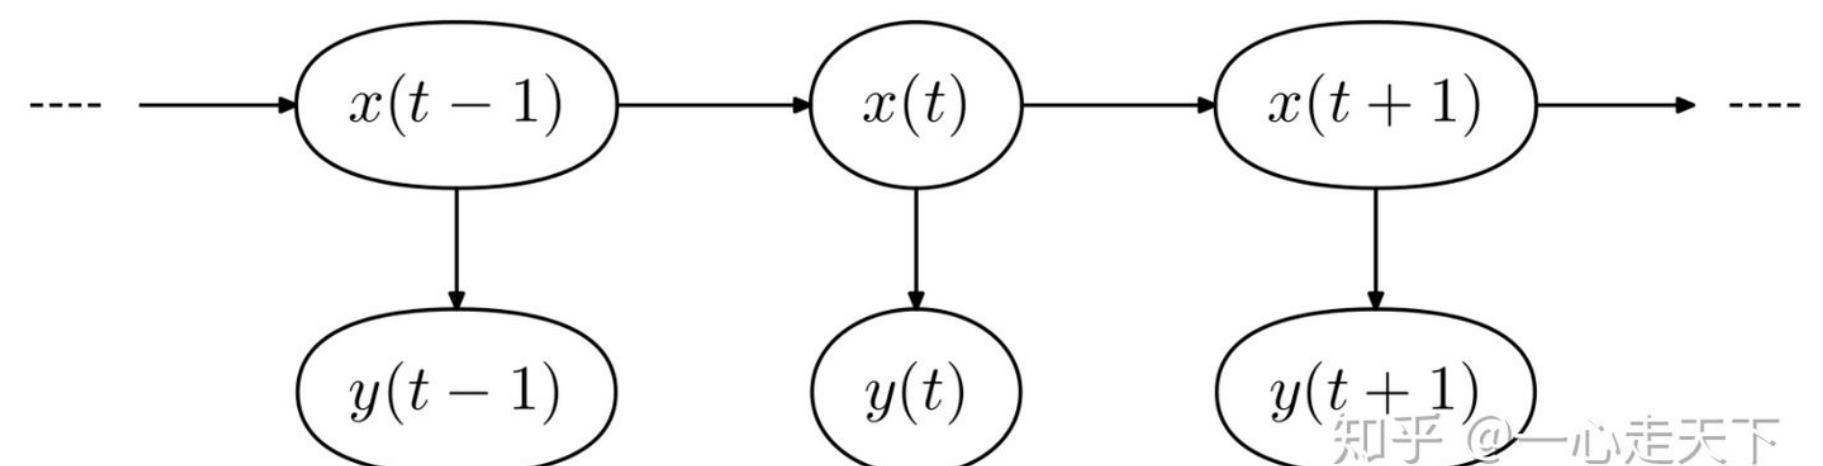
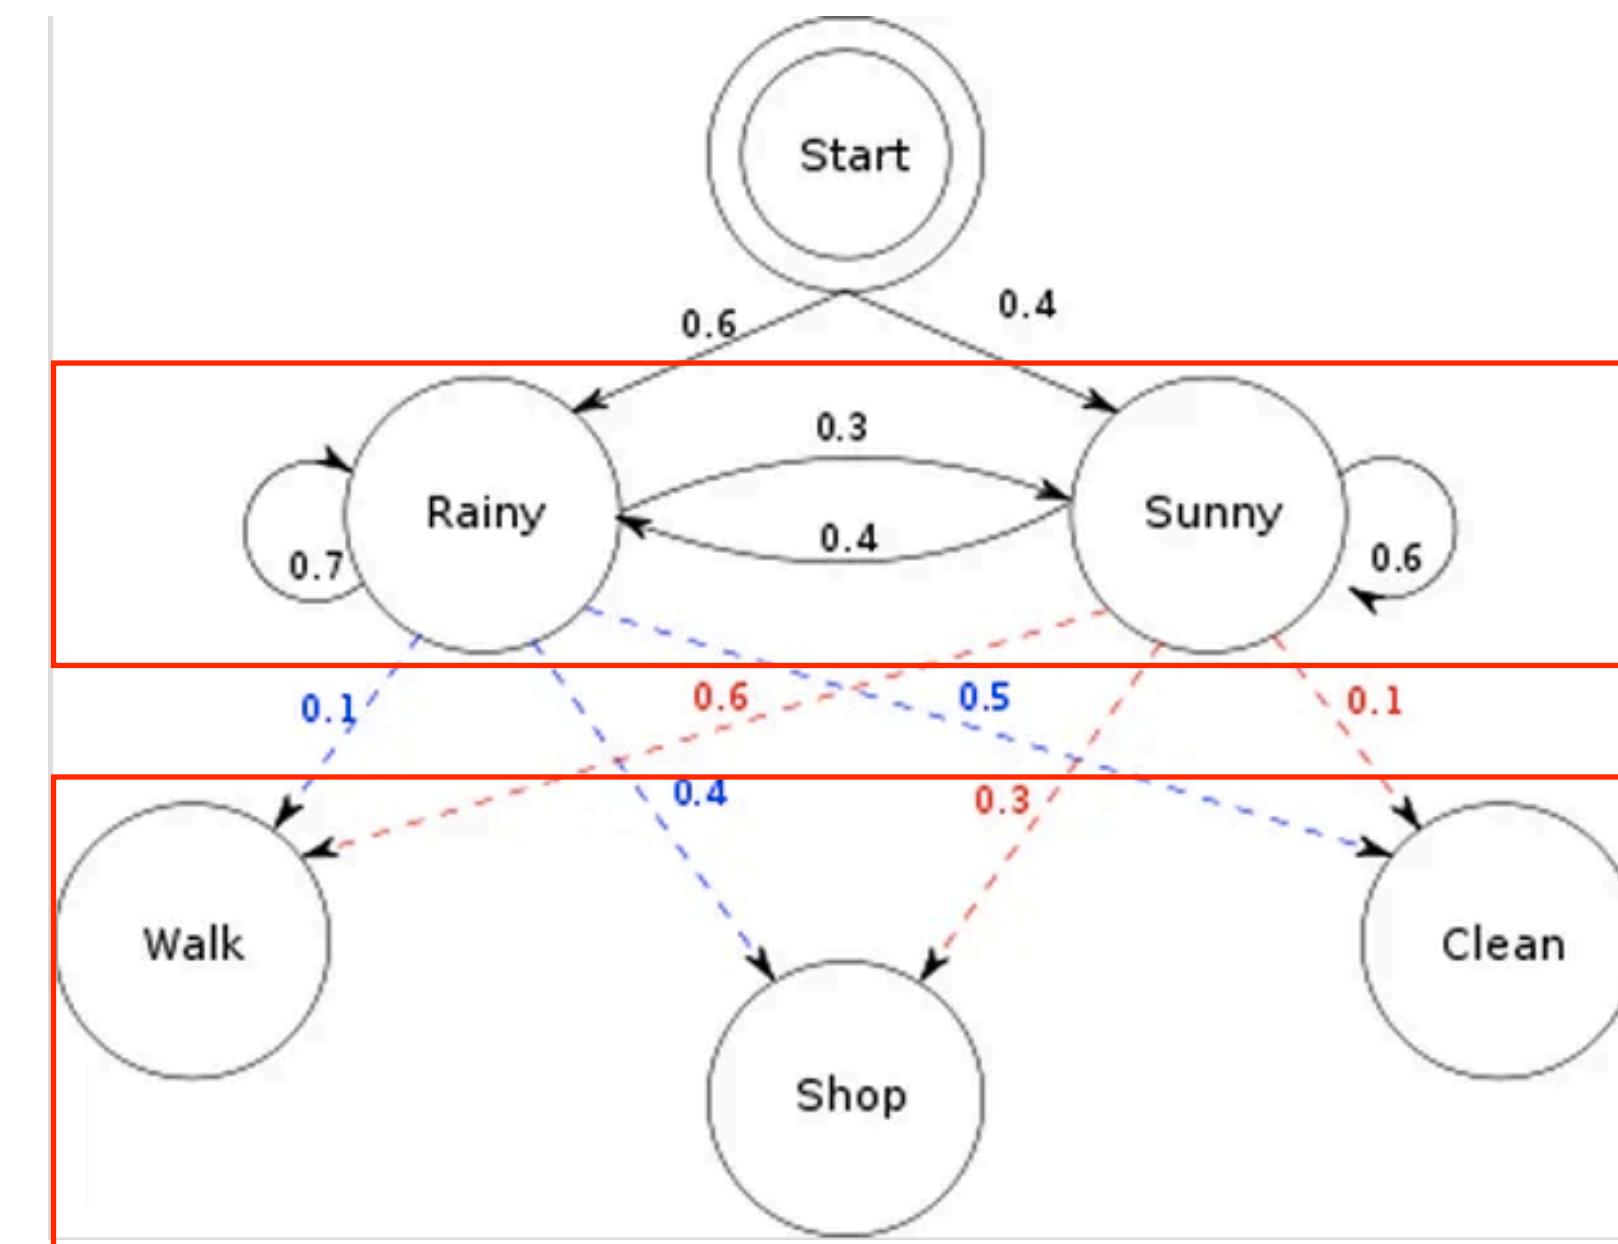
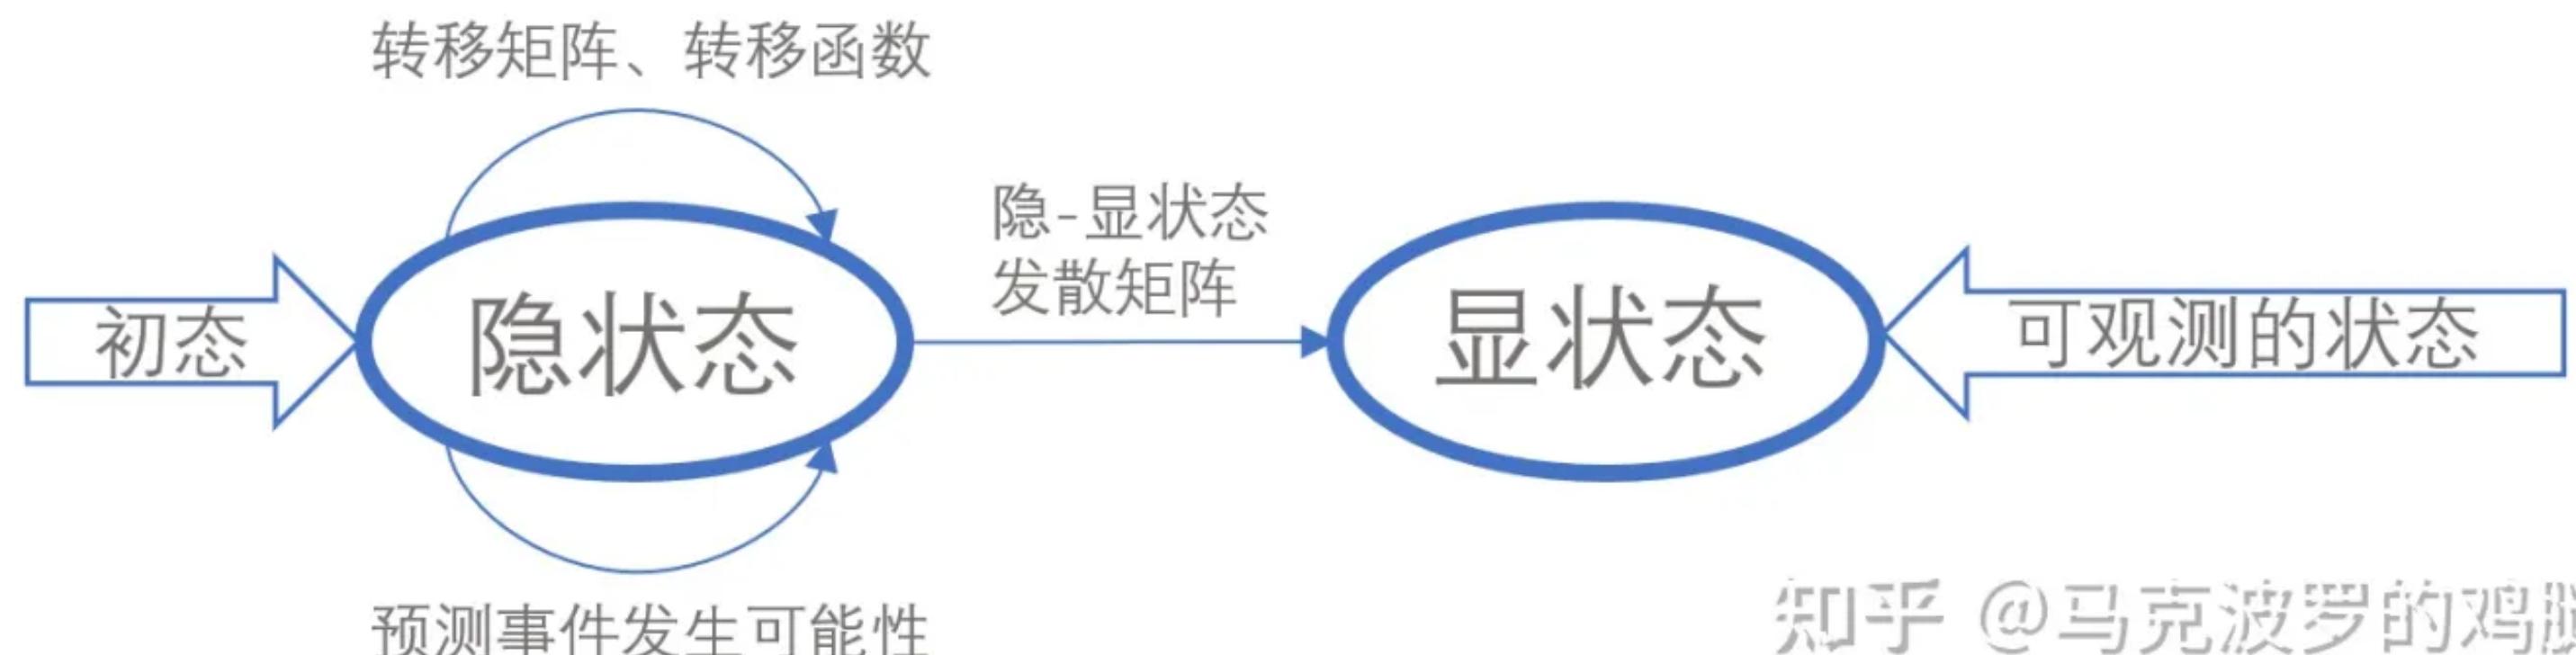
4.2 隐马尔科夫模型

- **HMM案例**
 - **问题1:** 已知整个模型，连续三天，A下班后做的事情分别是：散步，购物，内务。那么，B根据模型，计算产生这些行为的概率是多少。
 - **问题2:** 同样知晓这个模型，同样是这三件事，A要B猜，这三天她下班后北京的天气是怎么样的。这三天怎么样的天气才最有可能让她做这样事情。
 - **问题3,** 最复杂的，A只告诉B这三天她分别做了这三件事，而其他什么信息我都没有。A要B建立一个模型，晴雨转换概率，第一天天气情况的概率分布，根据天气情况她选择做某事的概率分布。（惨绝人寰）

4.2 隐马尔科夫模型

- 基本概念

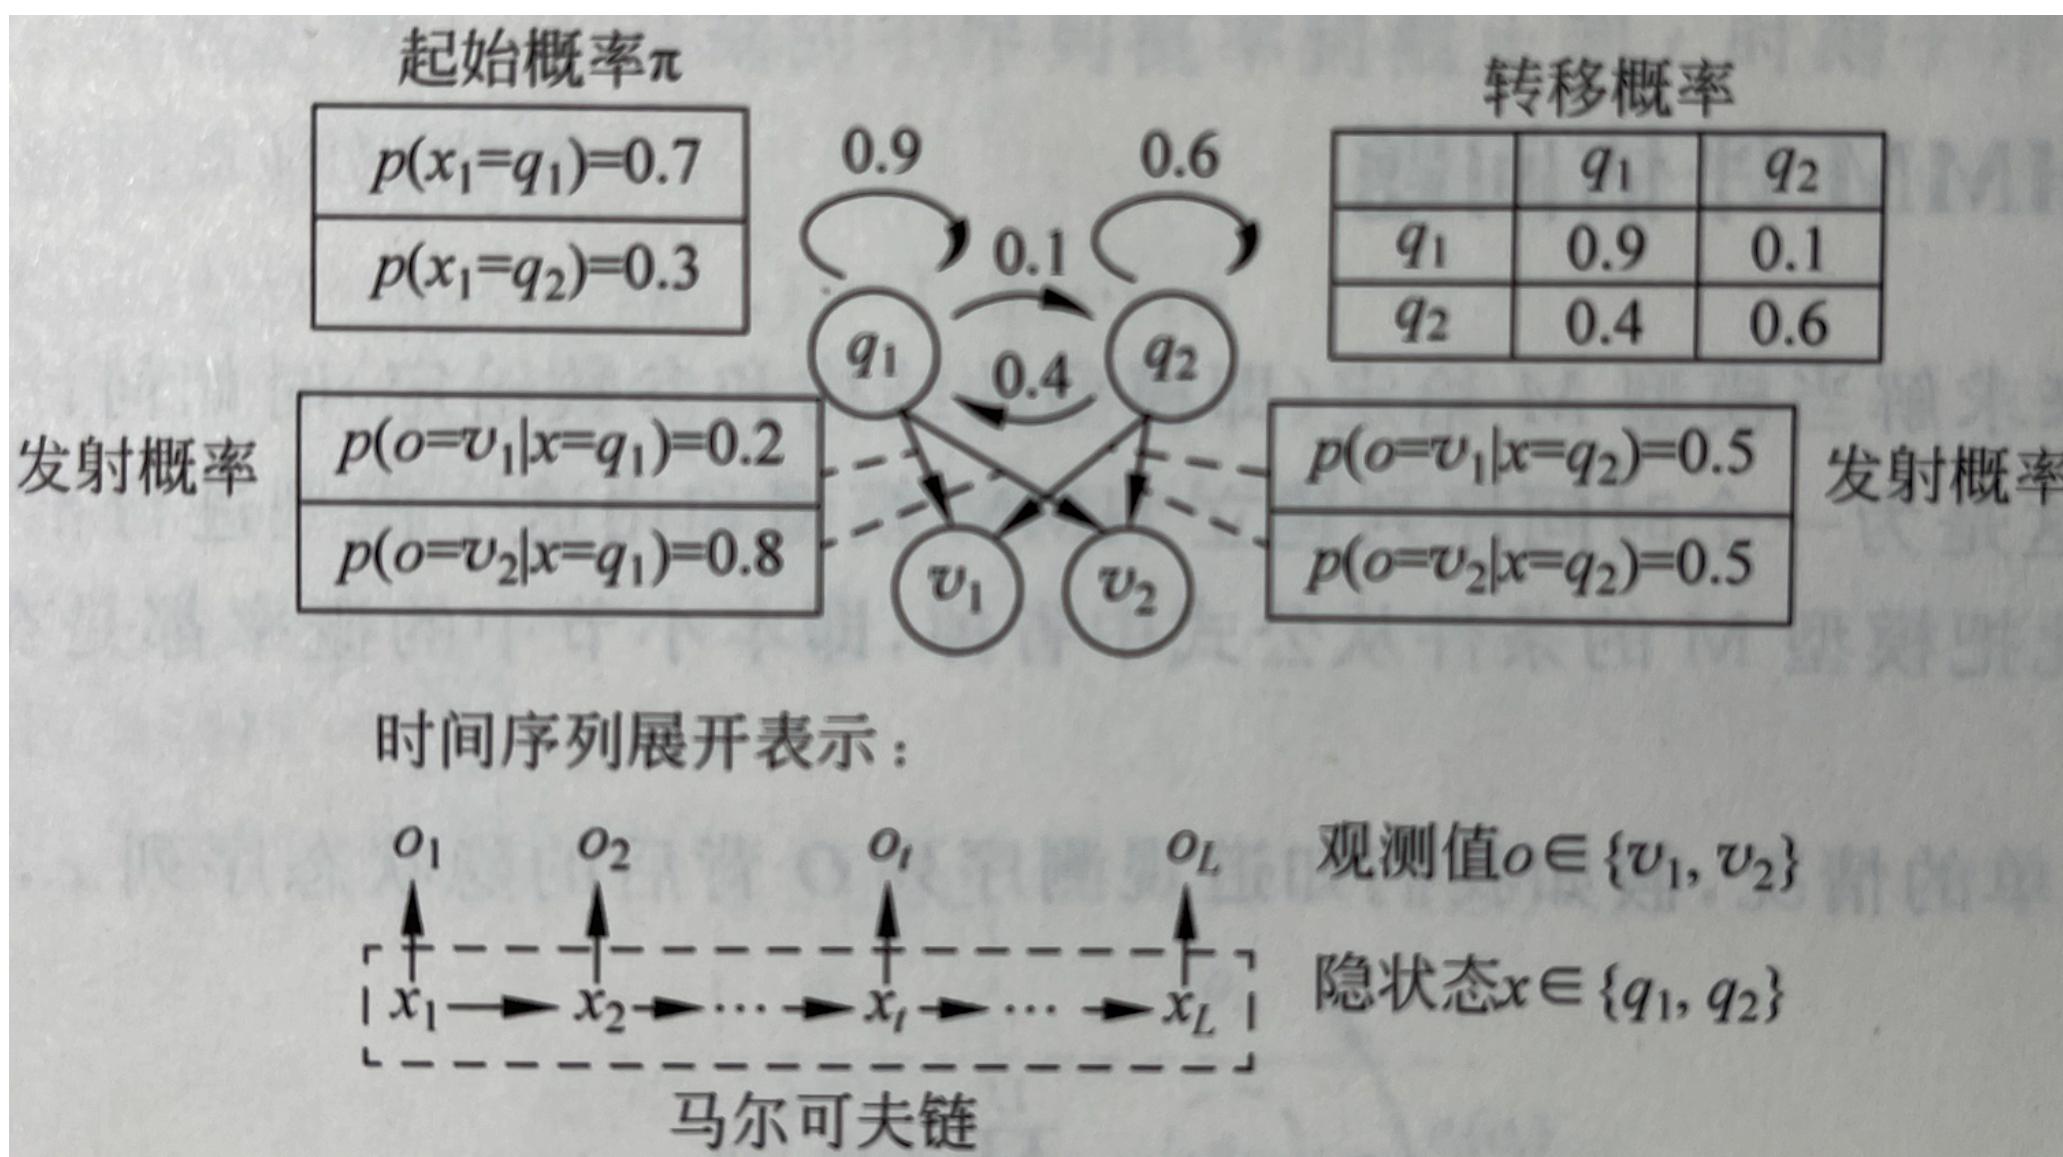
- 系统的状态取值服从马尔可夫链
- 系统状态的变化无法直接观察到
- 可能的状态和观测是贝叶斯网络的**隐节点**和**可观测节点**
- **转移概率**为隐节点之间的边
- **发射概率**为隐节点到可观测节点之间的边



知乎 @马克波罗的鸡腿

4.2 隐马尔科夫模型

- HMM三要素 $M = (A, E, \pi)$
 - 状态转移矩阵 A , 发射概率矩阵 E , 初始概率分布 π



变量表示	说明
$Q = \{q_1, q_2, \dots, q_n\}$	模型含有 n 个隐状态
$V = \{v_1, v_2, \dots, v_v\}$	观测值的取值范围
$A = [a_{ij}]_{n \times n}$	状态转移概率矩阵, a_{ij} 表示从状态 i 转到状态 j 的概率, 满足 $\sum_{j=1}^n a_{ij} = 1, \forall i$
$O = o_1 o_2 \dots o_L$	长度为 L 的观测序列, o_t 的取值为 V 中某个值
$X = x_1 x_2 \dots x_L$	长度为 L 的隐状态序列, x_t 的取值为 Q 中某个值
$E = [e_{ij}]_{n \times V}$	发射概率矩阵, $e_{ij} = p(o = v_j x = q_i)$ 表示模型隐状态取值 q_i 时观测到 v_j 的概率, 满足 $\sum_{j=1}^V e_{ij} = 1, \forall i$
$\pi = [\pi_1, \pi_2, \dots, \pi_n]$	初始概率分布, π_i 表示马氏链从该状态起始的概率, 满足 $\sum_{i=1}^n \pi_i = 1$

4.2 隐马尔科夫模型

- 隐马尔科夫模型的三种典型问题：解决时间序列的决策问题

- 模型评估问题 (Evaluation)

概率计算问题。已知HMM模型 M 和观测序列 O , 求当前观测序列出现的概率 $p(O | M)$ (似然度)。

- 隐状态推断问题 (Decoding)

预测问题。已知HMM模型 M 和观测序列 O , 求产生该序列的最有可能的隐状态序列

$$x = \arg \max_x p(x, O | M).$$

- 模型学习问题 (Learning)

已知观测序列 O 和隐层状态序列 x , 求HMM的模型参数 $\arg \max_M p(x, O | M)$ 或者

$$\arg \max_M p(O | M).$$

4.2.1 HMM模型评估问题

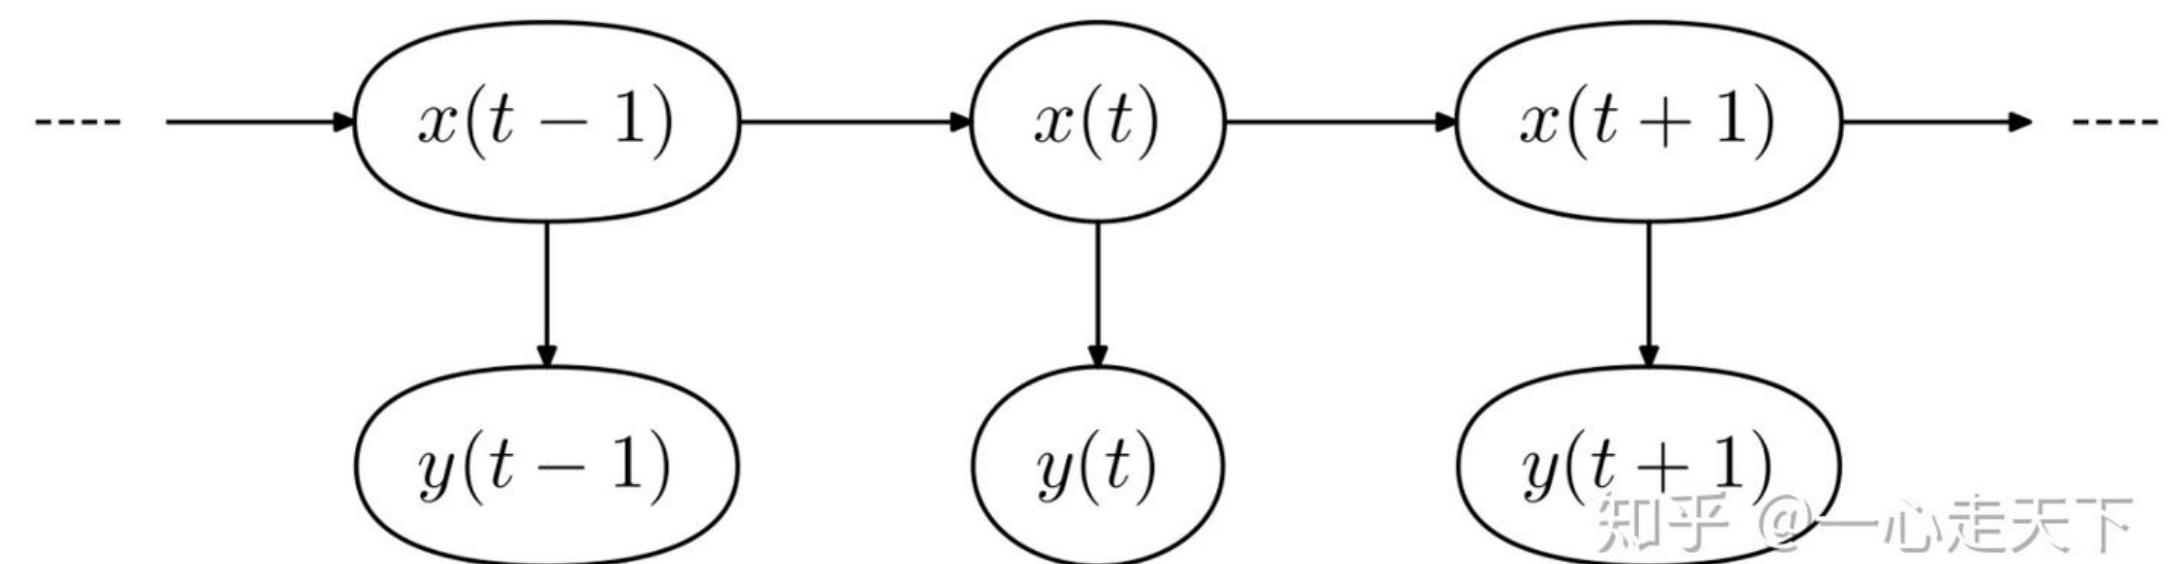
已知HMM模型 M （模型结构和参数）和观测序列 O ，求当前观测序列出现的概率 $p(O|M)$ （似然度）。

- 已知隐状态序列 x ，即 $p(x)$ 已知

似然度：
$$p(O|x) = \prod_{i=1}^L p(o_i | x_i)$$

- 观测序列 O 和隐状态序列 x 的联合概率，即 $p(O|M)$ ：

$$p(O, x) = p(O | x)p(x) = \prod_{i=1}^L p(o_i | x_i) \left(\pi_{x_1} \prod_{i=2}^L p(x_i | x_{i-1}) \right)$$



4.2.1 HMM模型评估问题

已知HMM模型 M （模型结构和参数）和观测序列 O ，求当前观测序列出现的概率 $p(O|M)$ （似然度）。

- 未知隐状态序列 x ，即 $p(x)$ 未知
 - 概率分解：穷举，求解当前观测序列在所有可能隐状态序列下的加权概率和

$$p(O) = \sum_x p(O, x) = \sum_x p(O, x)p(x)$$

- 计算量巨大： n^L 种隐状态序列取值组合

4.2.1 HMM模型评估问题

- 前向（向前）算法：Forward Algorithm
 - 已知当前状态，要得到结果，往后能怎么“走”？（**求果**）
 - 从前往后，迭代求解：长度为 t 的观测子序列 $o_1 o_2 \dots o_t$ 在 t 时刻隐变量取值 q_j 的概率 $\alpha_t(j)$
 - $\alpha_t(j) = p(o_1 o_2 \dots o_t, x_t = q_j)$: t 时刻，隐状态为 q_j 时，观测子序列(1-t)出现的概率
 - $\alpha_t(j) = \sum_{i=1}^n \alpha_{t-1}(i) a_{ij} e_j(o_t) = e_j(o_t) \sum_{i=1}^n \alpha_{t-1}(i) a_{ij}$, n 为隐状态数
 - $\alpha_1(j), \alpha_2(j), \dots, \alpha_L(j)$
 - 终止结果
 - $p(O) = \sum_{i=1}^n \alpha_L(i)$: 将最终结点的（不同走法）的概率求和，就是产生目前观测的可能情况

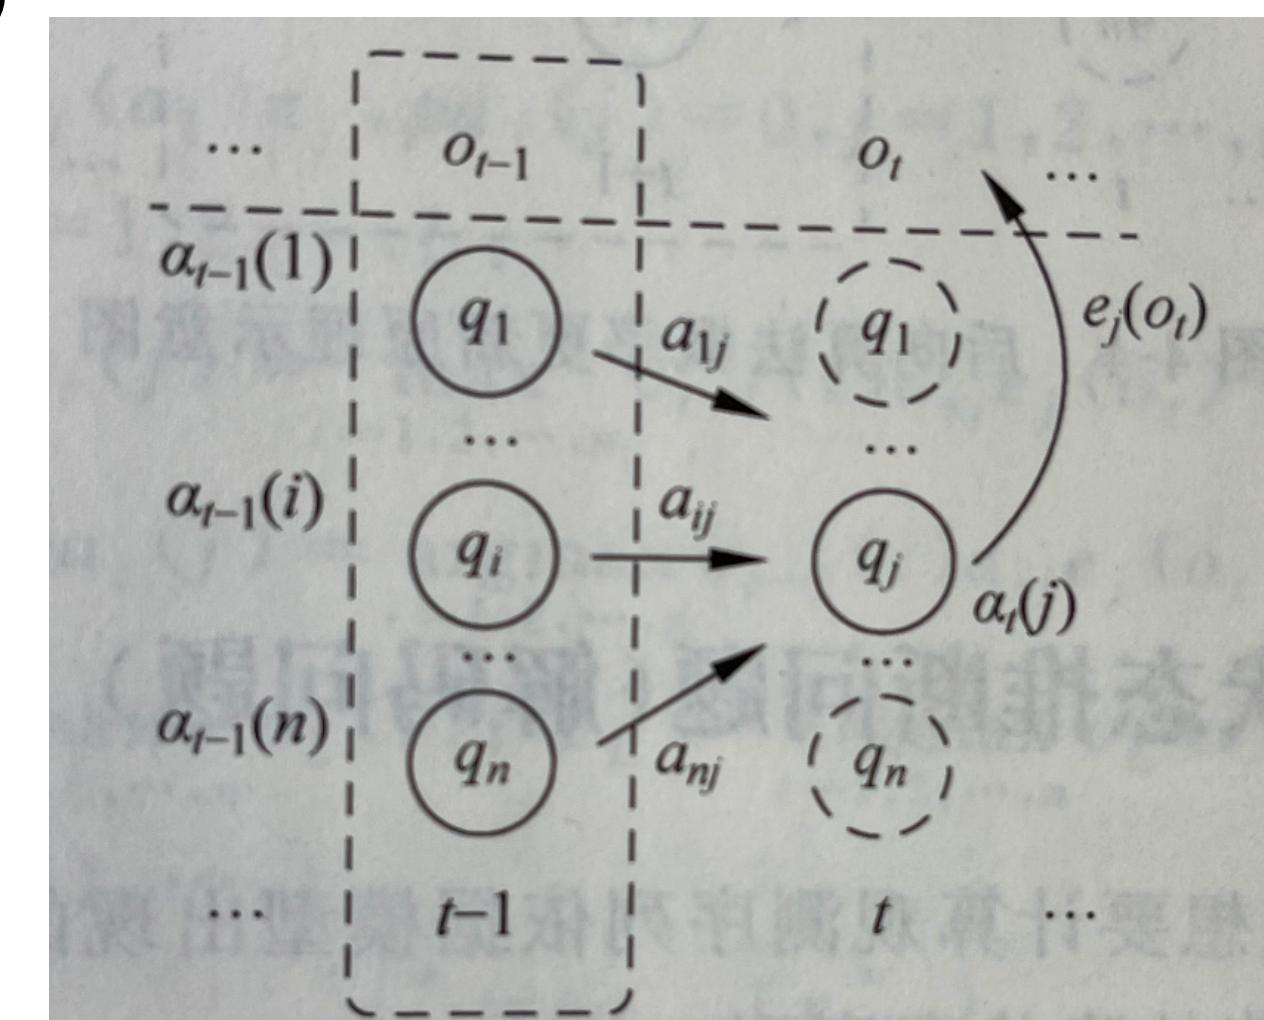


图 4-3 前向算法概率更新原理示意图

4.2.1 HMM模型评估问题

- 前向算法举例

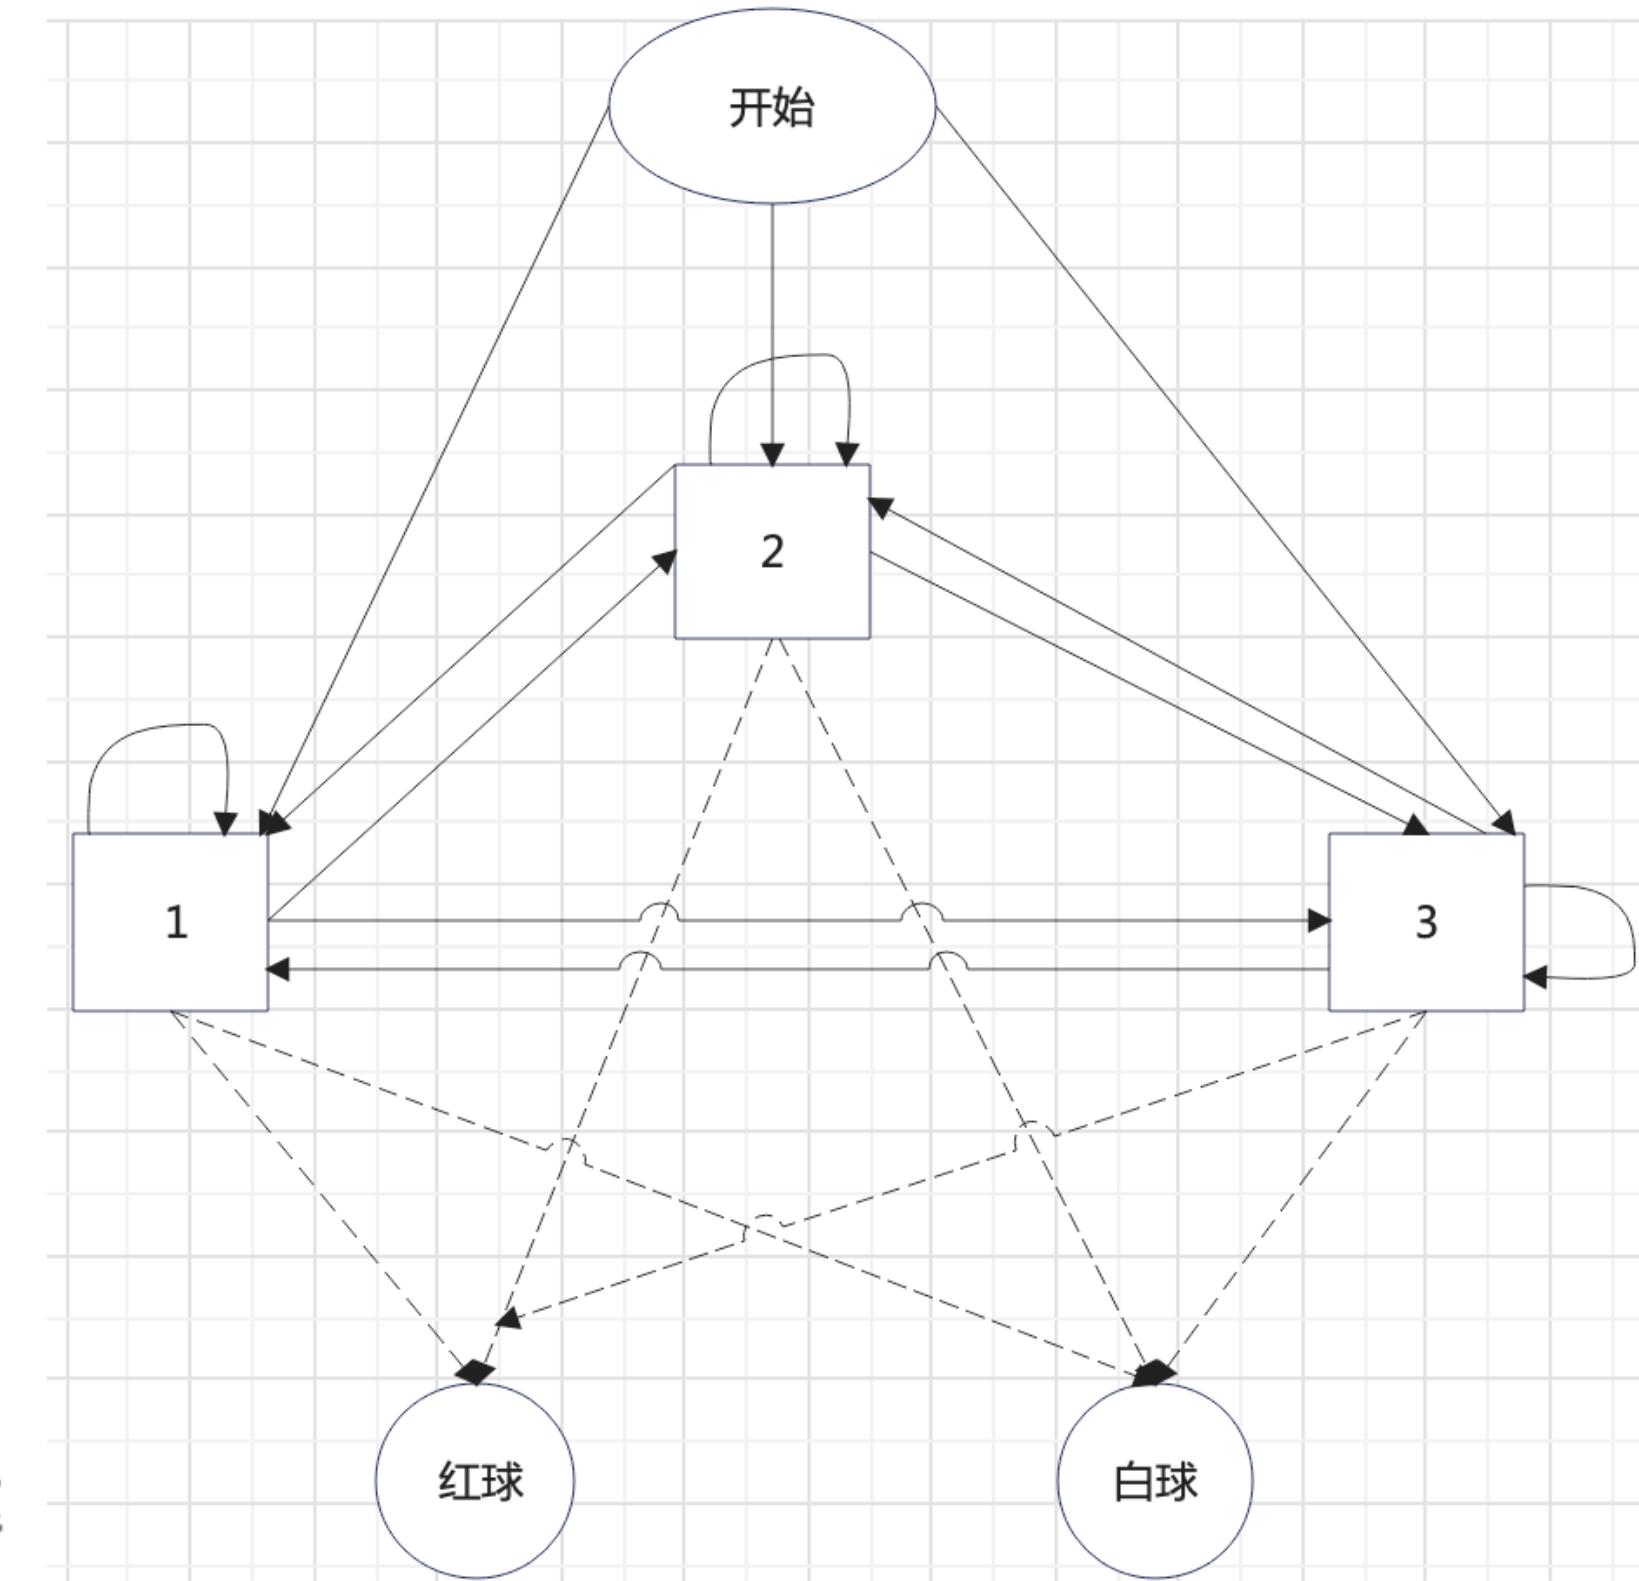
例如，李航《统计学习方法》例10.2的模型，观测序列为 $O = \{\text{红}, \text{白}, \text{红}\}$ ，提供转移矩阵A，发射矩阵B，初始矩阵 π ，求最优的状态序列（也就是说这红，白，红最可能是通过怎样从1、2、3号盒中拿球得到的）

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}$$

$$\pi = (0.2, 0.4, 0.4)^T$$

求给定这个模型条件下，观测为 $O = (\text{红}, \text{白}, \text{红})$ 的概率



4.2.1 HMM模型评估问题

• 前向算法举例

计算初值，第一局取的是红球，可能从1, 2, 3号盒取：

- 红球是从1盒取的： $\alpha_{red}(1) = \pi_1 b_1(o_{red}) = 0.2 \times 0.5 = 0.1$
- 红球是从2盒取的： $\alpha_{red}(2) = \pi_2 b_2(o_{red}) = 0.4 \times 0.4 = 0.16$
- 红球是从3盒取的： $\alpha_{red}(3) = \pi_3 b_3(o_{red}) = 0.4 \times 0.7 = 0.28$

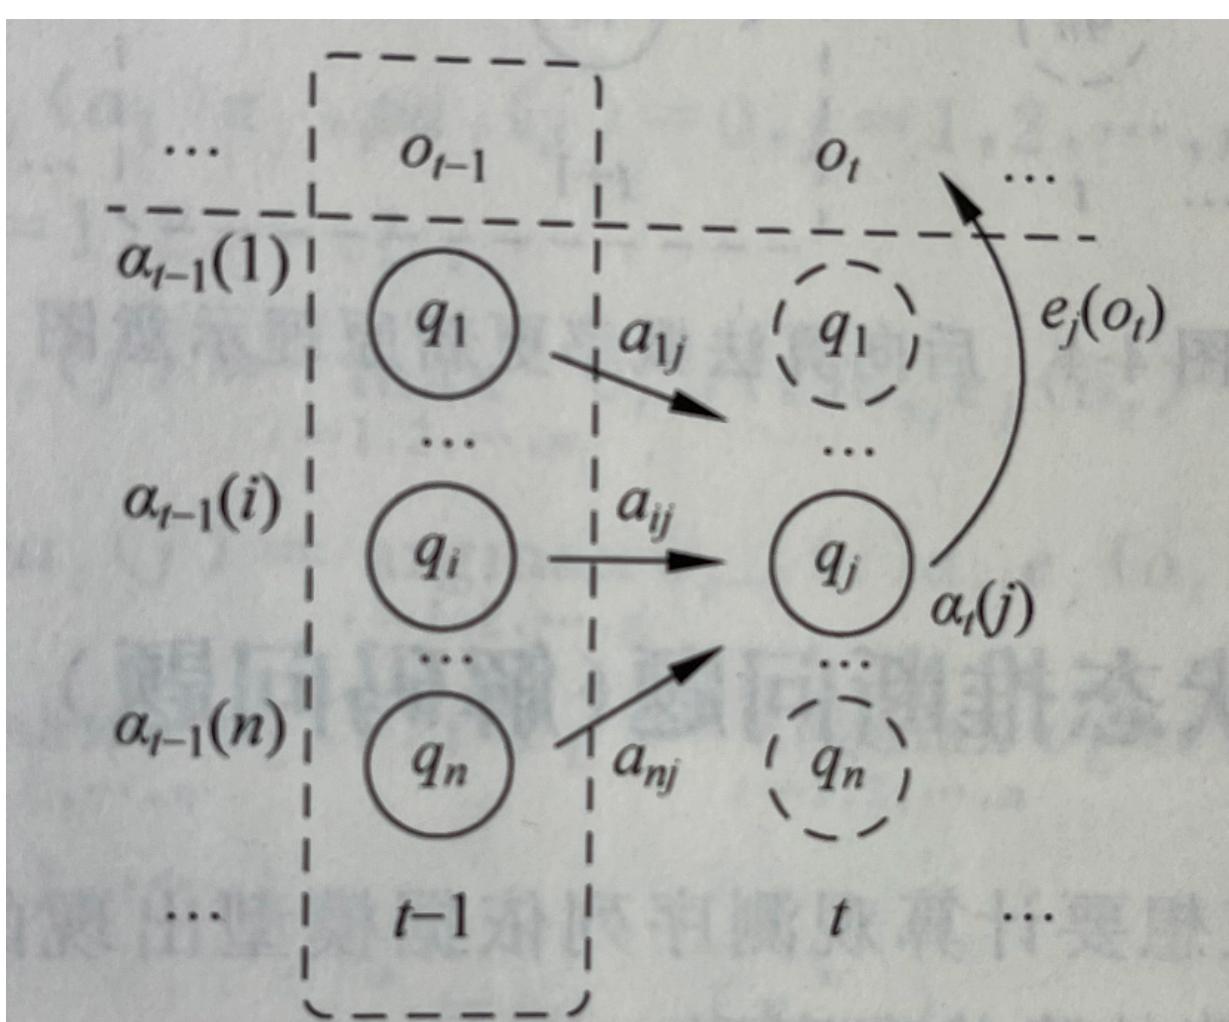


图 4-3 前向算法概率更新原理示意图

$$\alpha_t(j) = \sum_{i=1}^n \alpha_{t-1}(i) a_{ij} e_j(o_t) = e_j(o_t) \sum_{i=1}^n \alpha_{t-1}(i) a_{ij}$$

第二局取的是白球，可能从1, 2, 3号盒取

- 白球从1号盒取的概率：

$$\alpha_{white}(1) = (\alpha_{red}(1) \cdot a_{11} + \alpha_{red}(2) \cdot a_{21} + \alpha_{red}(3) \cdot a_{31}) \cdot b_1(O_{white})$$

$$= (0.1 \times 0.5 + 0.16 \times 0.3 + 0.28 \times 0.2) \times 0.5 = 0.154 * 0.5 = 0.077$$

- 白球从2号盒取的概率：

$$\alpha_{white}(2) = (\alpha_{red}(1) \cdot a_{12} + \alpha_{red}(2) \cdot a_{22} + \alpha_{red}(3) \cdot a_{32}) \cdot b_2(O_{white})$$

$$= (0.1 \times 0.2 + 0.16 \times 0.5 + 0.28 \times 0.3) \times 0.6 = 0.184 * 0.6 = 0.1104$$

- 白球从3号盒取的概率

$$\alpha_{white}(3) = (\alpha_{red}(1) \cdot a_{13} + \alpha_{red}(2) \cdot a_{23} + \alpha_{red}(3) \cdot a_{33}) \cdot b_3(O_{white})$$

$$= (0.1 \times 0.3 + 0.16 \times 0.2 + 0.28 \times 0.5) \times 0.7 = 0.202 * 0.3 = 0.0606$$

4.2.1 HMM模型评估问题

第三局取的是红球，可能从1, 2, 3号盒取

• 前向算法举例

- 红球从1号盒取的概率：

$$\alpha_{red}(1) = (\alpha_{white}(1) \cdot a_{11} + \alpha_{white}(2) \cdot a_{21} + \alpha_{white}(3) \cdot a_{31}) \cdot b_1(O_{red})$$

$$= (0.077 \times 0.5 + 0.1104 \times 0.3 + 0.0606 \times 0.2) \times 0.5 = 0.08374 * 0.5 = 0.04187$$

- 红球从2号盒取的概率：

$$\alpha_{red}(2) = (\alpha_{white}(1) \cdot a_{12} + \alpha_{white}(2) \cdot a_{22} + \alpha_{white}(3) \cdot a_{32}) \cdot b_2(O_{red})$$

$$= (0.077 \times 0.2 + 0.1104 \times 0.5 + 0.0606 \times 0.3) \times 0.4 = 0.08878 * 0.4 = 0.03551$$

- 红球从3号盒取的概率

$$\alpha_{red}(3) = (\alpha_{white}(1) \cdot a_{13} + \alpha_{white}(2) \cdot a_{23} + \alpha_{white}(3) \cdot a_{33}) \cdot b_3(O_{red})$$

$$= (0.077 \times 0.3 + 0.1104 \times 0.2 + 0.0606 \times 0.5) \times 0.7 = 0.08878 * 0.7 = 0.05284$$

终止：

$$P(O|\lambda) = \alpha_{red}(1) + \alpha_{red}(2) + \alpha_{red}(3) = 0.04187 + 0.03551 + 0.05284 = 0.13022$$

以上过程其实是前向算法

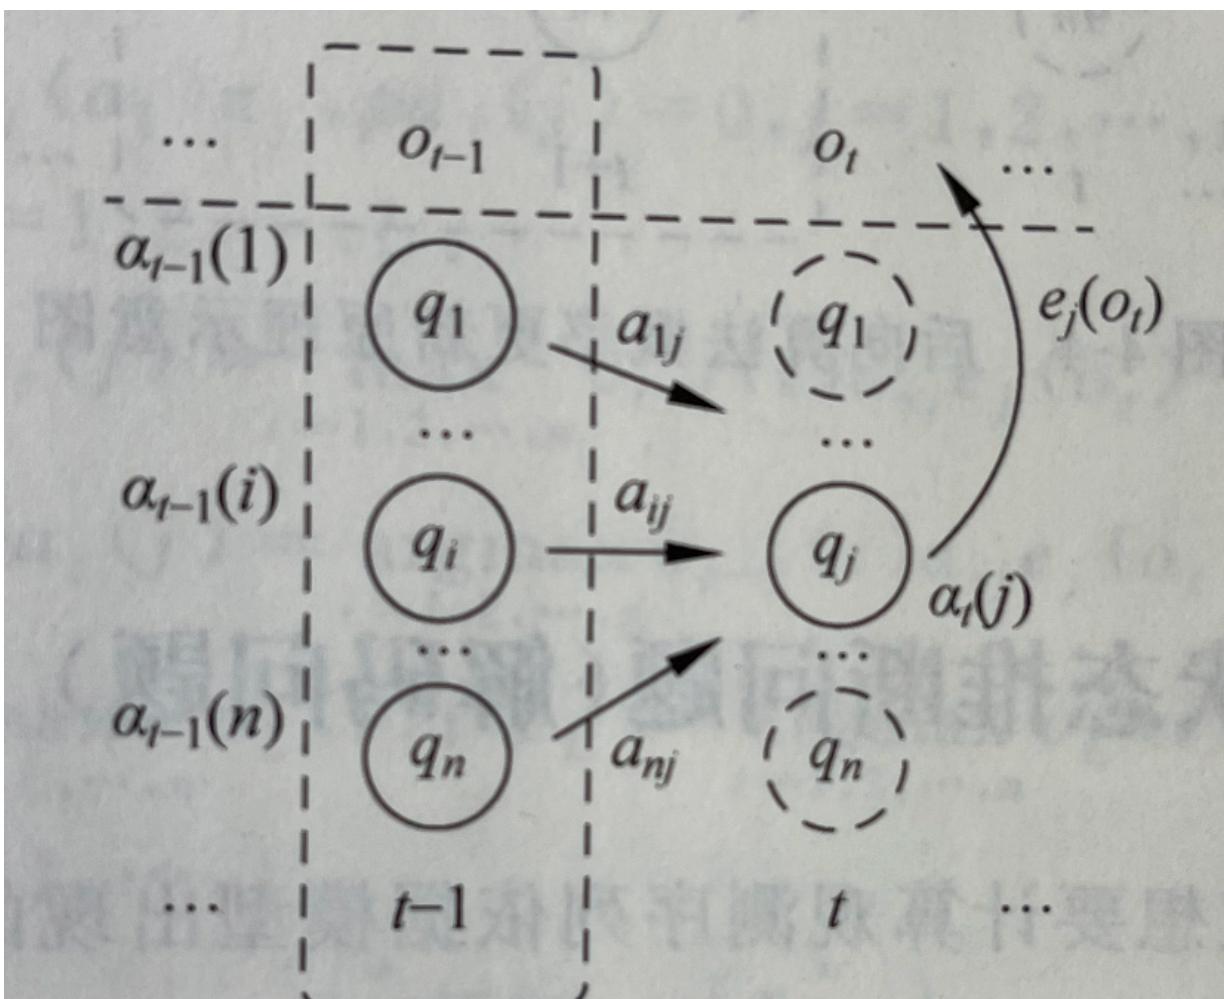


图 4-3 前向算法概率更新原理示意图

4.2.1 HMM模型评估问题

- 后向（向后）算法：Backward Algorithm
 - 已知结果，是当初怎么“走”造成的？（追因）
 - 从后往前求解： t 时刻隐状态 $x_t = q_j$ 时，观察到后续观测值 $o_{t+1} o_{t+2} \dots o_L$ 的概率 $\beta_t(j)$
 - $\beta_t(j) = p(o_{t+1} o_{t+2} \dots o_L | x_t = q_j)$: t 时刻，隐状态为 q_j 时，观测子序列($t+1 - L$)出现的概率
 - $\beta_t(j) = \sum_{i=1}^n \beta_{t+1}(i) e_i(o_{t+1}) a_{ji}$
 - $\beta_L(j) = 1, \beta_{L-1}(j), \dots, \beta_1(j)$
 - 终止结果
 - $p(O) = \sum_{i=1}^n \pi_i e_i(o_1) \beta_1(i)$

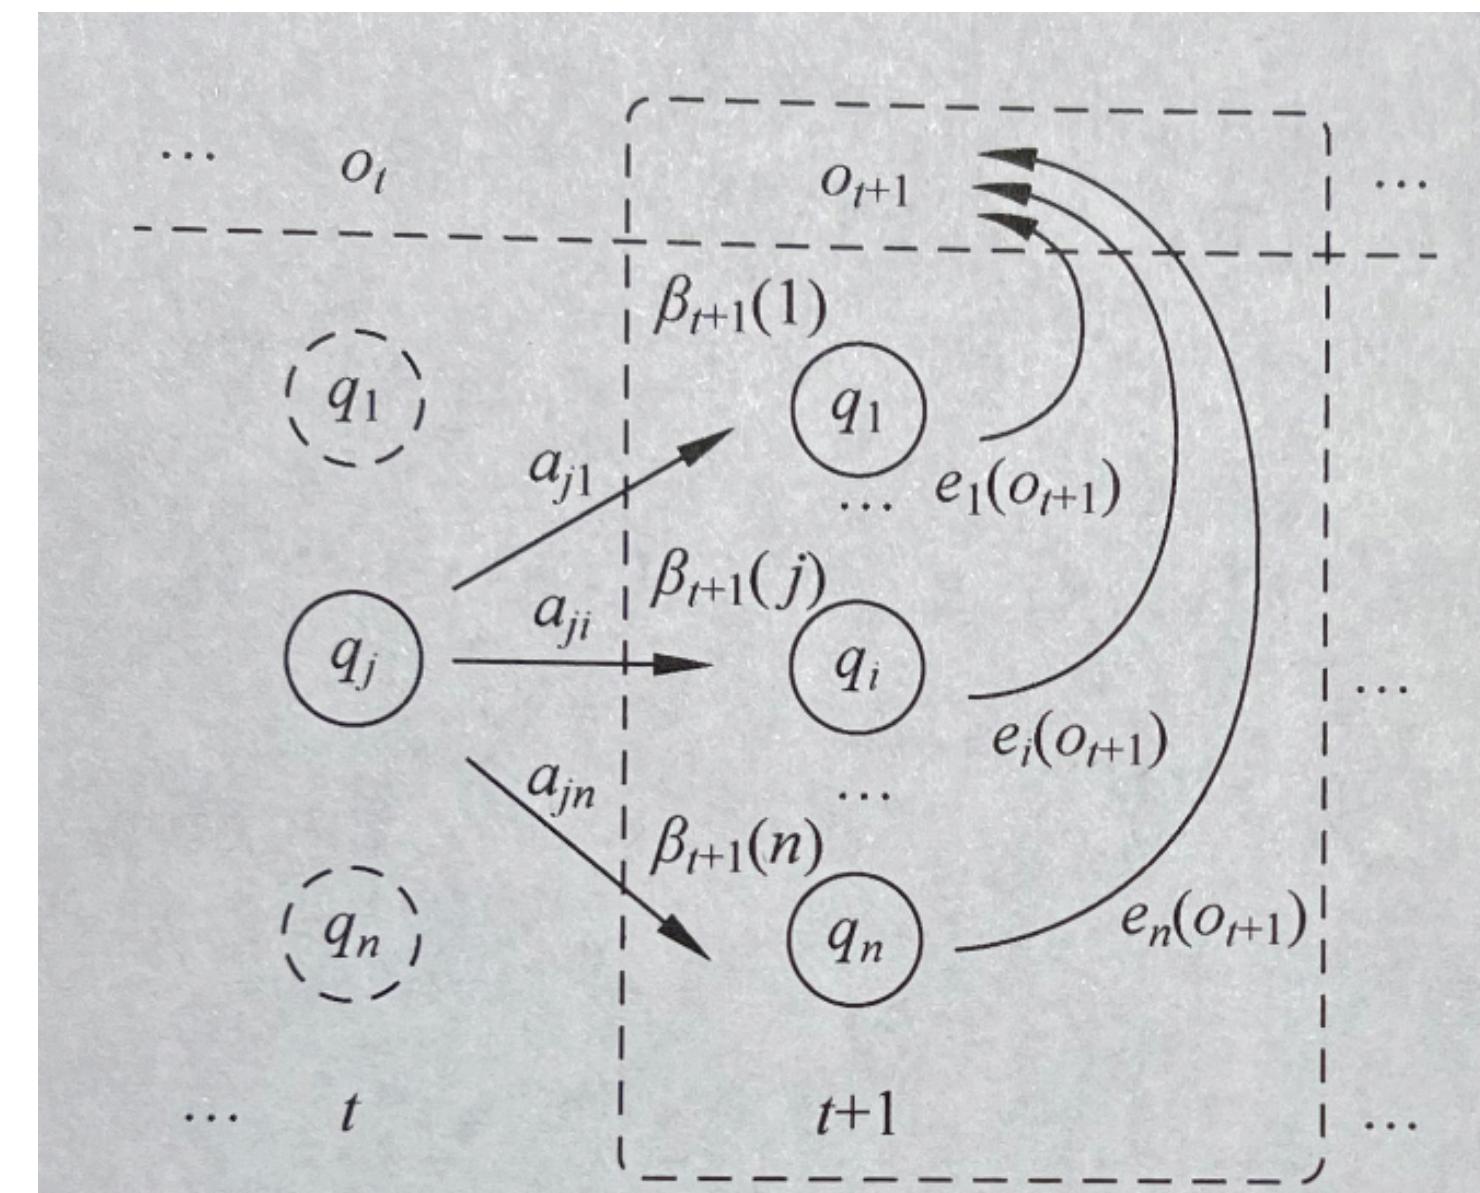


图 4-4 后向算法概率更新原理示意图

4.2.1 HMM模型评估问题

- 后向算法举例

给定模型 $\lambda = (A, B, \pi)$ 和观测序列 $O = (o_1, o_2, \dots, o_T)$ ，计算在模型 λ 下观测序列 O 出现的概率 $P(O|\lambda)$

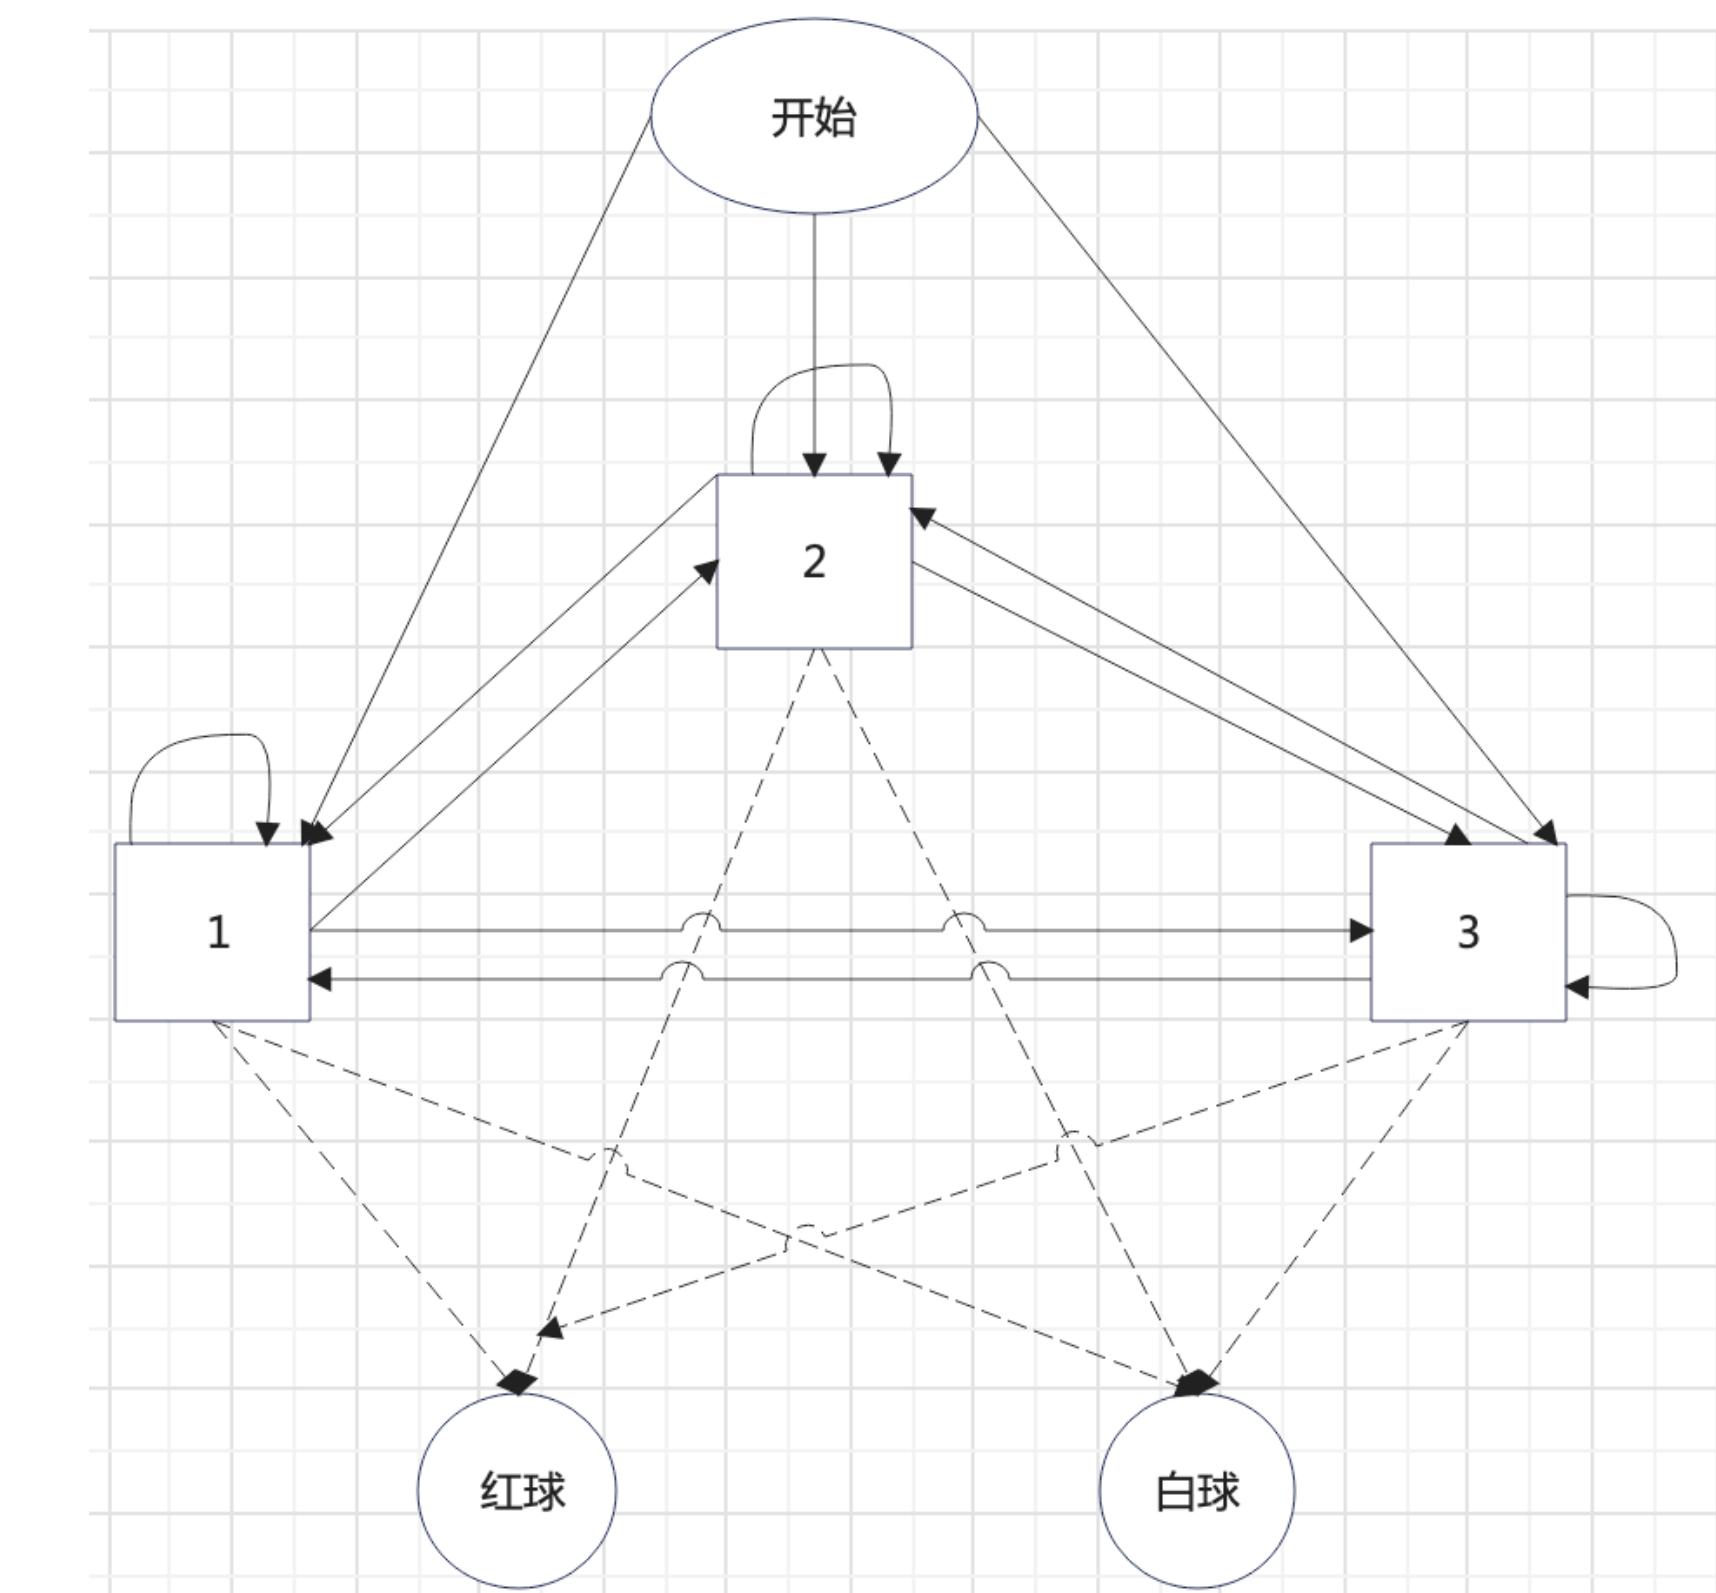
还是前面文章的那个例子，同样的条件

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}$$

$$B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}$$

$$\pi = (0.2, 0.4, 0.4)^T$$

求给定这个模型条件下，观测为 $O = (\text{红}, \text{白}, \text{红})$ 的概率



4.2.1 HMM模型评估问题

• 后向算法举例

第三个观测是红球的情况：

- 第三个观测红球来自1号盒: $\beta_{red}(1) = 1$
- 第三个观测红球来自2号盒: $\beta_{red}(2) = 1$
- 第三个观测红球来自3号盒: $\beta_{red}(3) = 1$

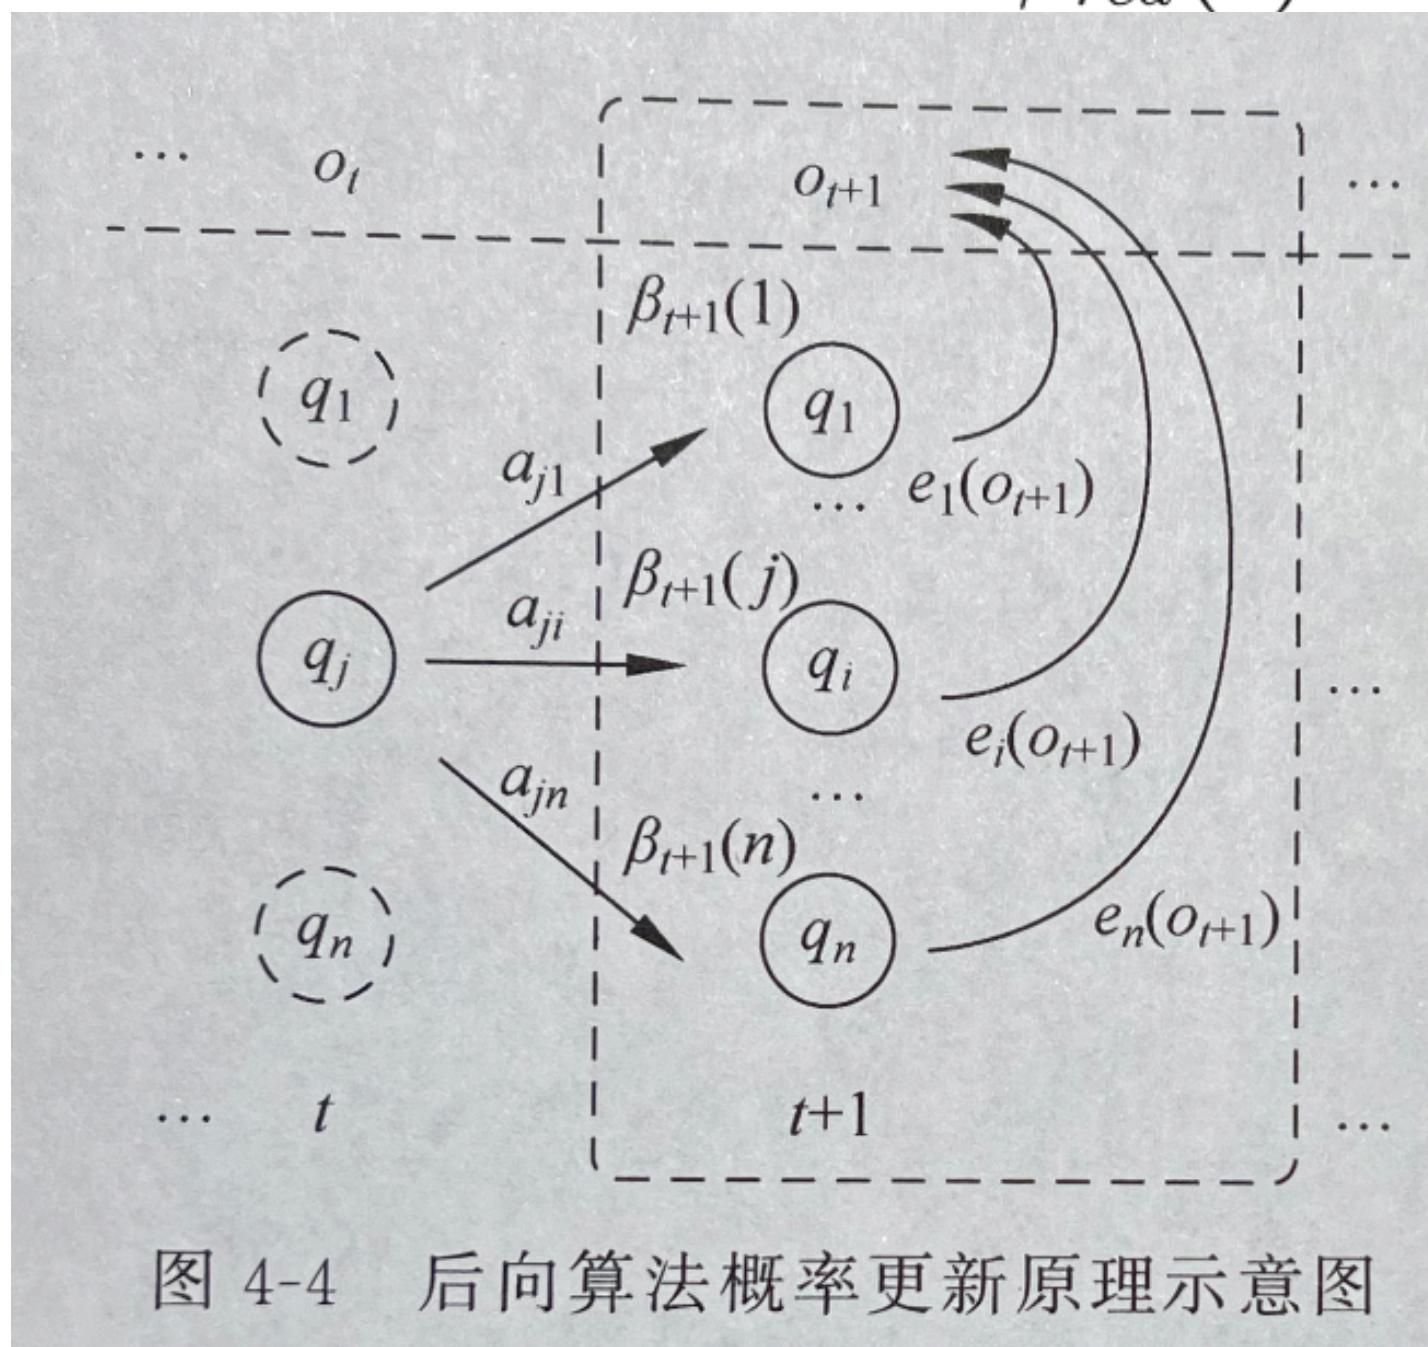


图 4-4 后向算法概率更新原理示意图

- 第二个观测白球来自1号盒:

$$\beta_t(j) = \sum_{i=1}^n \beta_{t+1}(i) e_i(o_{t+1}) a_{ji}$$

$$\beta_{white}(1) = a_{11} b_{red}(1) \beta_{red}(1) + a_{12} b_{red}(2) \beta_{red}(2) + a_{13} b_{red}(3) \beta_{red}(3)$$

$$= 0.5 \times 0.5 \times 1 + 0.3 \times 0.4 \times 1 + 0.2 \times 0.7 \times 1 = 0.51$$

- 第二个观测白球来自2号盒:

$$\beta_{white}(2) = a_{21} b_{red}(1) \beta_{red}(1) + a_{22} b_{red}(2) \beta_{red}(2) + a_{23} b_{red}(3) \beta_{red}(3)$$

$$= 0.2 \times 0.5 \times 1 + 0.5 \times 0.4 \times 1 + 0.3 \times 0.7 \times 1 = 0.51$$

- 第二个观测白球来自3号盒:

$$\beta_{white}(3) = a_{31} b_{red}(1) \beta_{red}(1) + a_{32} b_{red}(2) \beta_{red}(2) + a_{33} b_{red}(3) \beta_{red}(3)$$

$$= 0.3 \times 0.5 \times 1 + 0.2 \times 0.4 \times 1 + 0.5 \times 0.7 \times 1 = 0.58$$

4.2.1 HMM模型评估问题

• 后向算法举例

- 第一个观测红球来自1号盒:

$$\beta_t(j) = \sum_{i=1}^n \beta_{t+1}(i) e_i(o_{t+1}) a_{ji}$$

$$\begin{aligned}\beta_{red}(1) &= a_{11} b_{white}(1) \beta_{white}(1) + a_{12} b_{white}(2) \beta_{white}(2) + a_{13} b_{white}(3) \beta_{white}(3) \\ &= 0.5 \times 0.5 \times 0.51 + 0.3 \times 0.6 \times 0.51 + 0.2 \times 0.3 \times 0.58 = 0.2541\end{aligned}$$

- 第一个观测红球来自2号盒:

$$\begin{aligned}\beta_{red}(2) &= a_{21} b_{white}(1) \beta_{white}(1) + a_{22} b_{white}(2) \beta_{white}(2) + a_{23} b_{white}(3) \beta_{white}(3) \\ &= 0.2 \times 0.5 \times 0.51 + 0.5 \times 0.6 \times 0.51 + 0.3 \times 0.3 \times 0.58 = 0.51 = 0.2562\end{aligned}$$

- 第一个观测红球来自3号盒:

$$\begin{aligned}\beta_{red}(3) &= a_{31} b_{white}(1) \beta_{white}(1) + a_{32} b_{white}(2) \beta_{white}(2) + a_{33} b_{white}(3) \beta_{white}(3) \\ &= 0.3 \times 0.5 \times 0.51 + 0.2 \times 0.6 \times 0.51 + 0.5 \times 0.3 \times 0.58 = 0.2247\end{aligned}$$

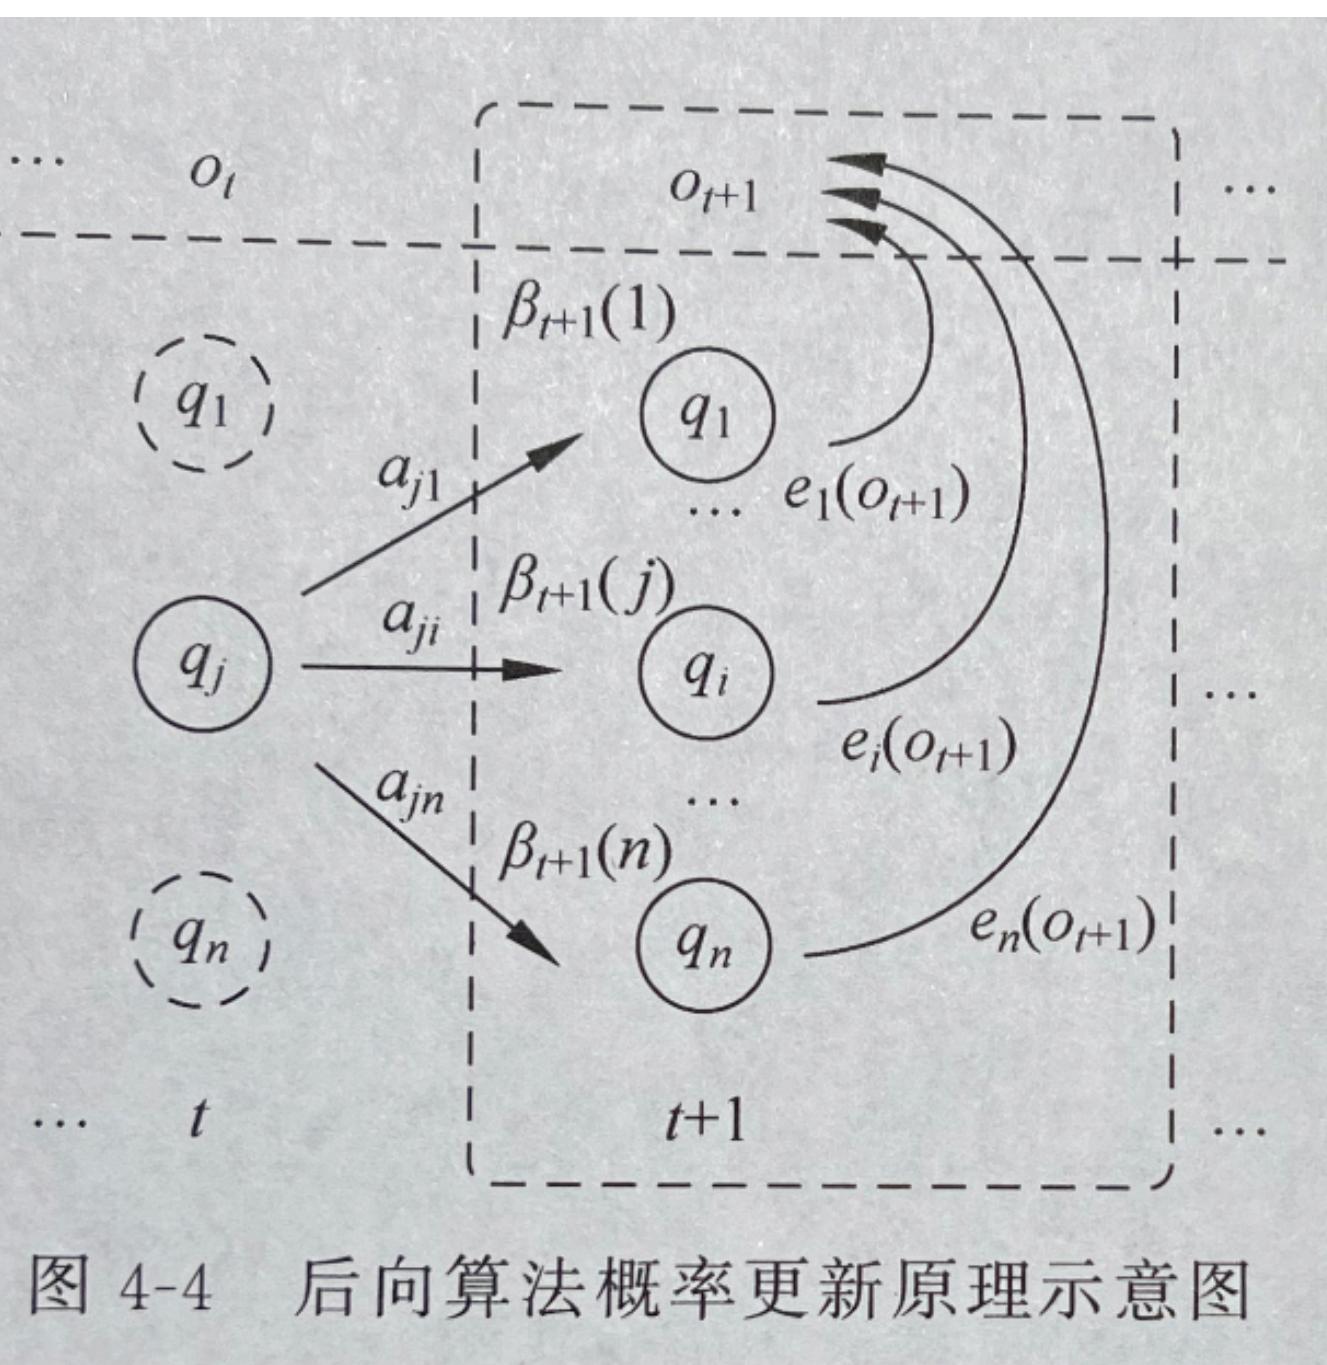


图 4-4 后向算法概率更新原理示意图

4.2.1 HMM模型评估问题

• 后向算法举例

逆向思考第一个观测是怎么来的？如何得知是从几号盒取的？答曰：初始值，所以结合初始值，这一条完整的“路径”才算走完

- 第一个观测红球来自1号盒（结合初始值）

$$\beta'_{red}(1) = \pi_1 b_{red}(1) \beta_{red}(1) = 0.2 \times 0.5 \times 0.2541 = 0.02541$$

- 第一个观测红球来自2号盒（结合初始值）

$$\beta'_{red}(2) = \pi_2 b_{red}(2) \beta_{red}(2) = 0.4 \times 0.4 \times 0.2562 = 0.0410$$

- 第一个观测红球来自3号盒（结合初始值）

$$\beta'_{red}(3) = \pi_3 b_{red}(3) \beta_{red}(3) = 0.4 \times 0.7 \times 0.2247 = 0.06292$$

终止：

$$P(O|\lambda) = \beta'_{red}(1) + \beta'_{red}(2) + \beta'_{red}(3) = 0.12932$$

以上“走法”都可以实现“红，白，红”的观测，我们是从后面状态向前推算的，所以称之为“后向算法”

4.2.1 HMM模型评估问题

- 前向算法和后向算法统一

$$P(O|M) = \sum_{i=1}^n \sum_{j=1}^n \alpha_i(i) a_{ij} e_j(o_{t+1}) \beta_{t+1}(j), t = 1, 2, \dots, L-1$$

4.2.2 HMM隐状态推断问题

已知HMM模型 M 和观测序列 O , 求产生该序列的最有可能的隐状态序列 $x = \arg \max_x p(x, O | M)$

- 维特比 (Viterbi) 算法
 - 一种利用动态规划求解最优路径的算法, 一条路径对应一个状态序列
 - 递推计算在每一时刻各条部分路径的最大概率

$$v_t(j) = \max_{x_1 \cdots x_{t-1}} p(x_1 \cdots x_{t-1}, o_1 \cdots o_t, x_t = q_j | M)$$

$$\cdot v_t(j) = \max_{i=1:n} v_{t-1}(i)a_{ij}e_j(o_t)$$

$$\cdot pa_t(j) = \arg \max_{i=1:n} v_{t-1}(i)a_{ij}e_j(o_i)$$

- 记录最大值对应的隐状态路径

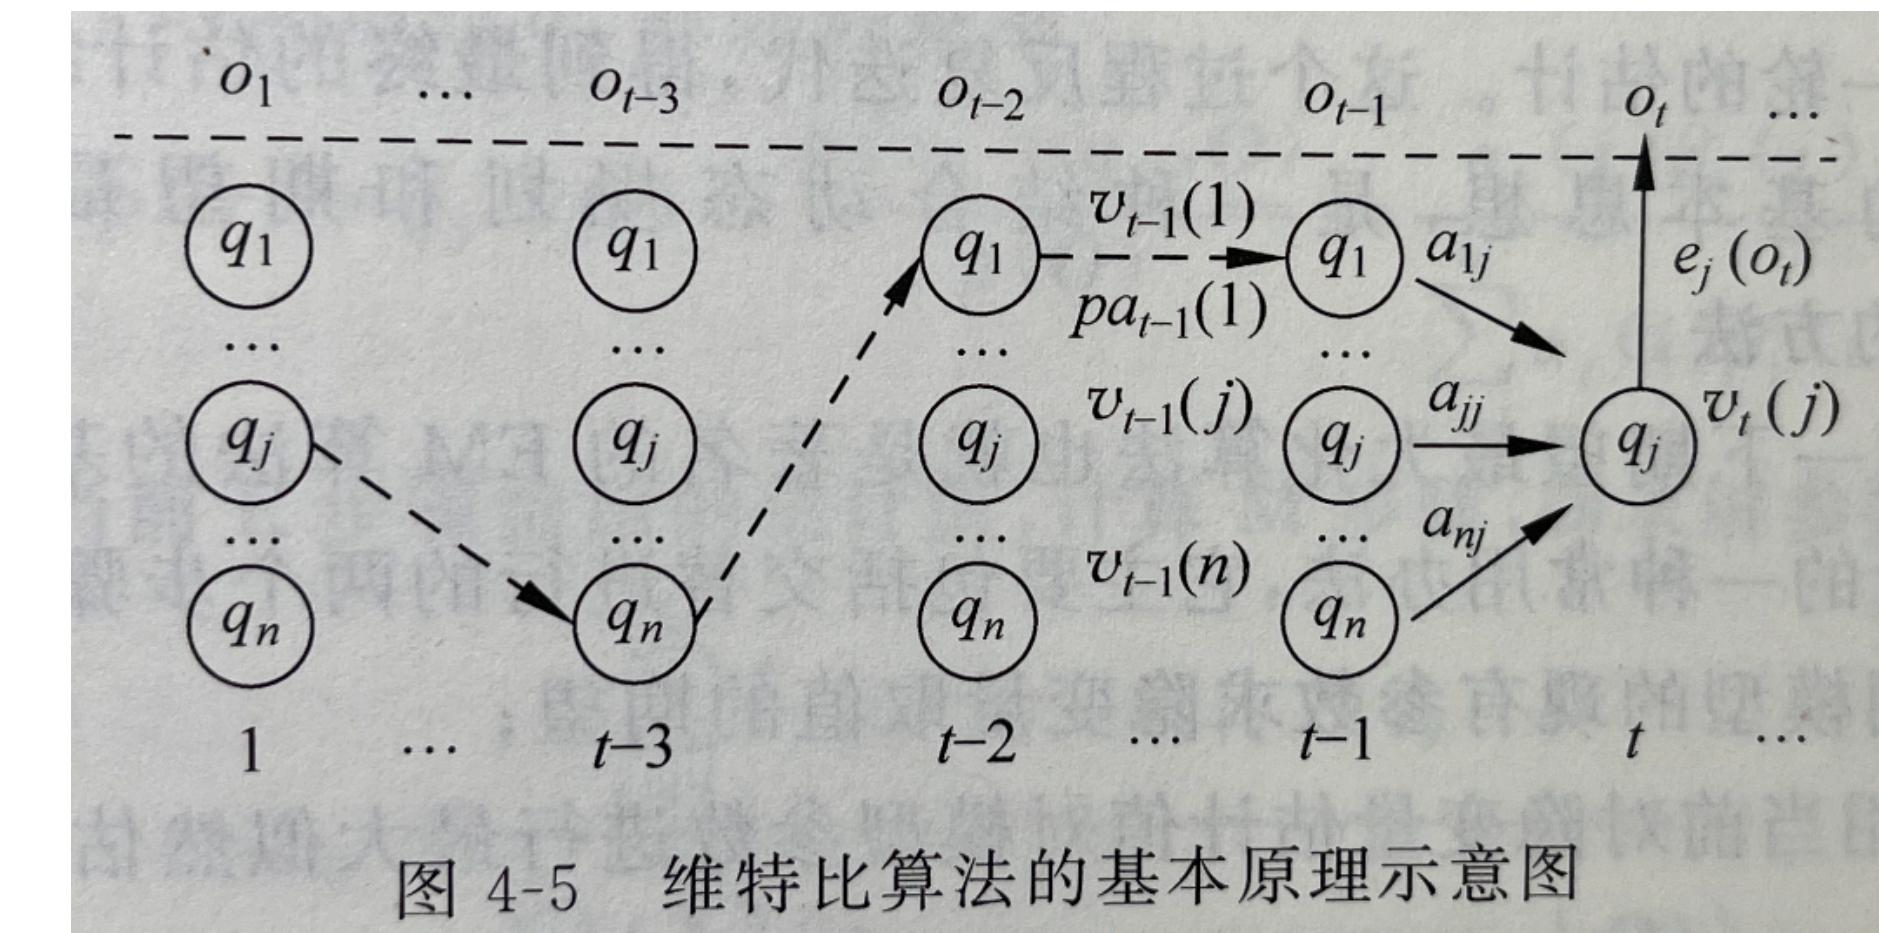
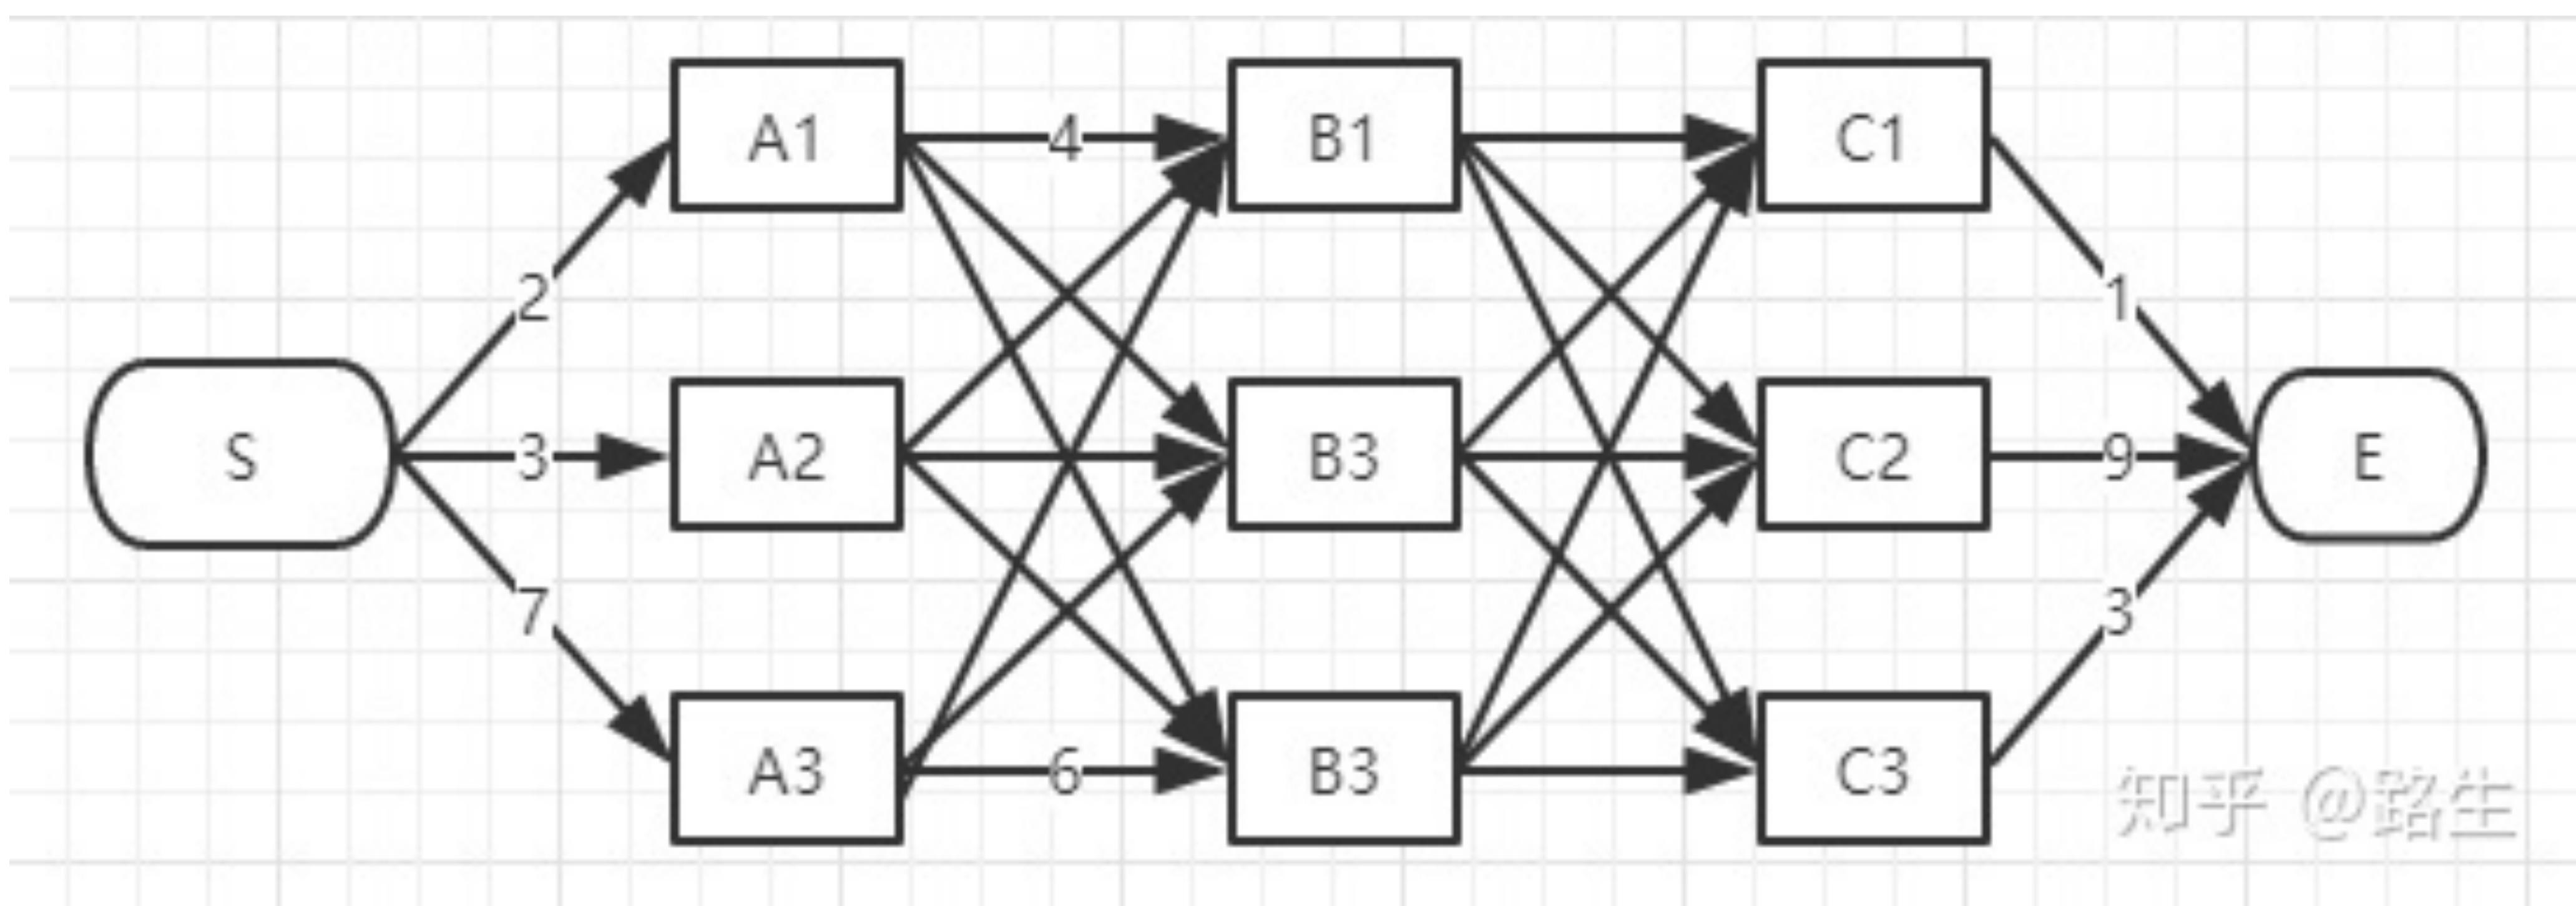


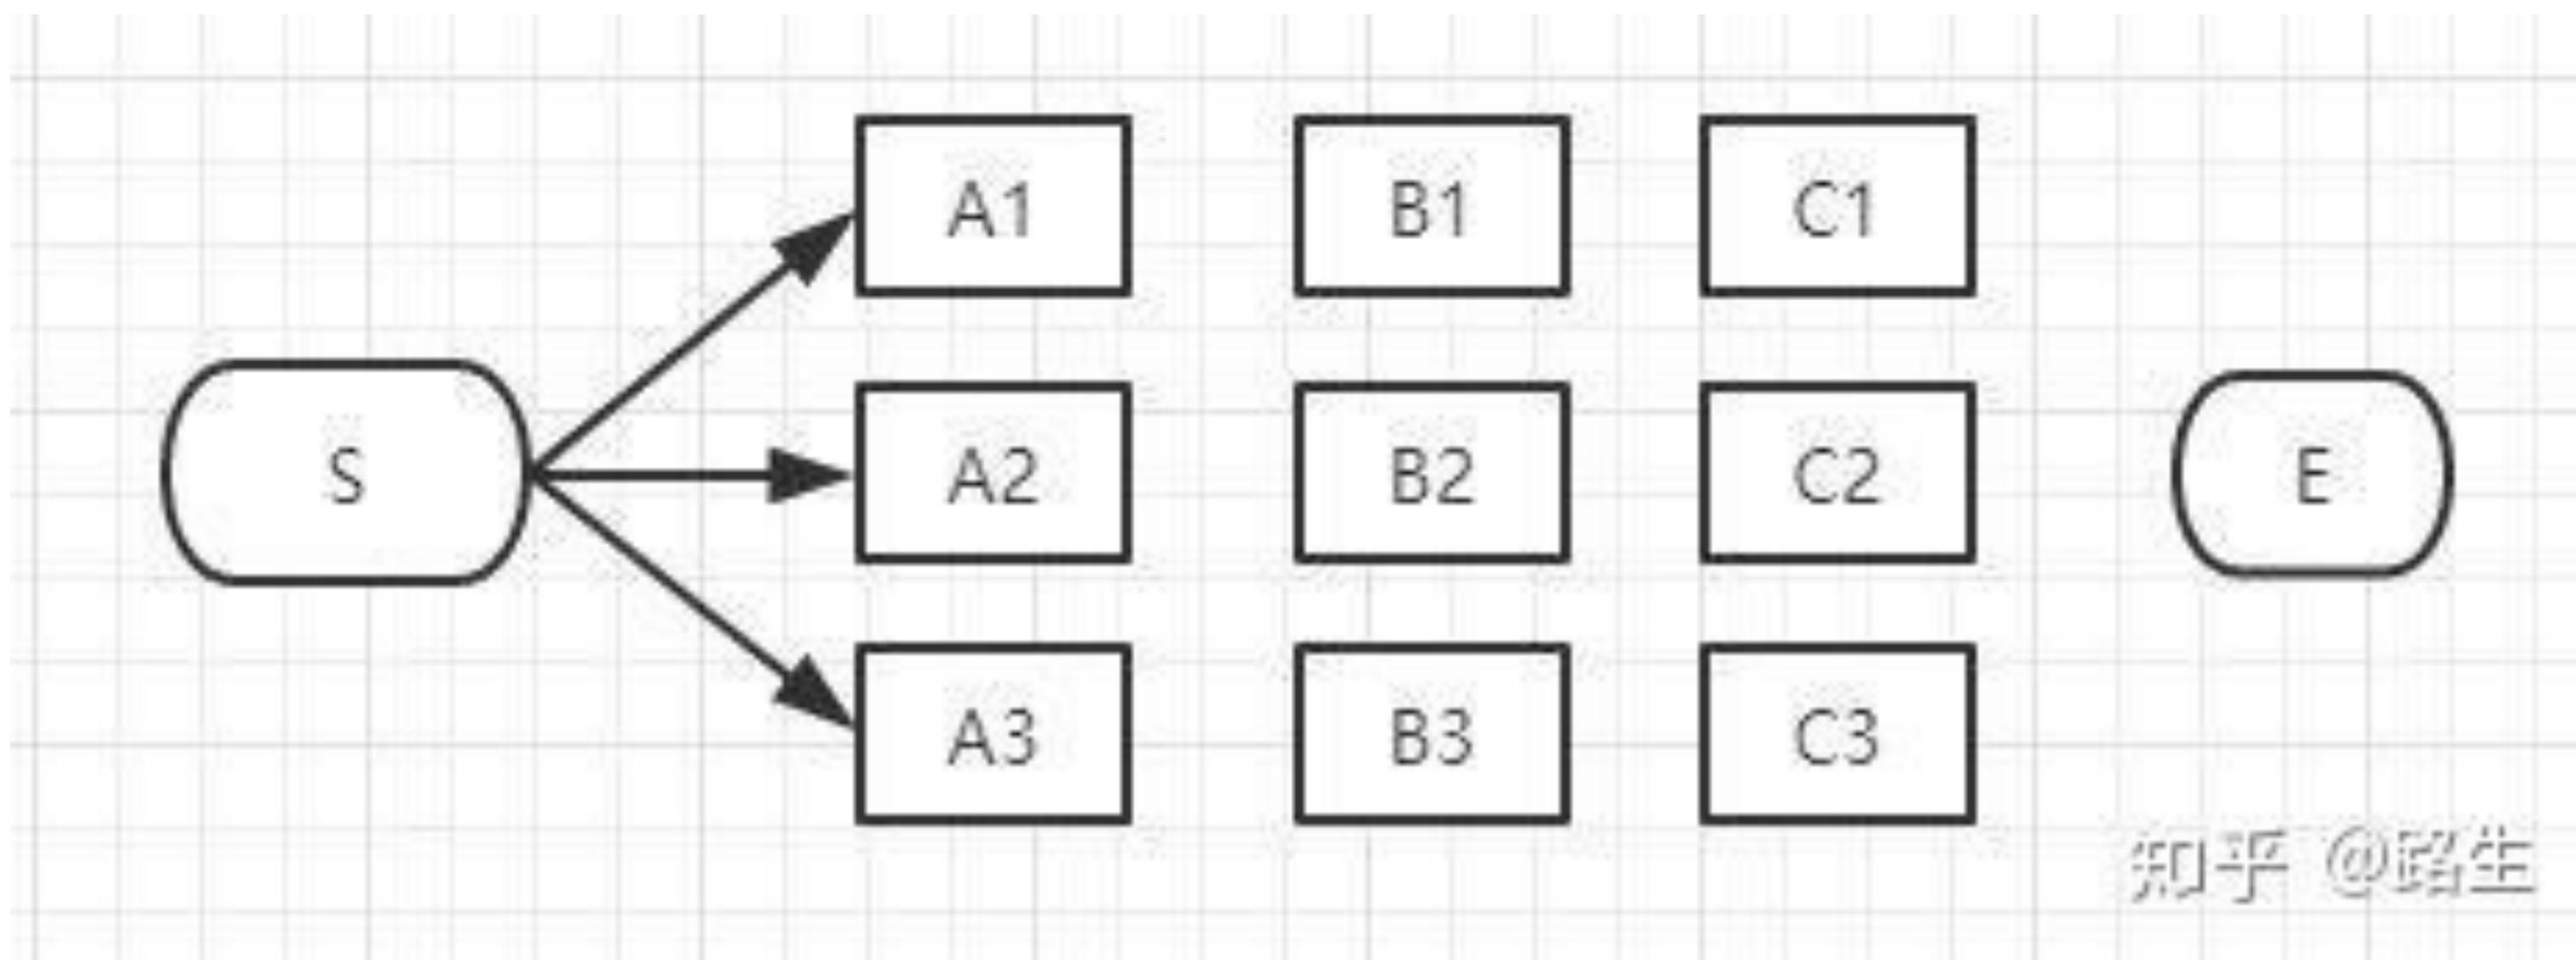
图 4-5 维特比算法的基本原理示意图

4.2.2 HMM隐状态推断问题

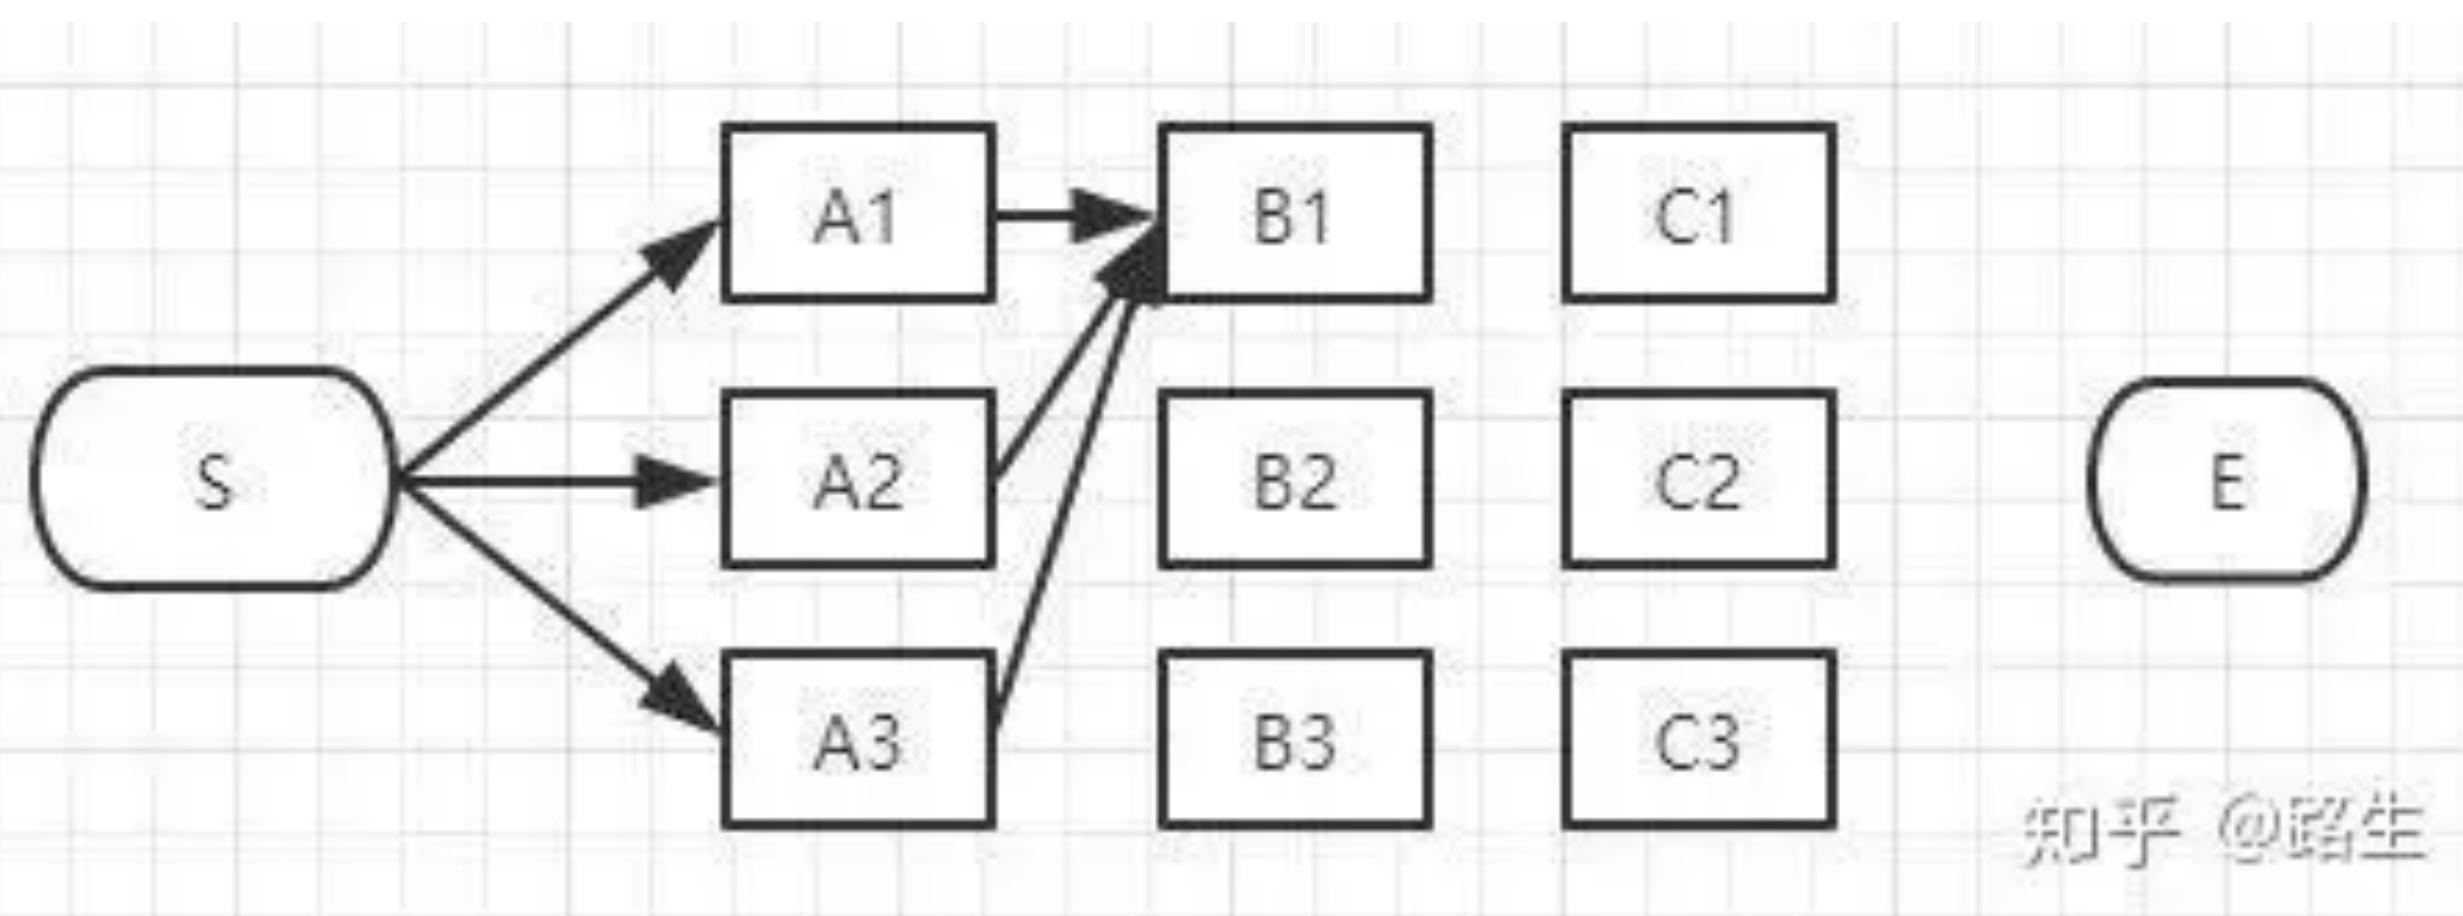


知乎 @路生

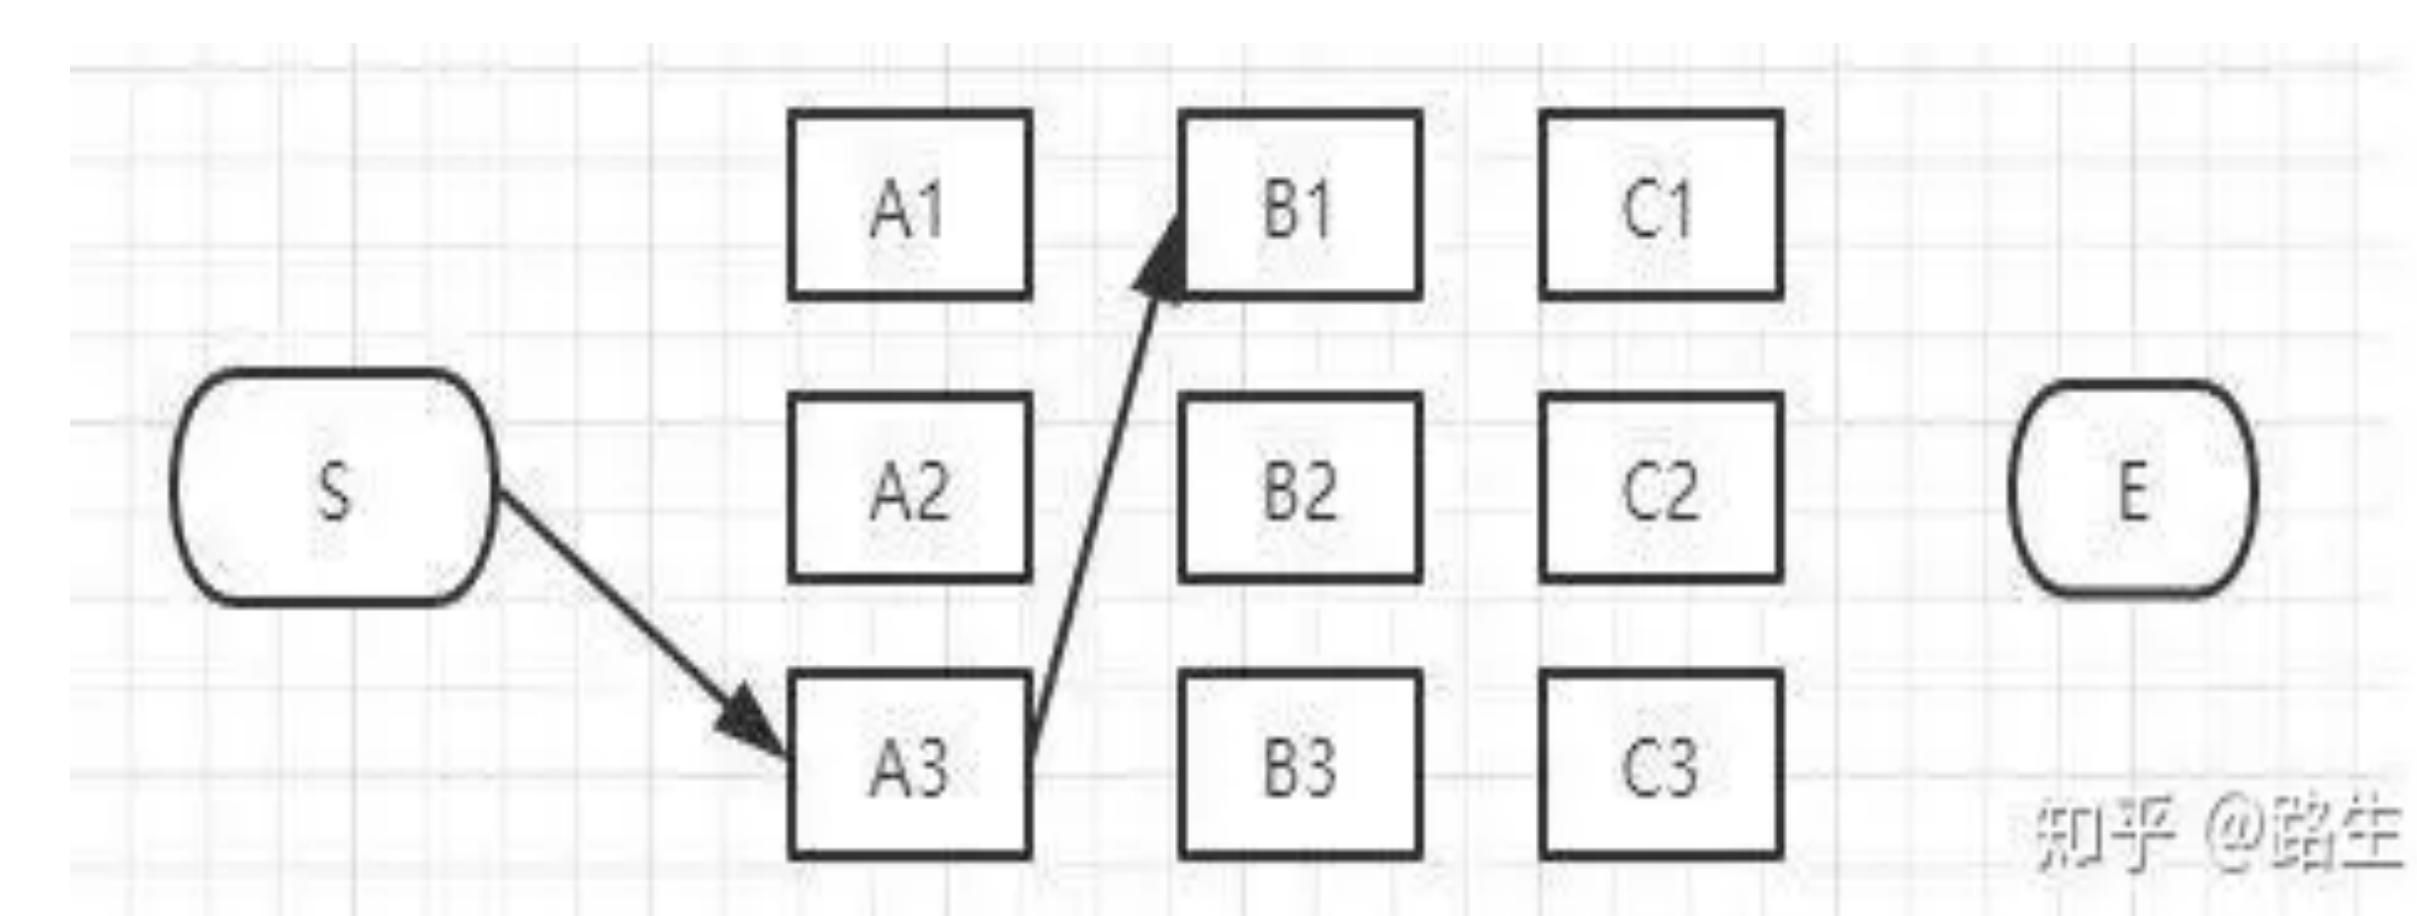
4.2.2 HMM隐状态推断问题



知乎 @路生

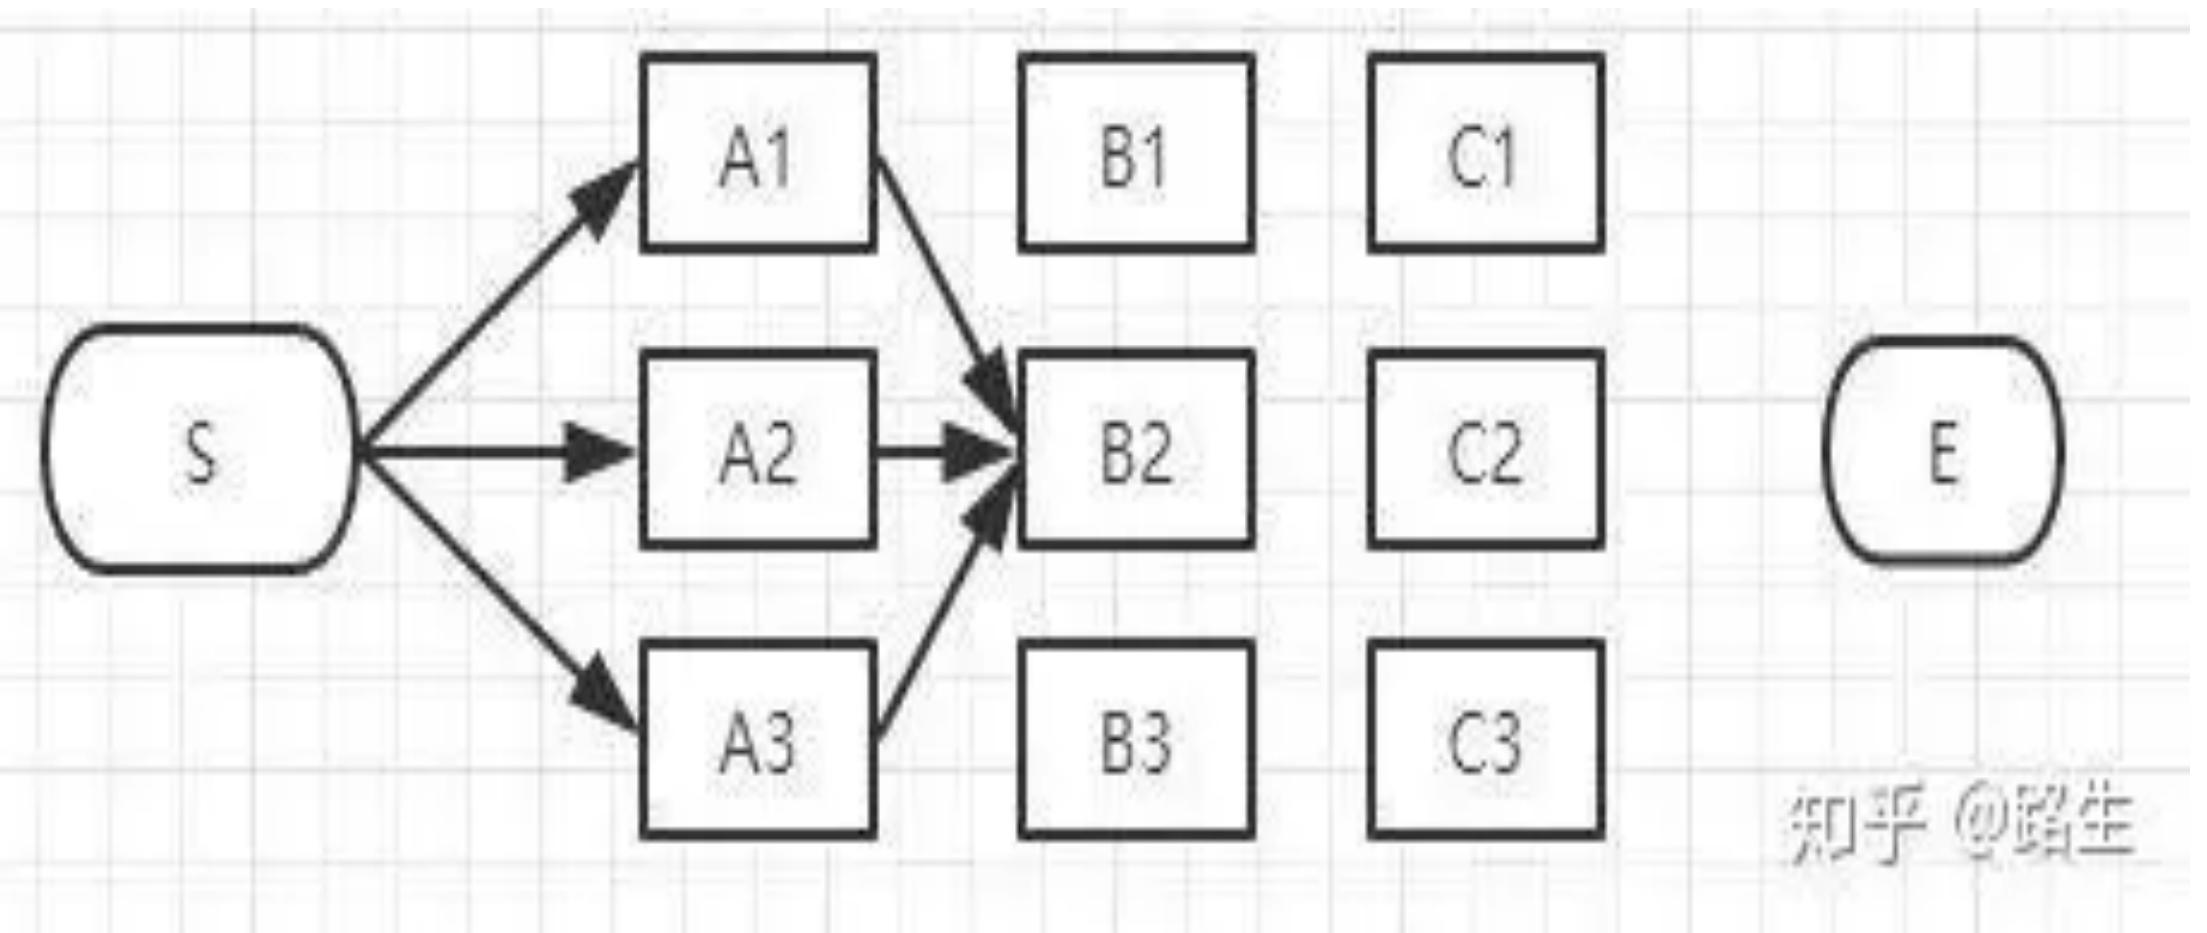


知乎 @路生

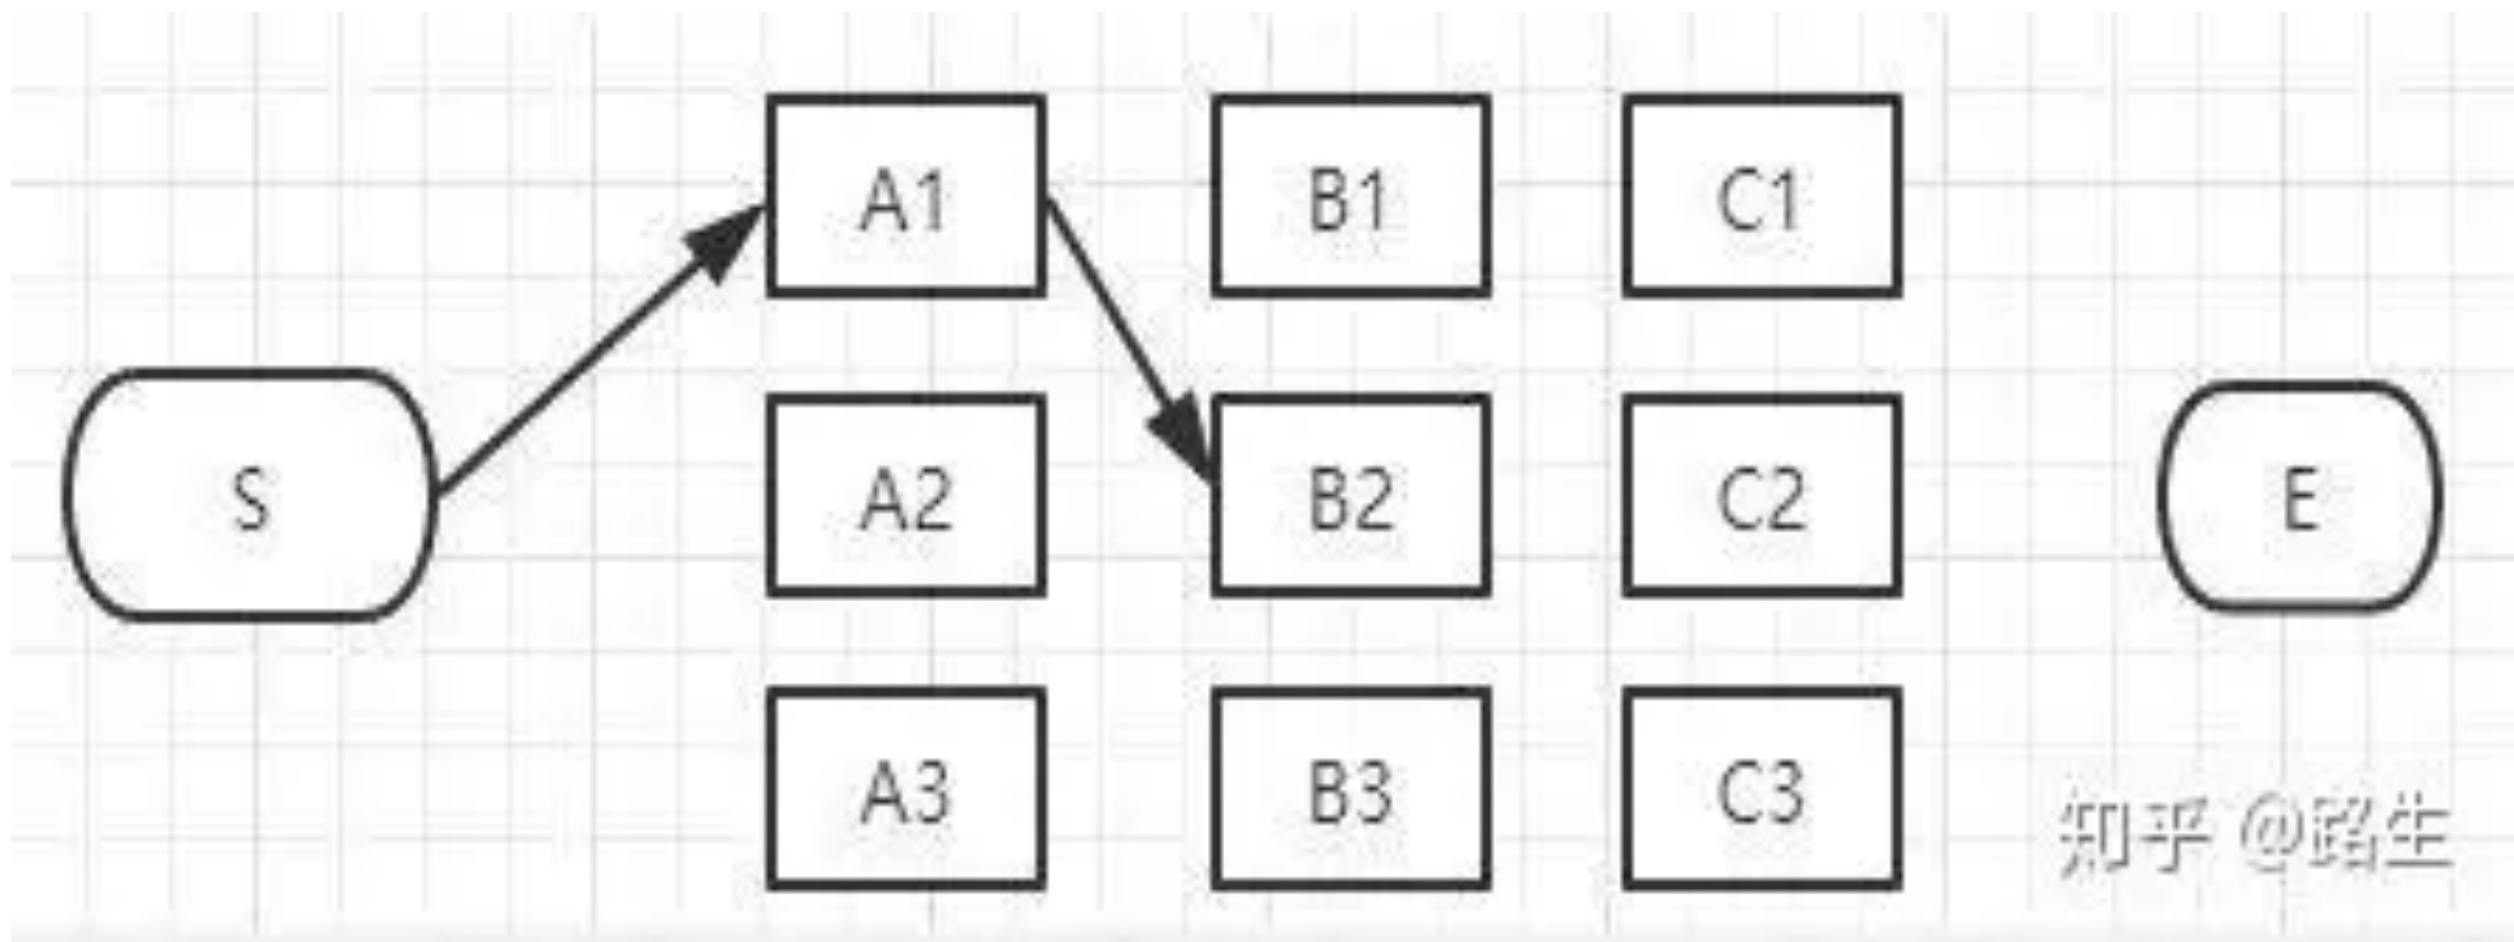


知乎 @路生

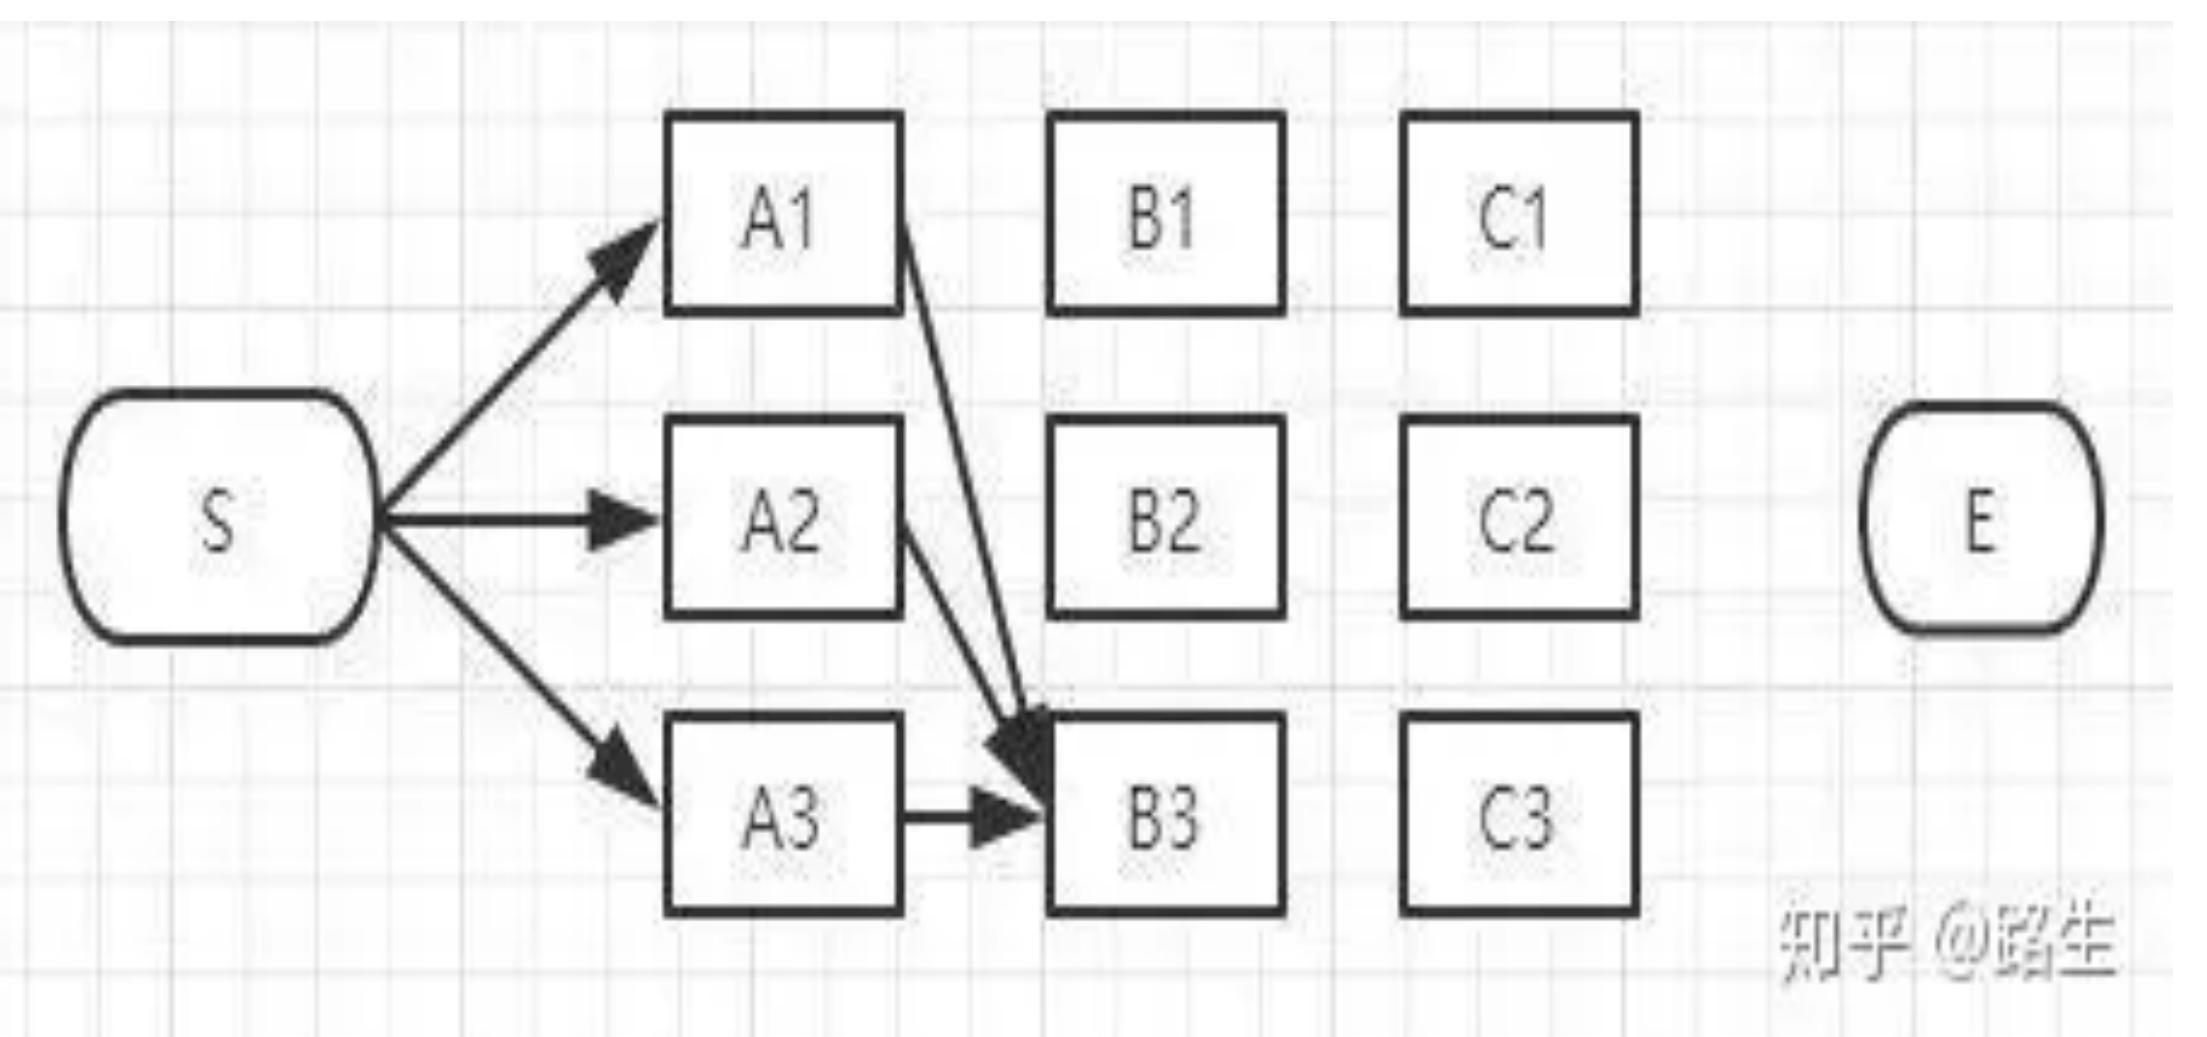
4.2.2 HMM隐状态推断问题



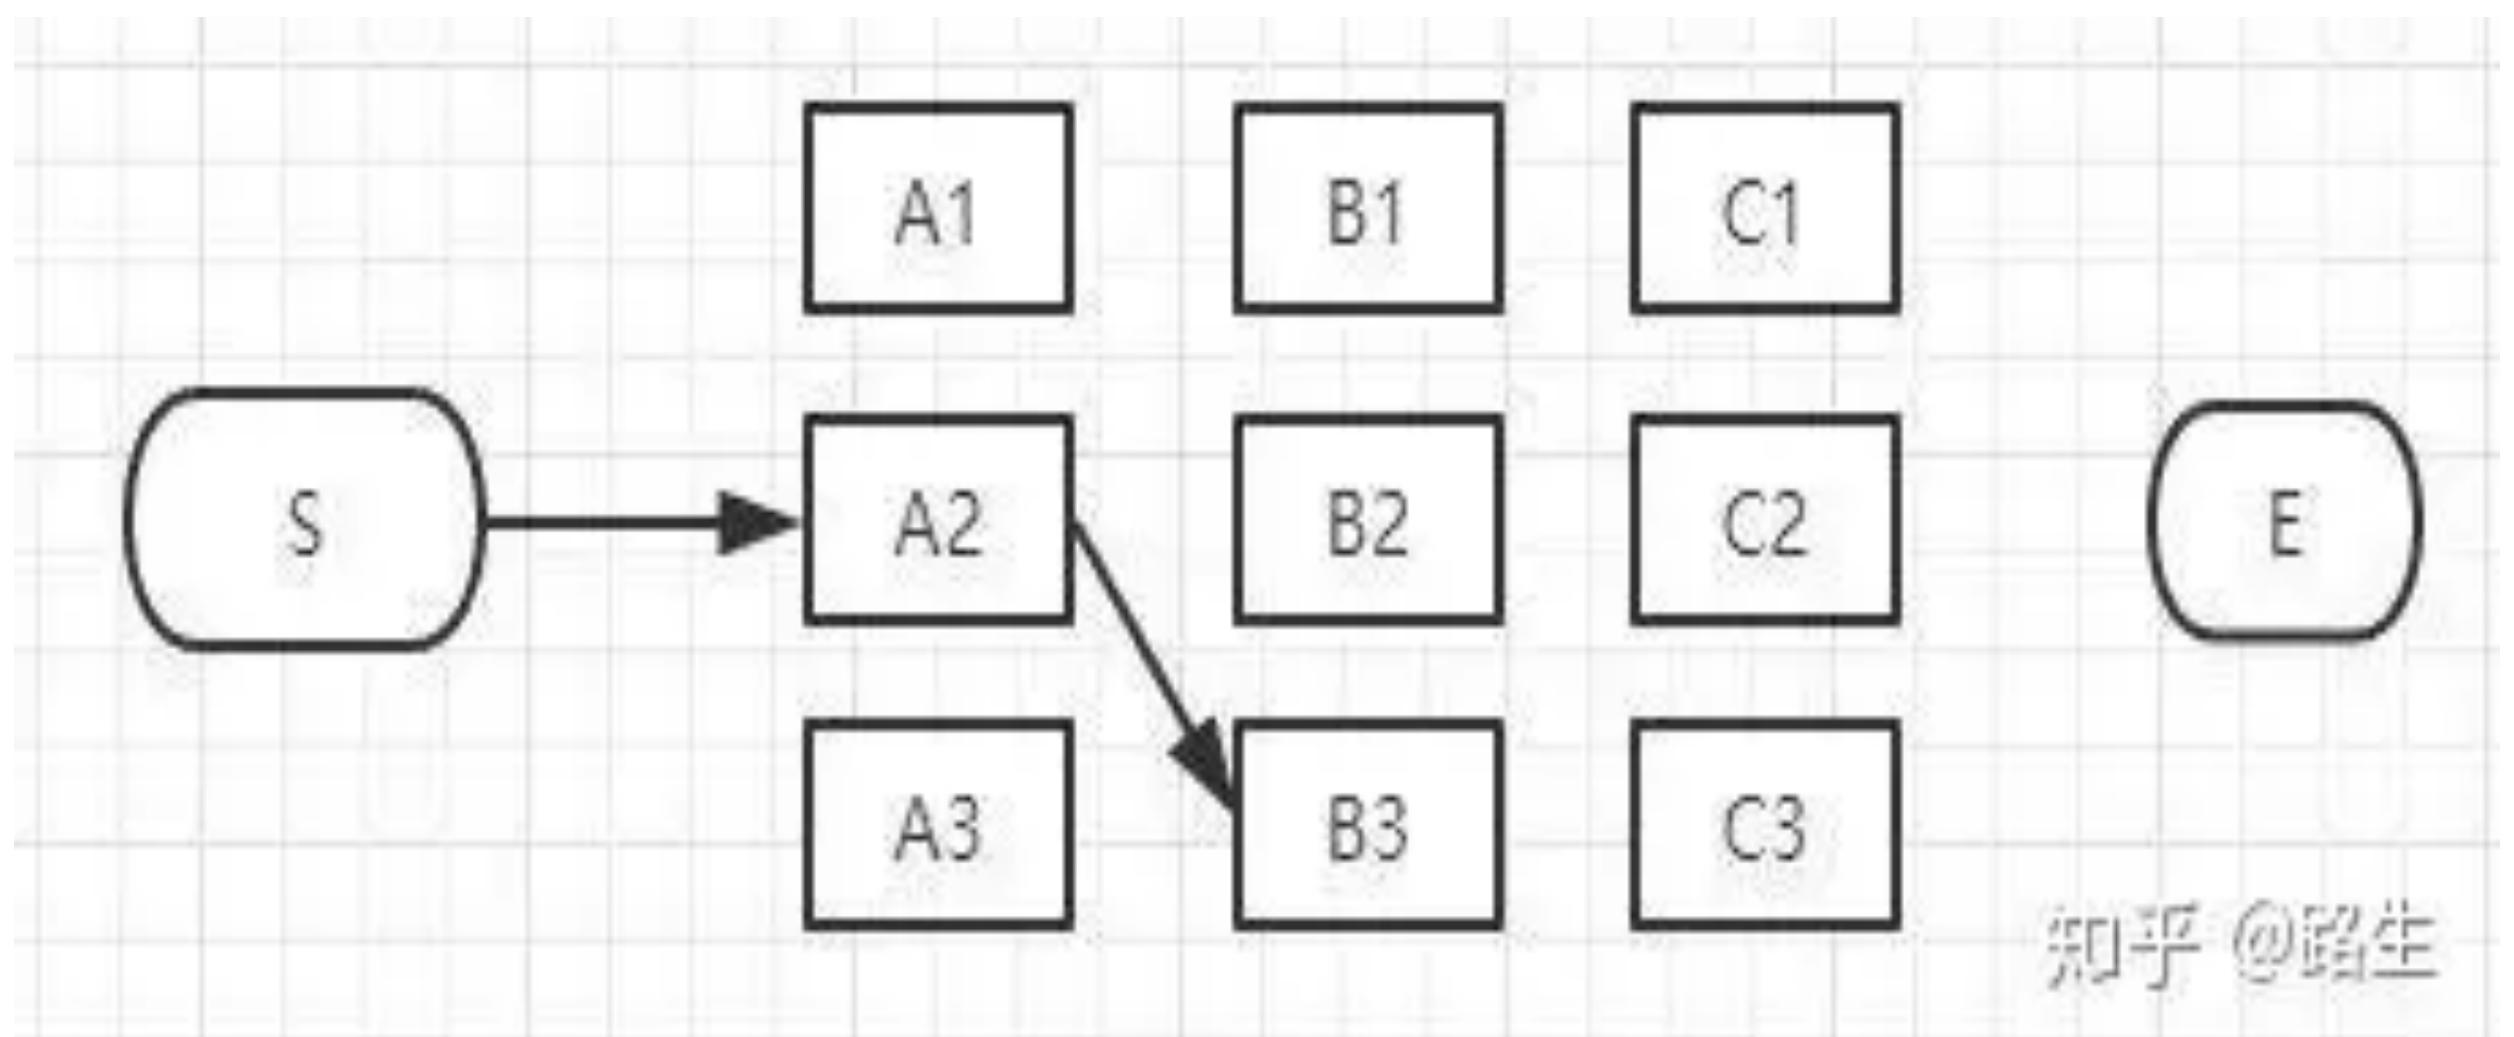
知乎 @路生



知乎 @路生

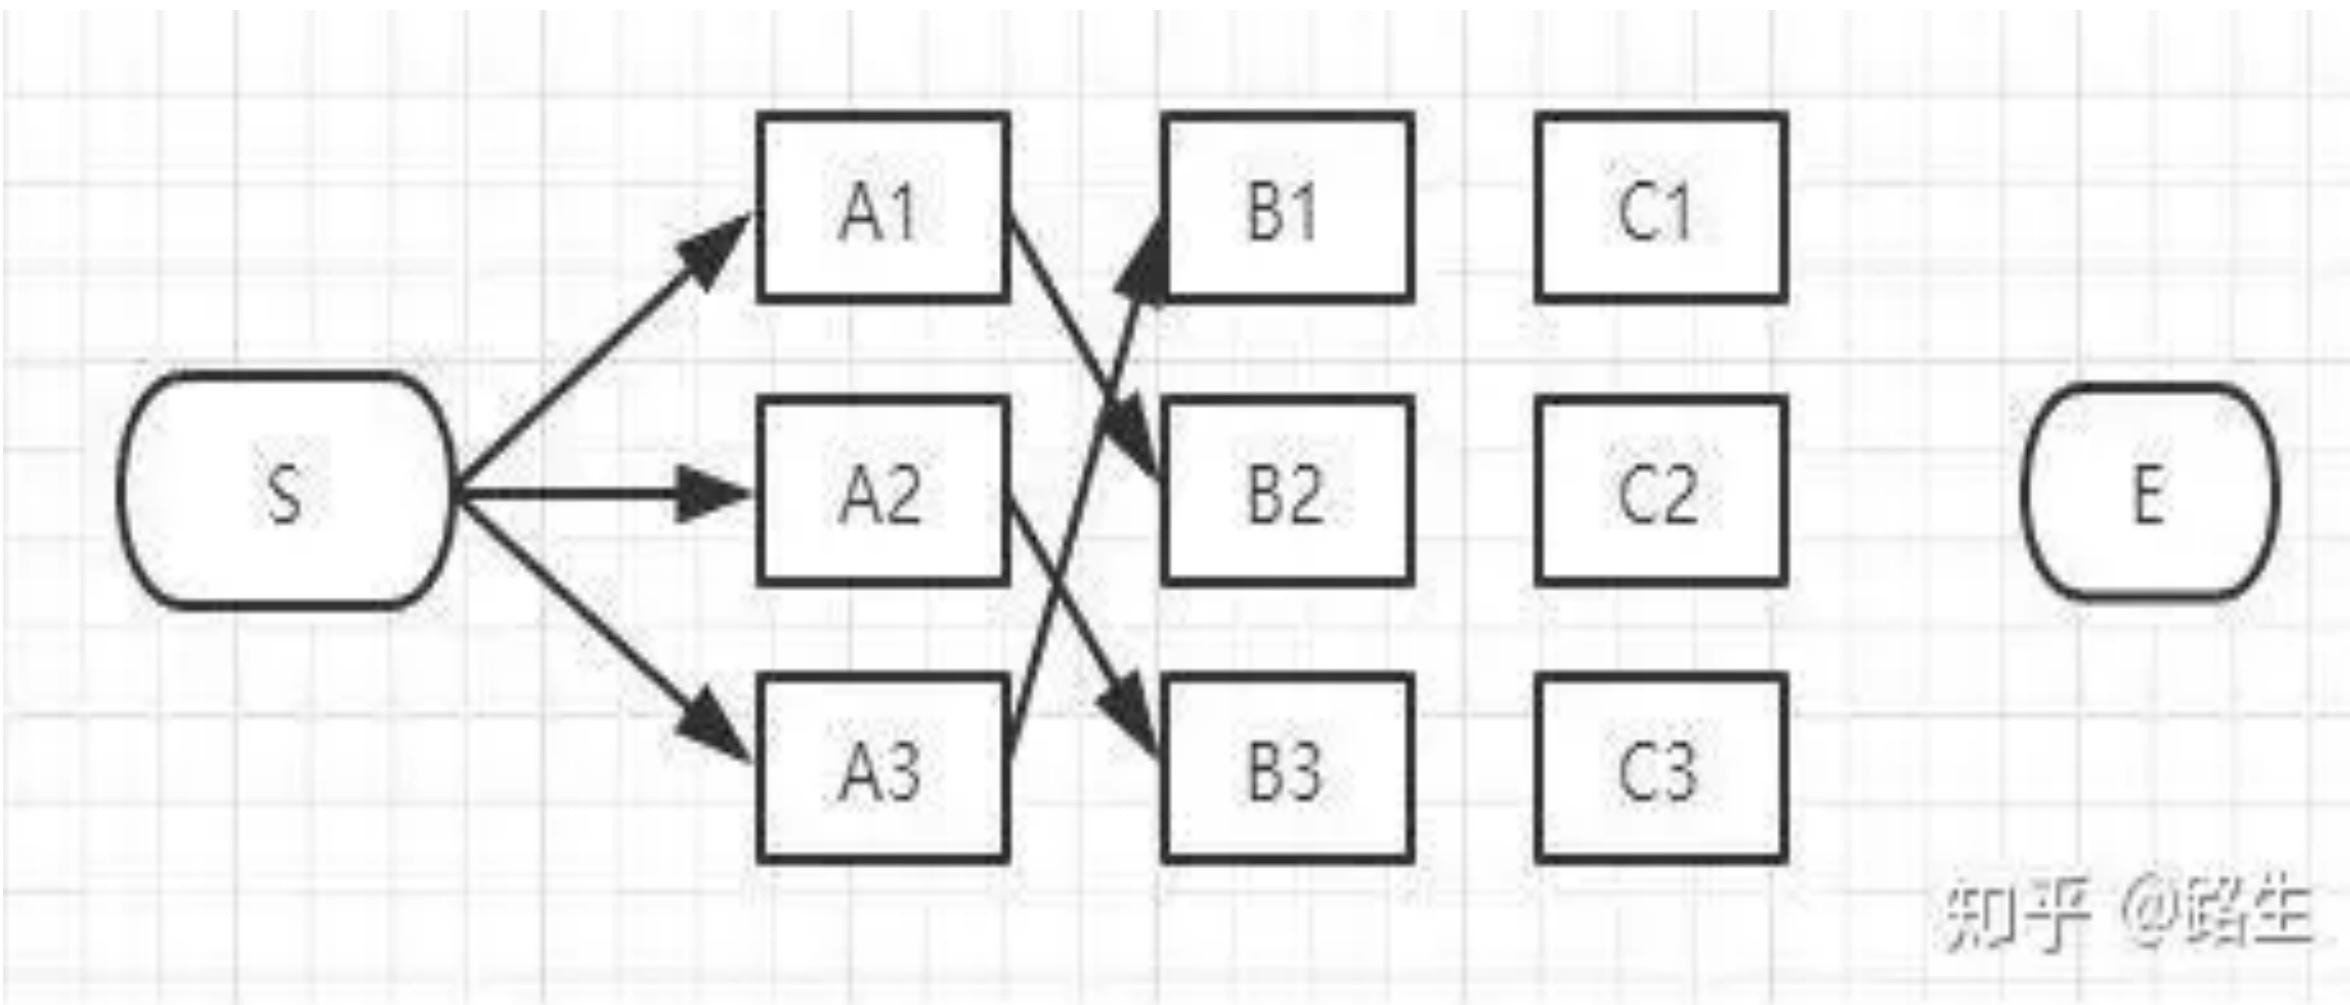


知乎 @路生

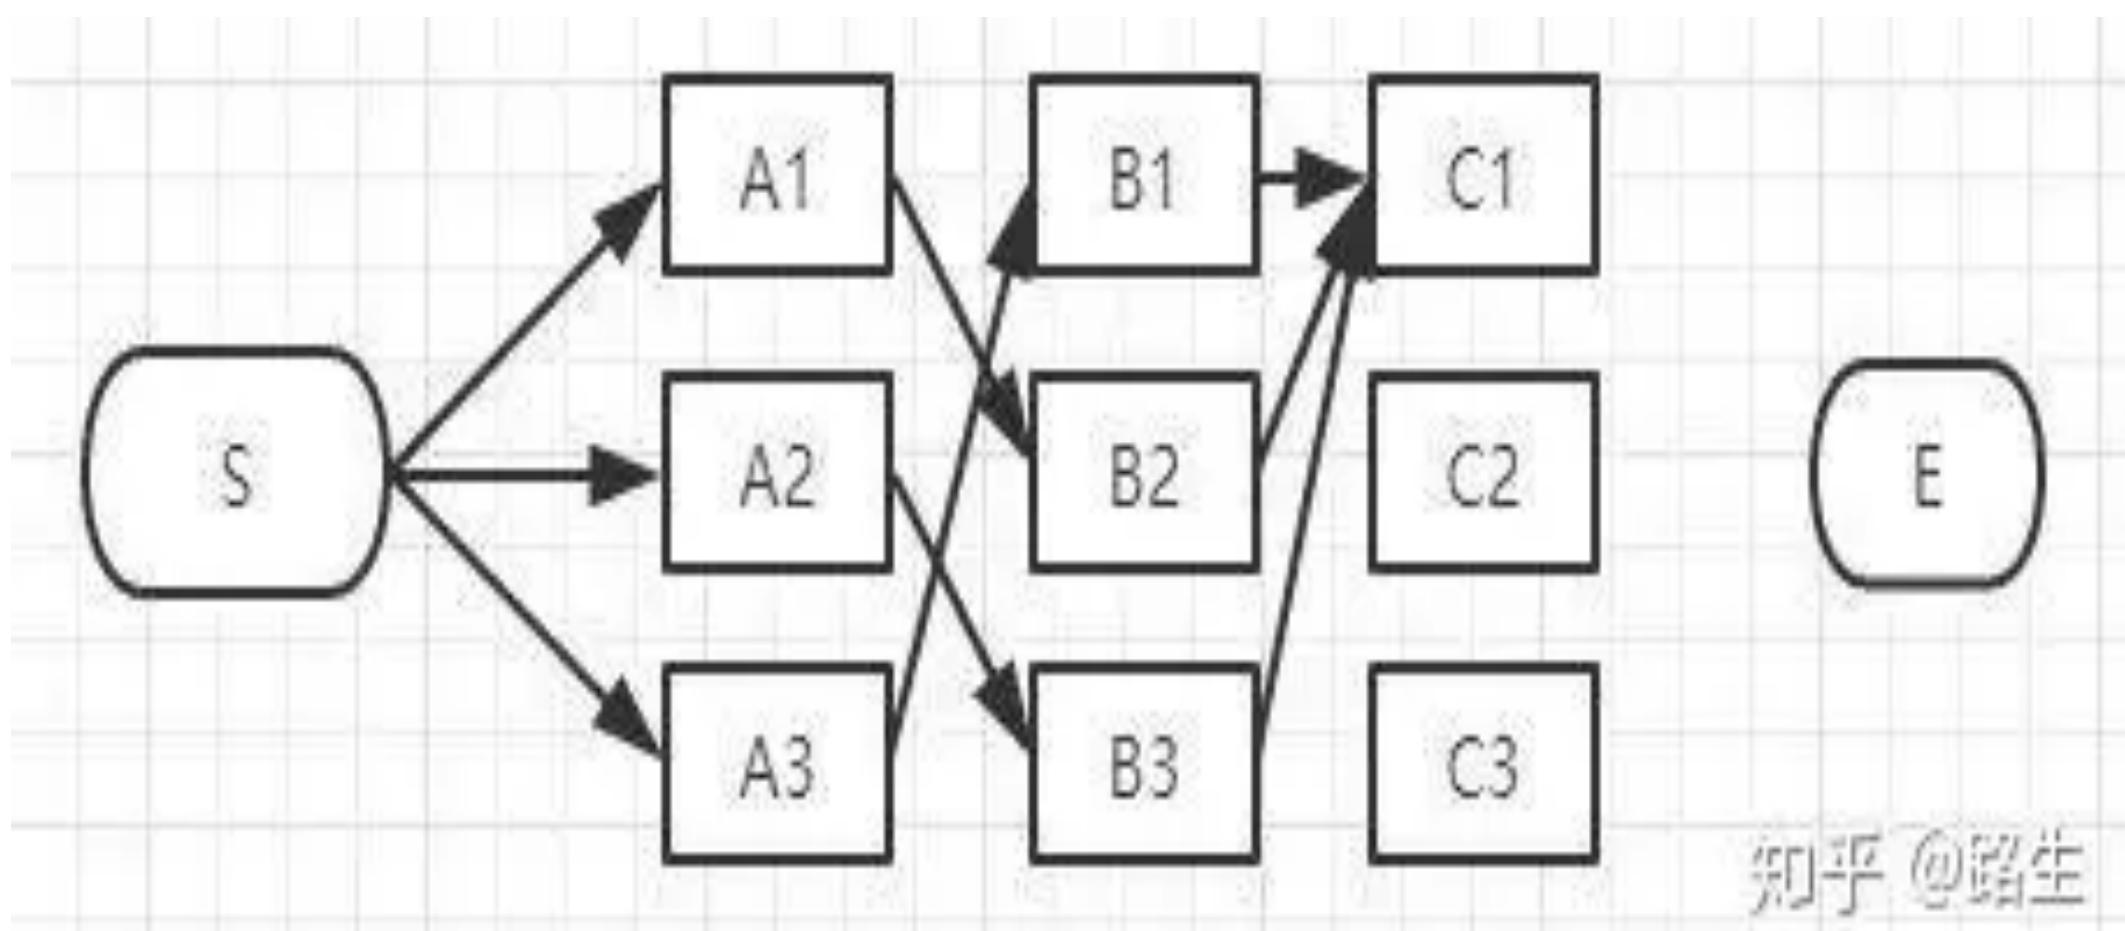


知乎 @路生

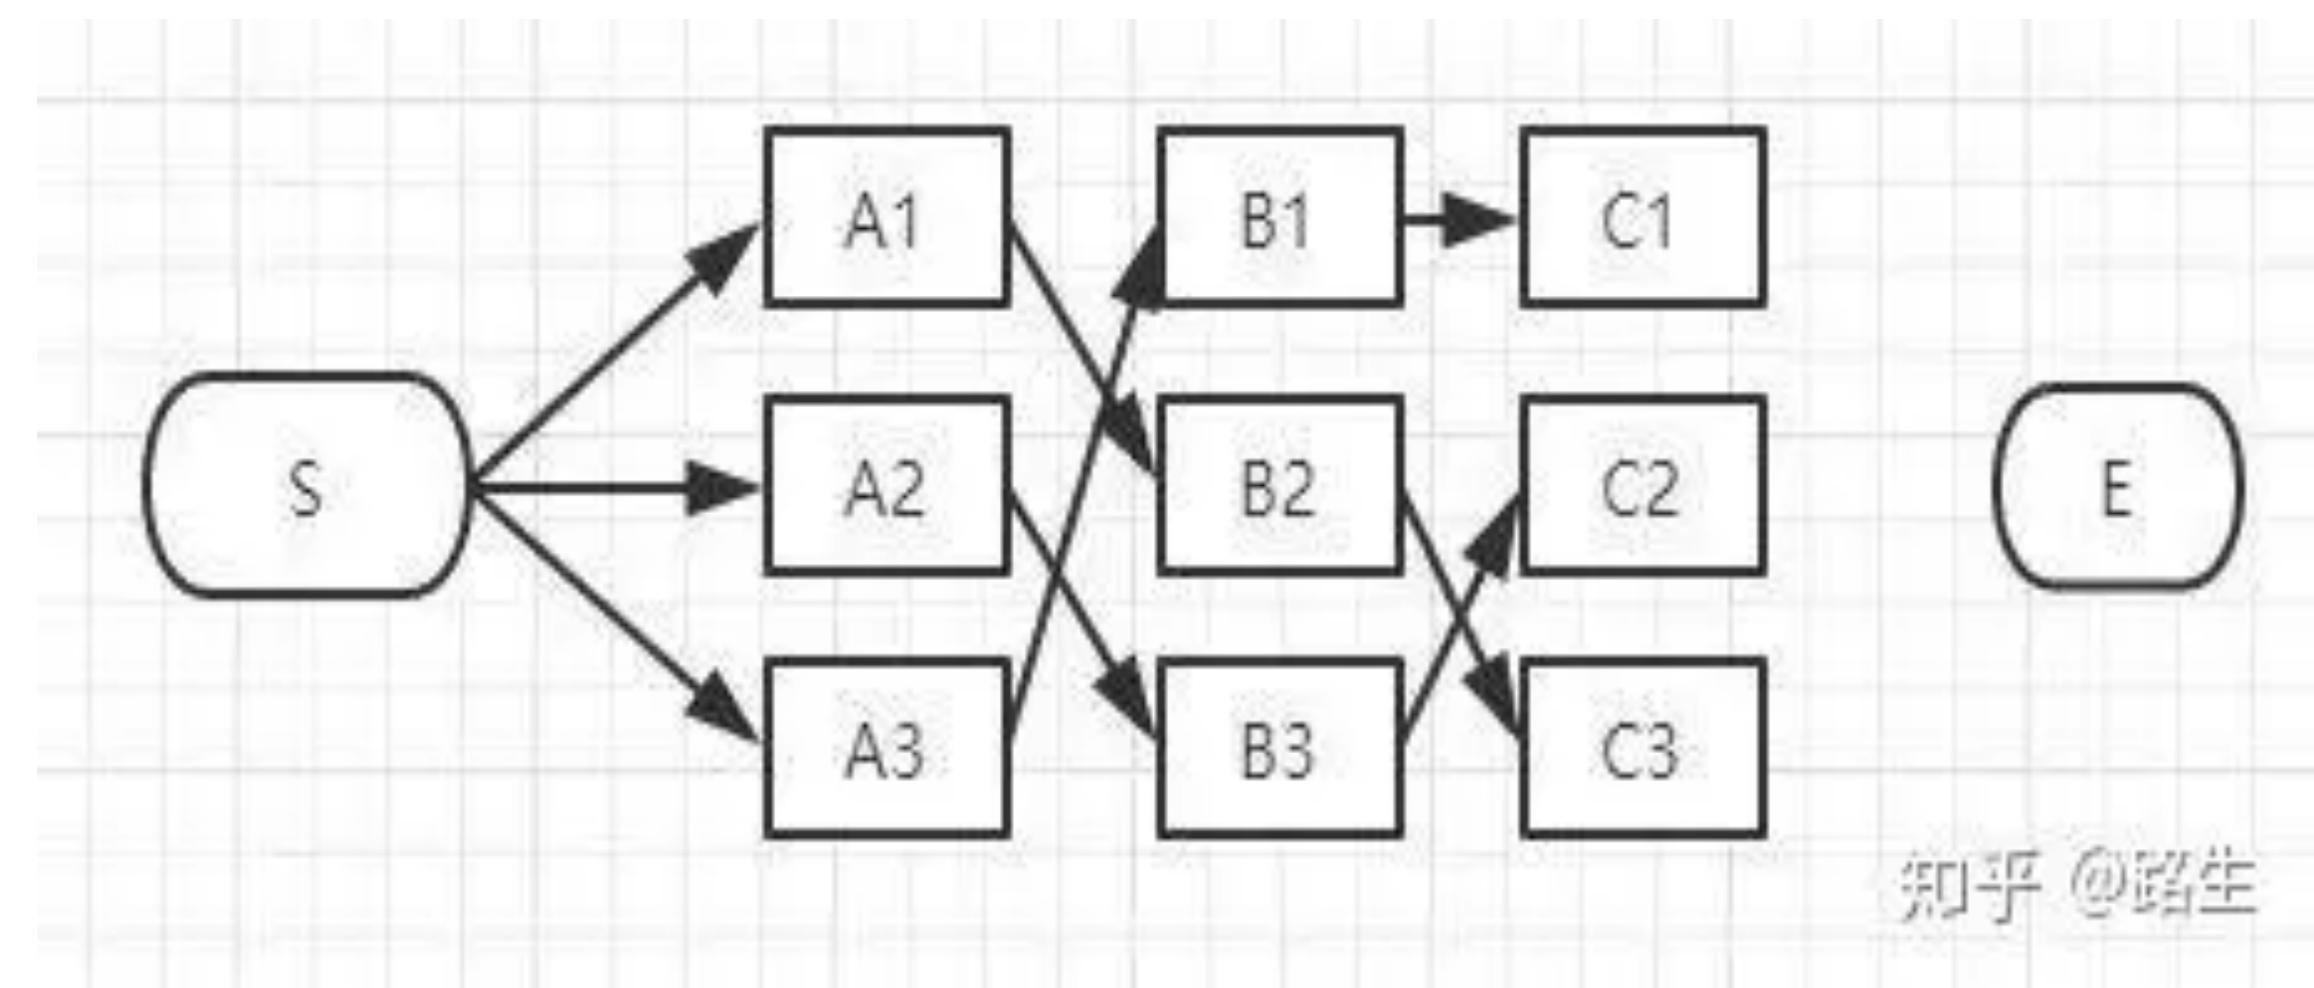
4.2.2 HMM隐状态推断问题



知乎 @路生

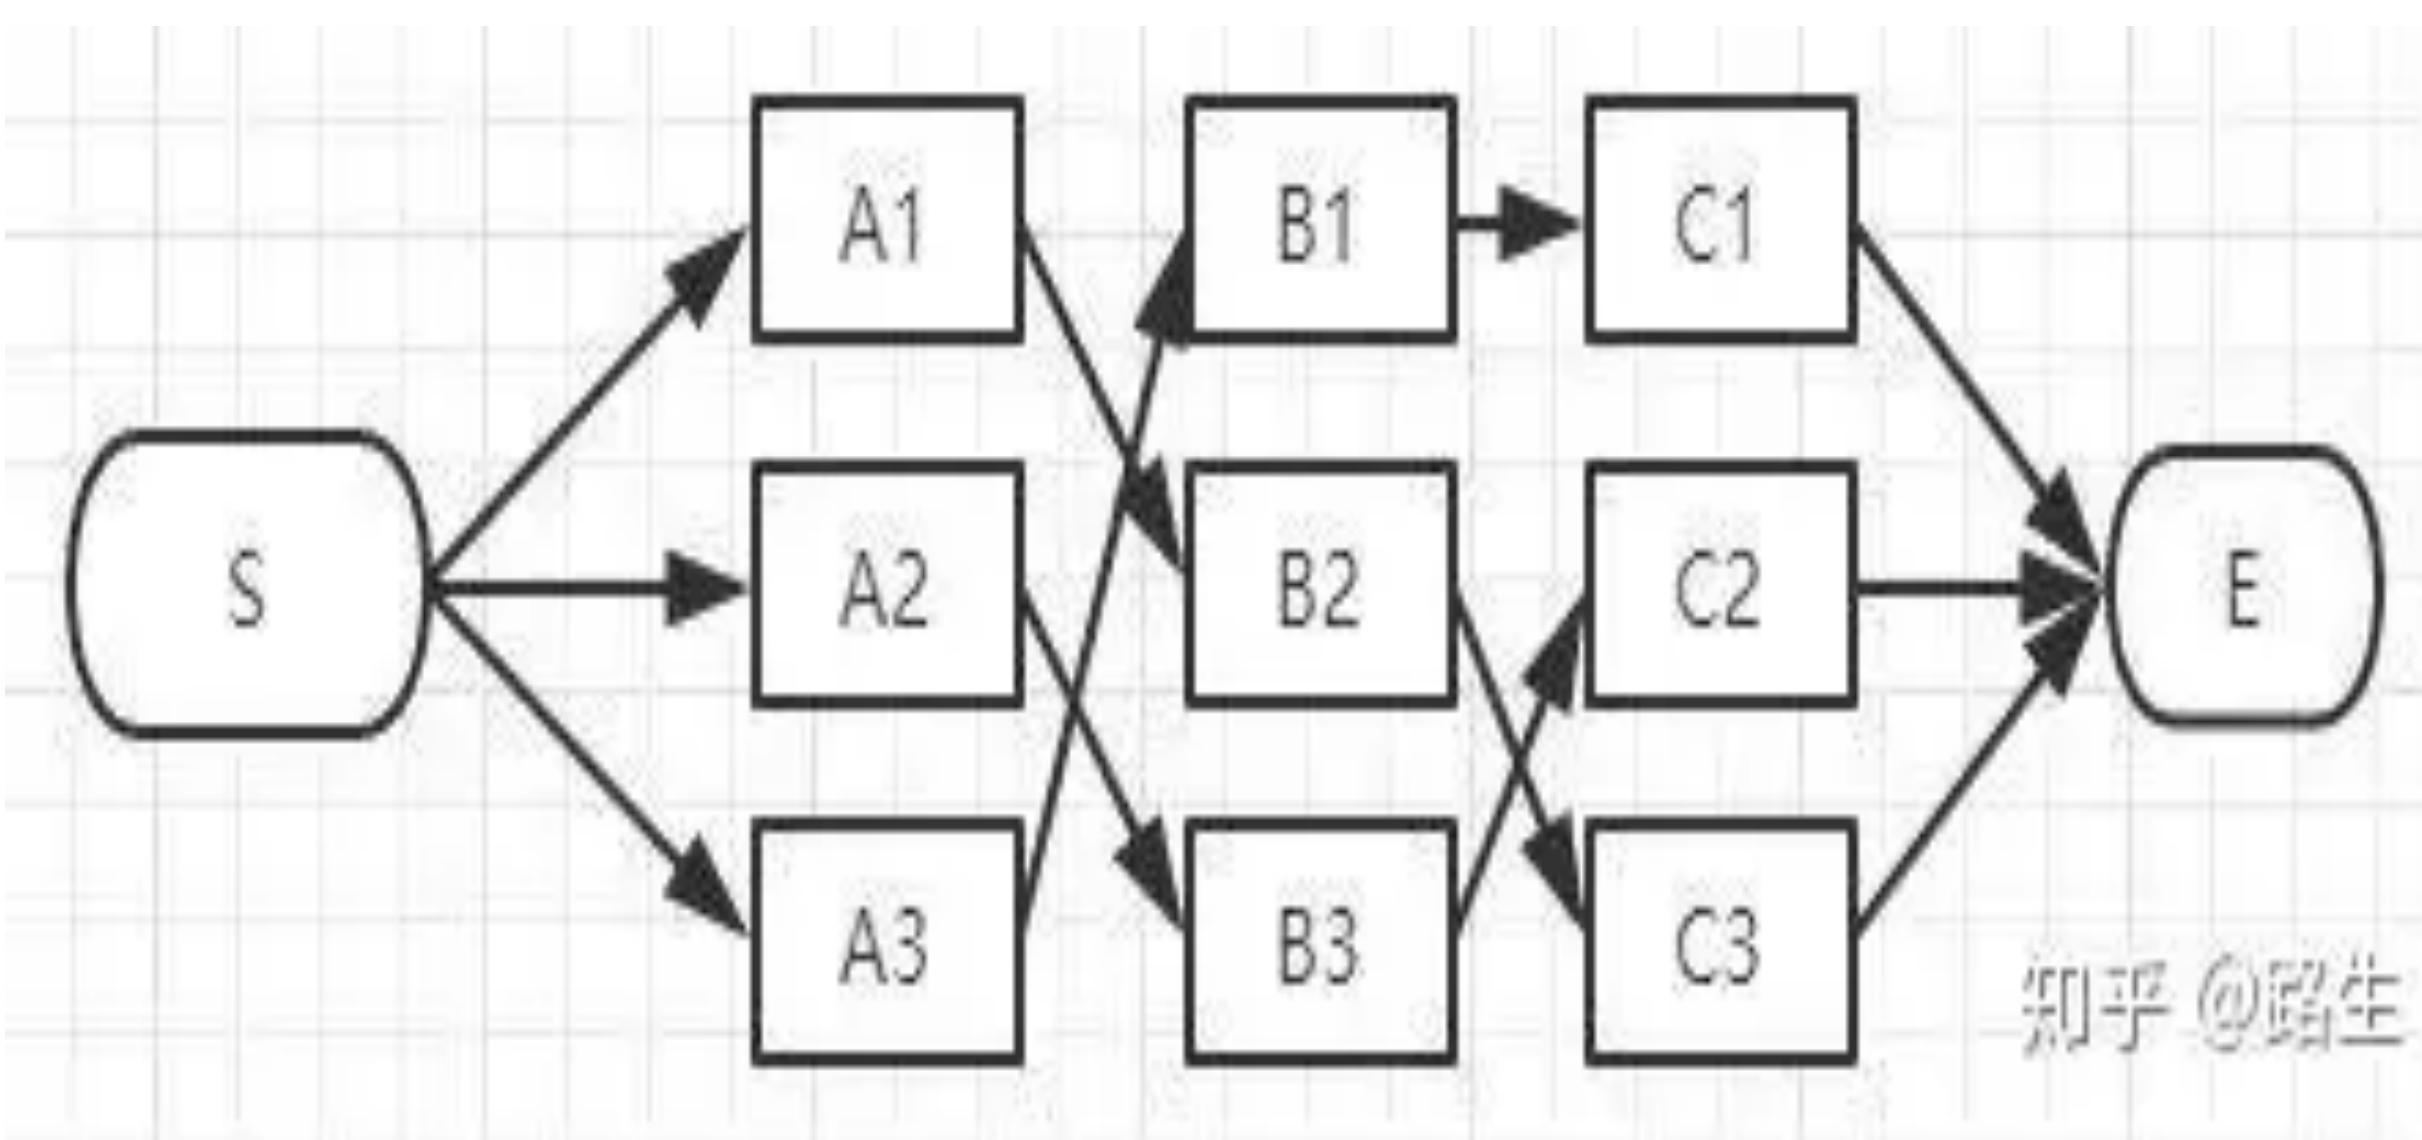


知乎 @路生

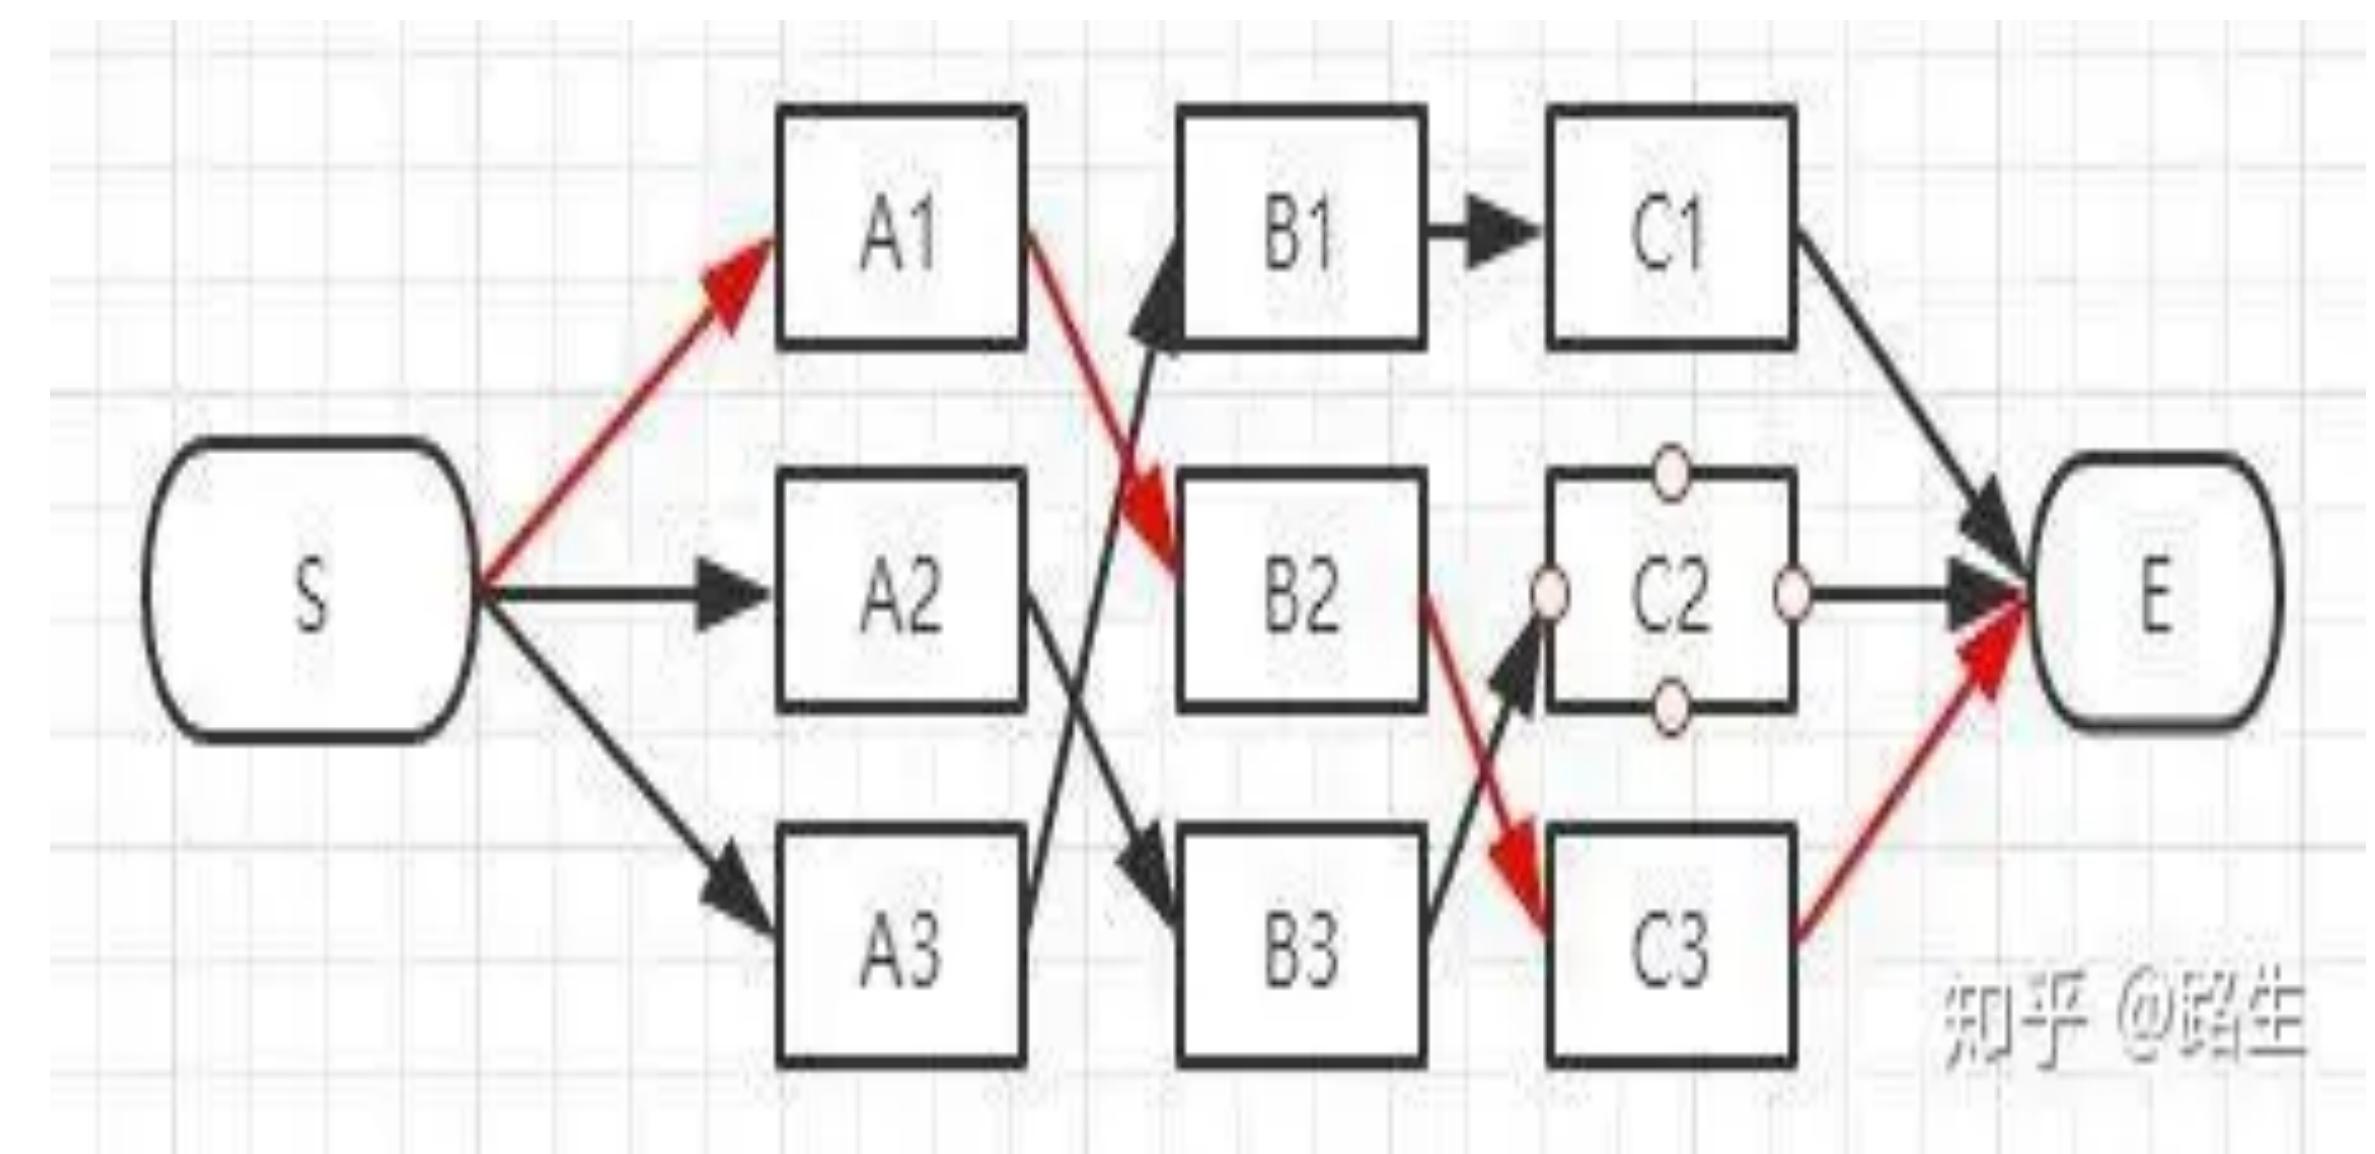


知乎 @路生

4.2.2 HMM隐状态推断问题



知乎 @路生



知乎 @路生

4.2.3 HMM模型学习问题

已知模型结构、观测值取值范围 V 、模型隐状态集 Q ，根据观测序列 O 的样本，学习模型参数 A 、 E 、 π 。

- 隐状态序列 x 已知：最大似然估计法

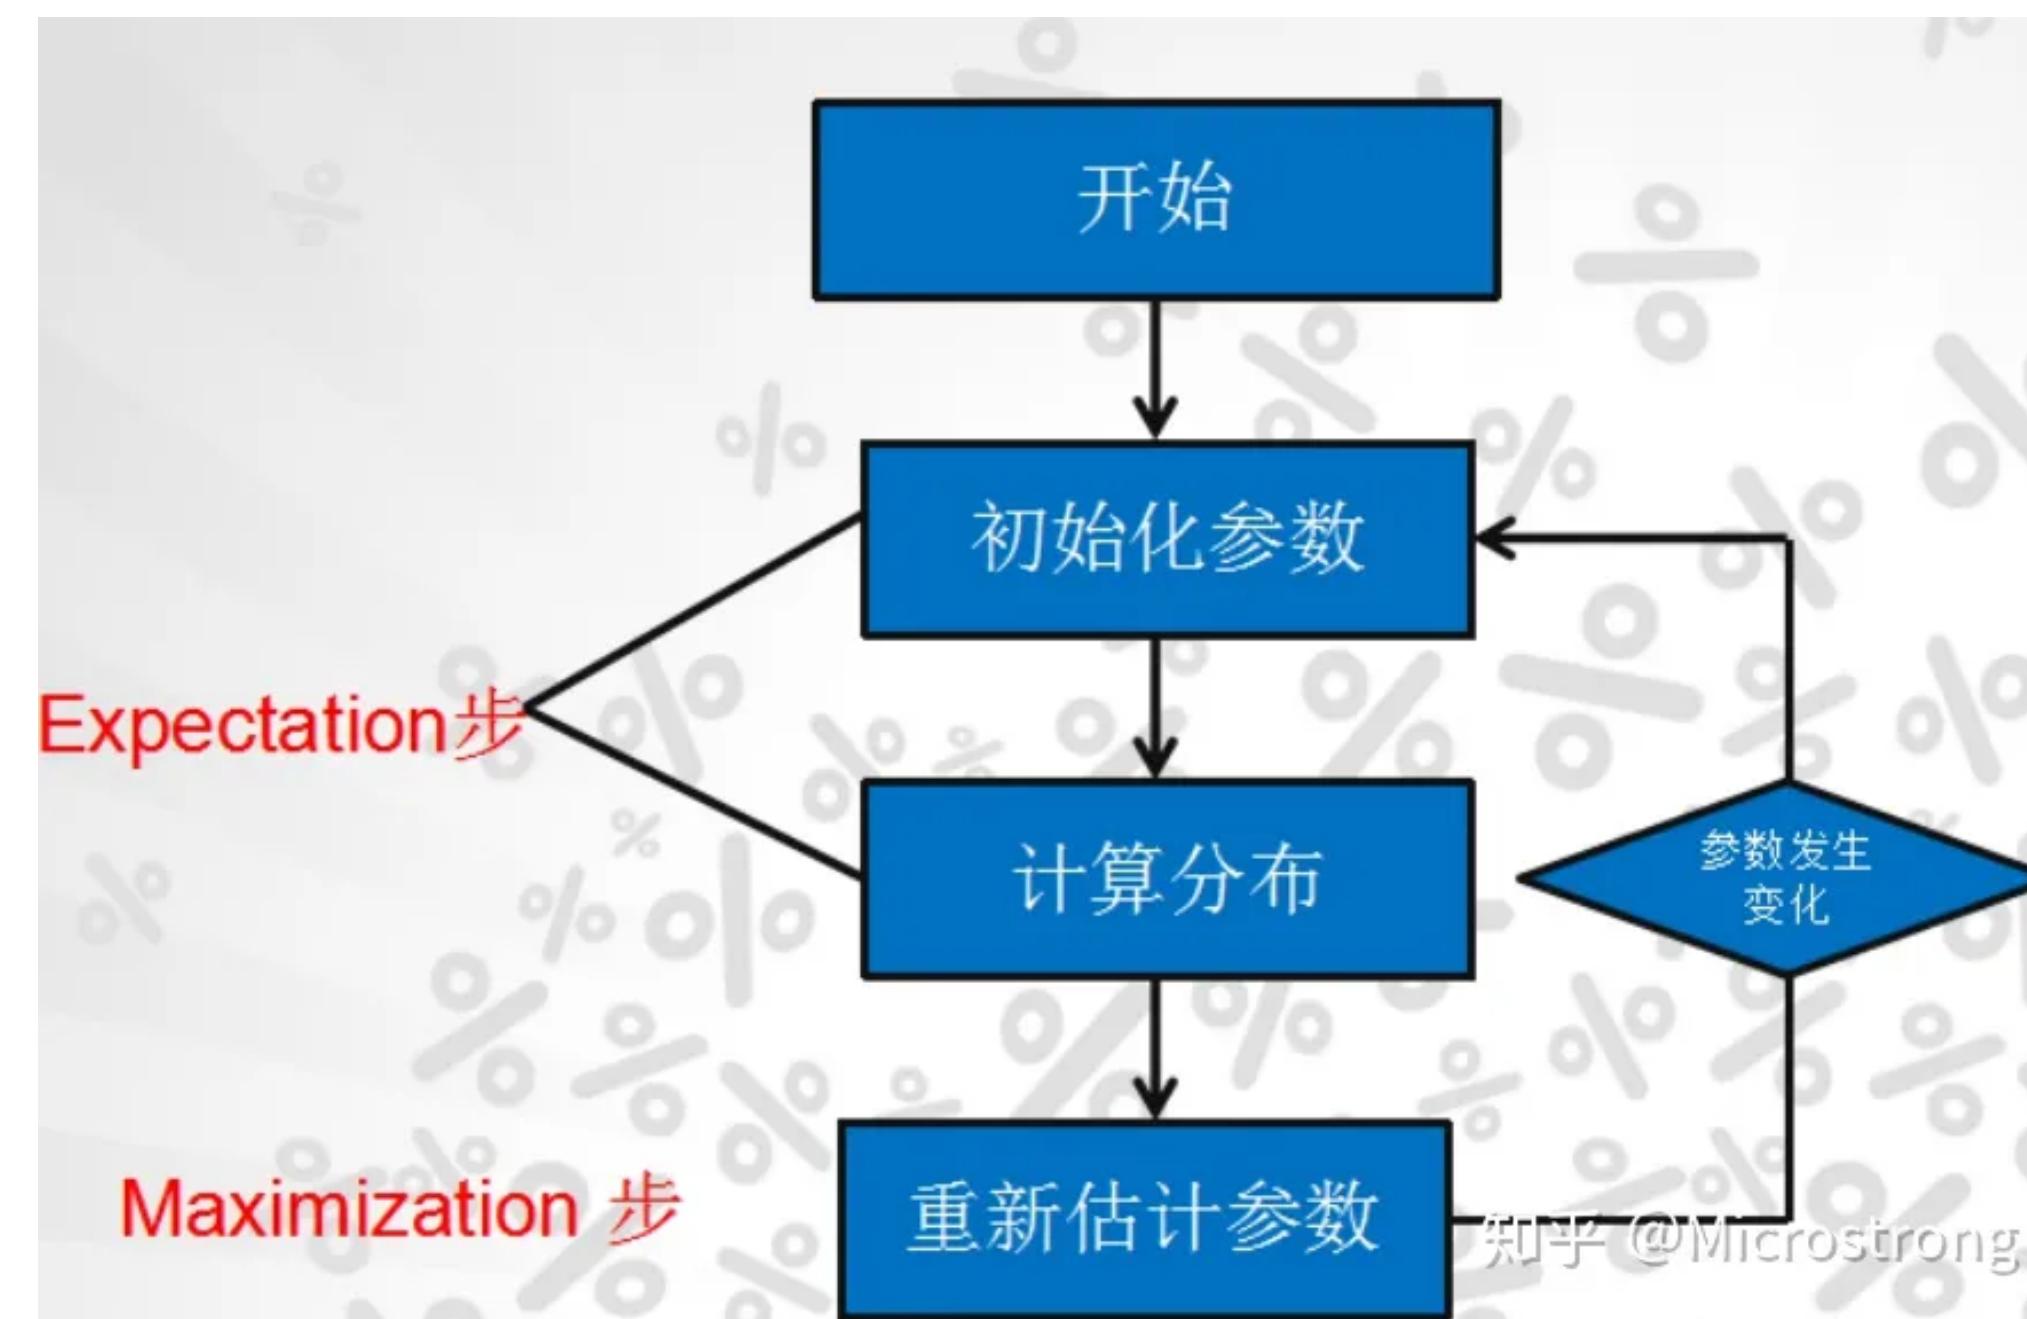
$$\hat{a}_{ij} = \frac{\#T_{ij}}{\sum_{j'}^n \#T_{ij'}}, \quad \hat{e}_{ik} = \frac{\#E_{ij}}{\sum_{k'}^V \#E_{ij'}}, \quad \hat{\pi}_i = \frac{\#S_i}{S}$$

- 隐状态序列 x 未知：最大方差估计法（Expectation-Maximum, EM）

4.2.3 HMM模型学习问题

- EM算法

- E步骤：利用模型现有参数求隐变量取值的期望
- M步骤：利用当前对隐变量估计值对模型参数最大似然估计，更新模型



4.2.3 HMM模型学习问题

- **EM算法**

输入：观察到的数据 $x = (x_1, x_2, \dots, x_n)$, 联合分布 $p(x, z; \theta)$, 条件分布 $p(z|x, \theta)$, 最大迭代次数J。

算法步骤：

(1) 随机初始化模型参数 θ 的初值 θ_0 。

(2) $j=1, 2, \dots, J$ 开始EM算法迭代：

- E步：计算联合分布的条件概率期望：

$$Q_i(z_i) = p(z_i|x_i, \theta_j)$$

$$l(\theta, \theta_j) = \sum_{i=1}^n \sum_{z_i} Q_i(z_i) \log \frac{p(x_i, z_i; \theta)}{Q_i(z_i)}$$

- M步：极大化 $l(\theta, \theta_j)$, 得到 θ_{j+1} :

$$\theta_{j+1} = \operatorname{argmax} l(\theta, \theta_j)$$

- 如果 θ_{j+1} 已经收敛，则算法结束。否则继续进行E步和M步进行迭代。

输出：模型参数 θ 。

4.2.3 HMM模型学习问题

例：假设有两枚硬币A、B，以相同的概率随机选择一个硬币，进行如下的掷硬币实验：共做5次实验，每次实验独立的掷十次(H代表正面朝上)。a是在知道每次选择的是A还是B的情况下进行，b是在不知道选择的是A还是B的情况下进行，问如何估计两个硬币正面出现的概率？

4.2.3 HMM模型学习问题

a Maximum likelihood



HTTTTHHTHTH
 HHHTTHHHHH
 HTHHHHHTHH
 HTHTTTHTHTT
 THHHHTHHHTH

5 sets, 10 tosses per set

Coin A	Coin B
	5 H, 5 T
9 H, 1 T	
8 H, 2 T	
	4 H, 6 T
7 H, 3 T	
24 H, 6 T	9 H, 11 T

$$\hat{\theta}_A = \frac{24}{24 + 6} = 0.80$$

$$\hat{\theta}_B = \frac{9}{9 + 11} = 0.45$$

CASE a

已知每个实验选择的是硬币A 还是硬币 B， 重点是如何计算输出的概率分布， 这其实也是极大似然求导所得。

$$\begin{aligned} \underset{\theta}{\operatorname{argmax}} \log P(Y|\theta) &= \log((\theta_B^5(1-\theta_B)^5)(\theta_A^9(1-\theta_A))(\theta_A^8(1-\theta_A)^2)(\theta_B^4(1-\theta_B)^6)(\theta_A^7(1-\theta_A)^3)) \\ &= \log[(\theta_A^{24}(1-\theta_A)^6)(\theta_B^9(1-\theta_B)^{11})] \end{aligned}$$

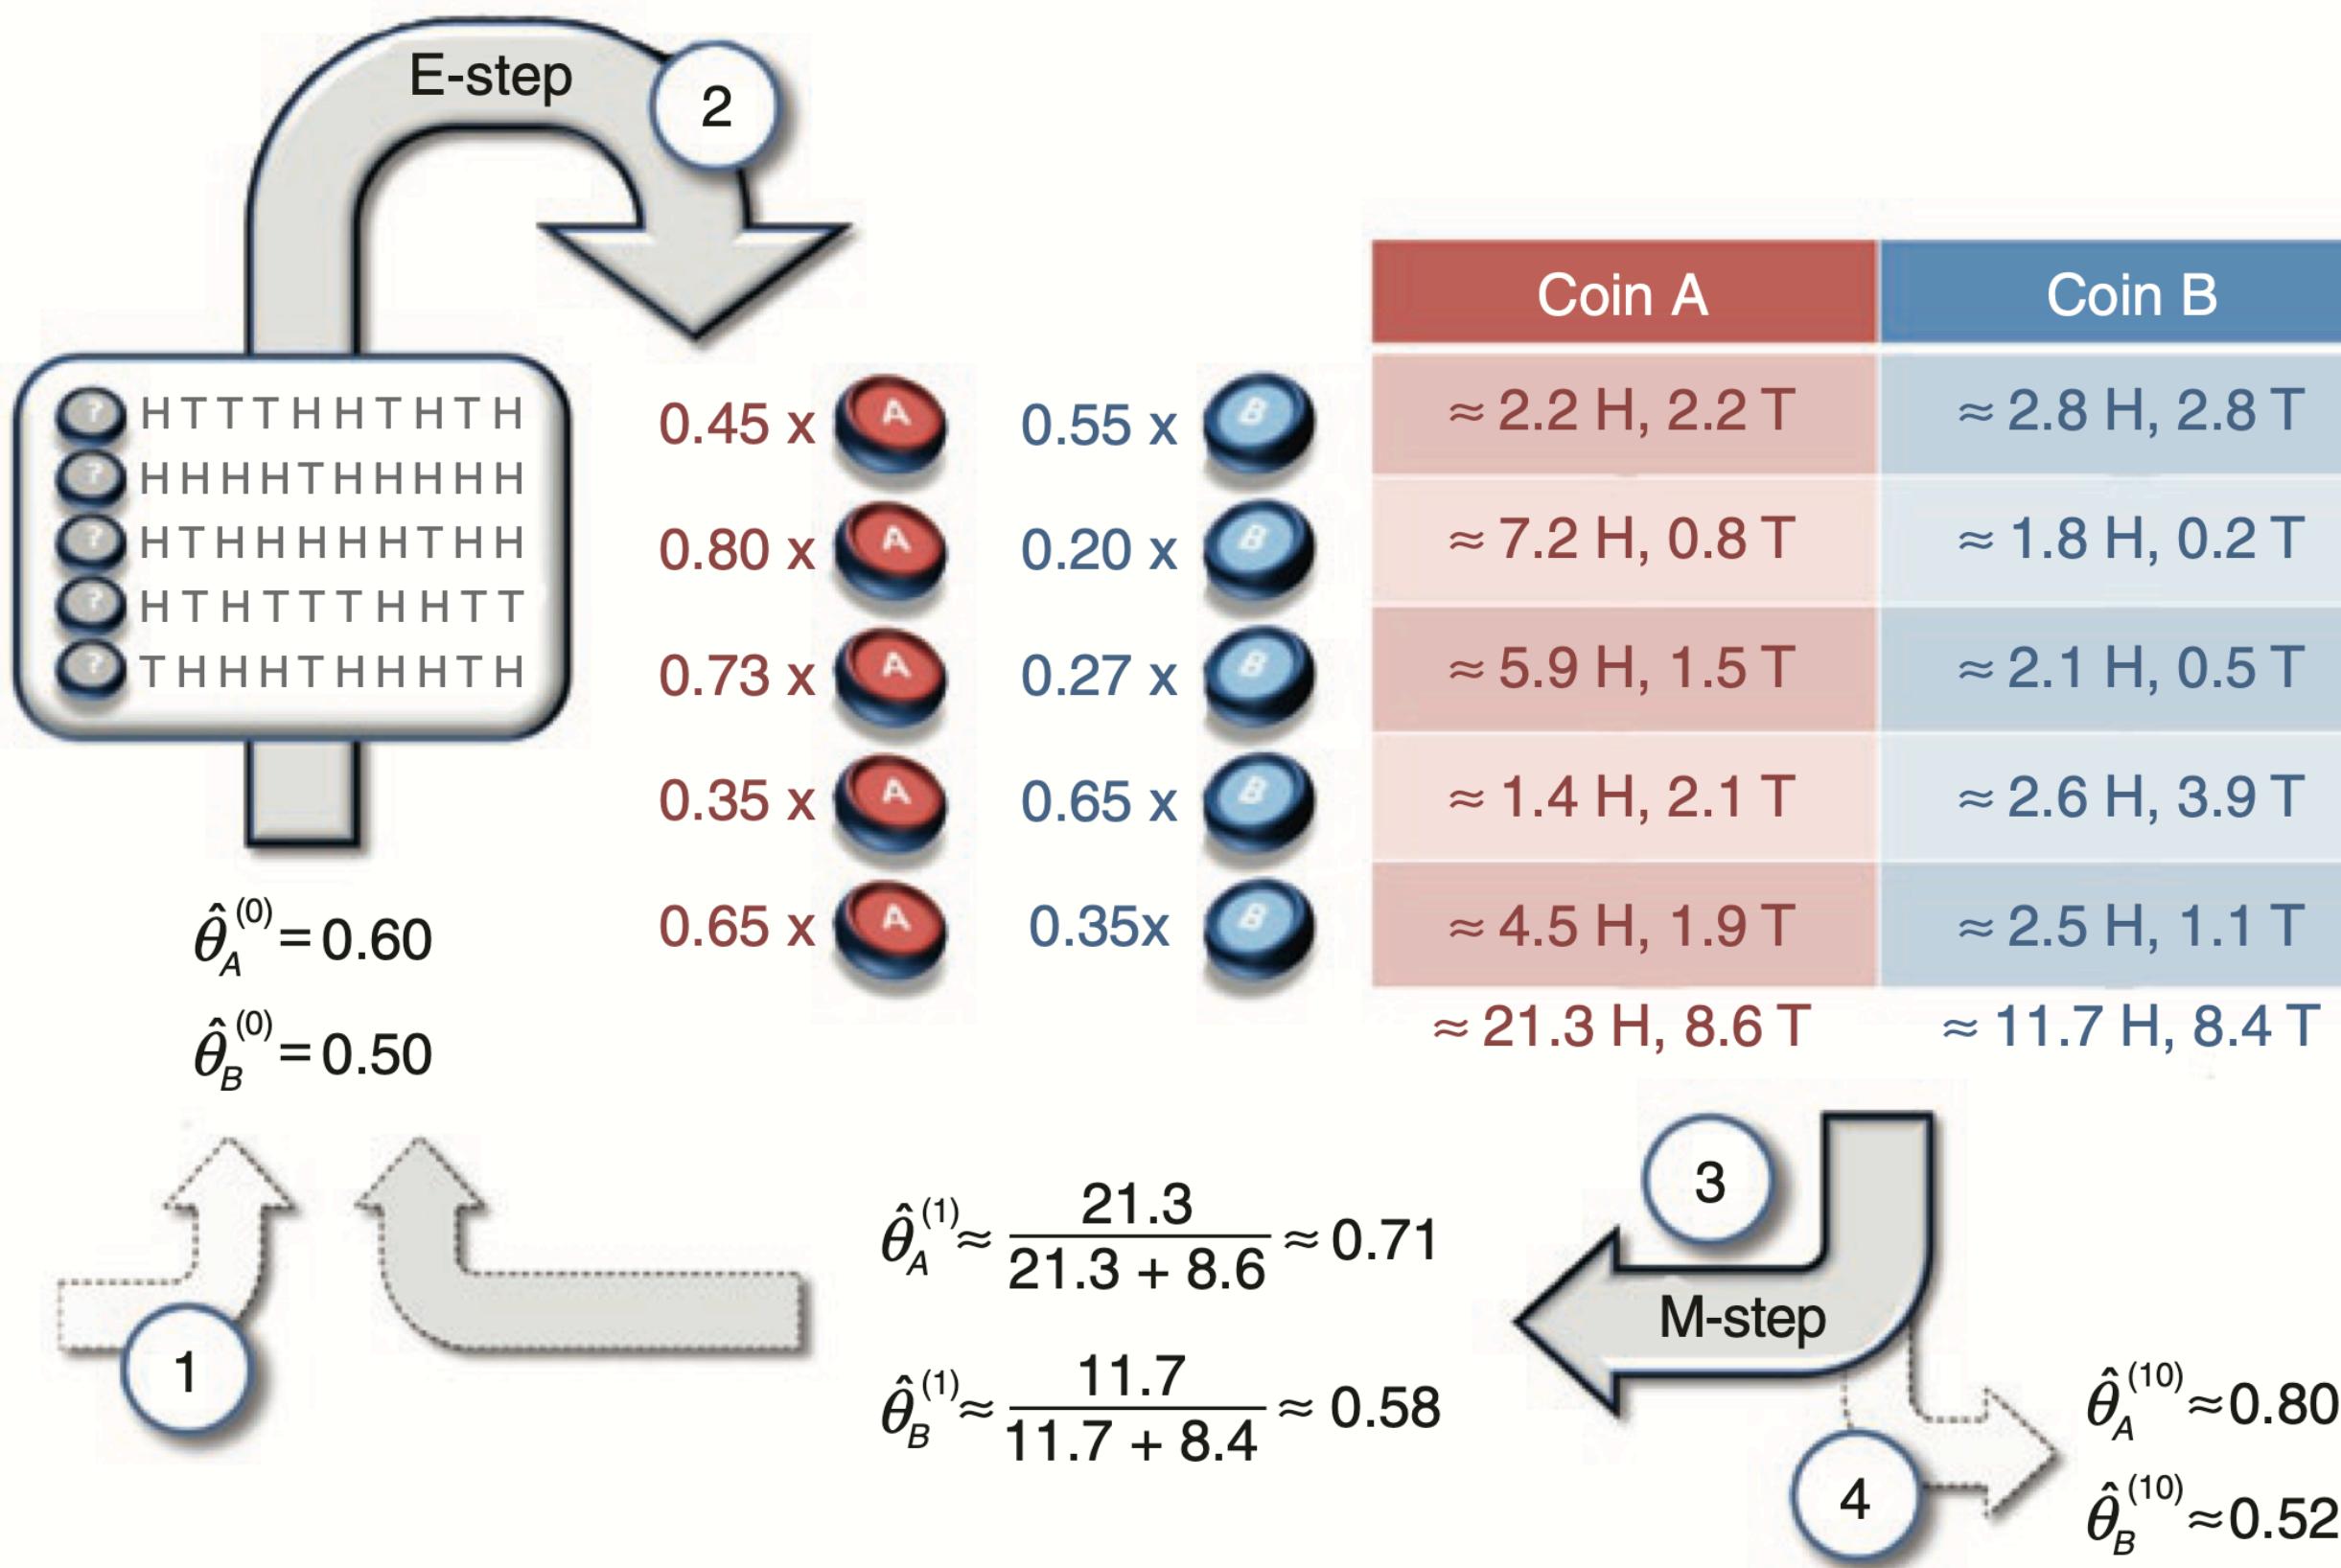
上面这个式子求导之后发现， 5 次实验中A正面向上的次数再除以总次数作为即为 $\hat{\theta}_A$ ， 5次实验中B正面向上的次数再除以总次数作为即为 $\hat{\theta}_B$ ， 即：

$$\hat{\theta}_A = \frac{24}{24 + 6} = 0.80$$

$$\hat{\theta}_B = \frac{9}{9 + 11} = 0.45$$

4.2.3 HMM模型学习问题

b Expectation maximization



CASE b

由于并不知道选择的是硬币 A 还是硬币 B，因此采用EM算法。

E步：初始化 $\hat{\theta}_A^{(0)} = 0.60$ 和 $\hat{\theta}_B^{(0)} = 0.50$ ，计算每个实验中选择的硬币是 A 和 B 的概率，例如第一个实验中选择 A 的概率为：

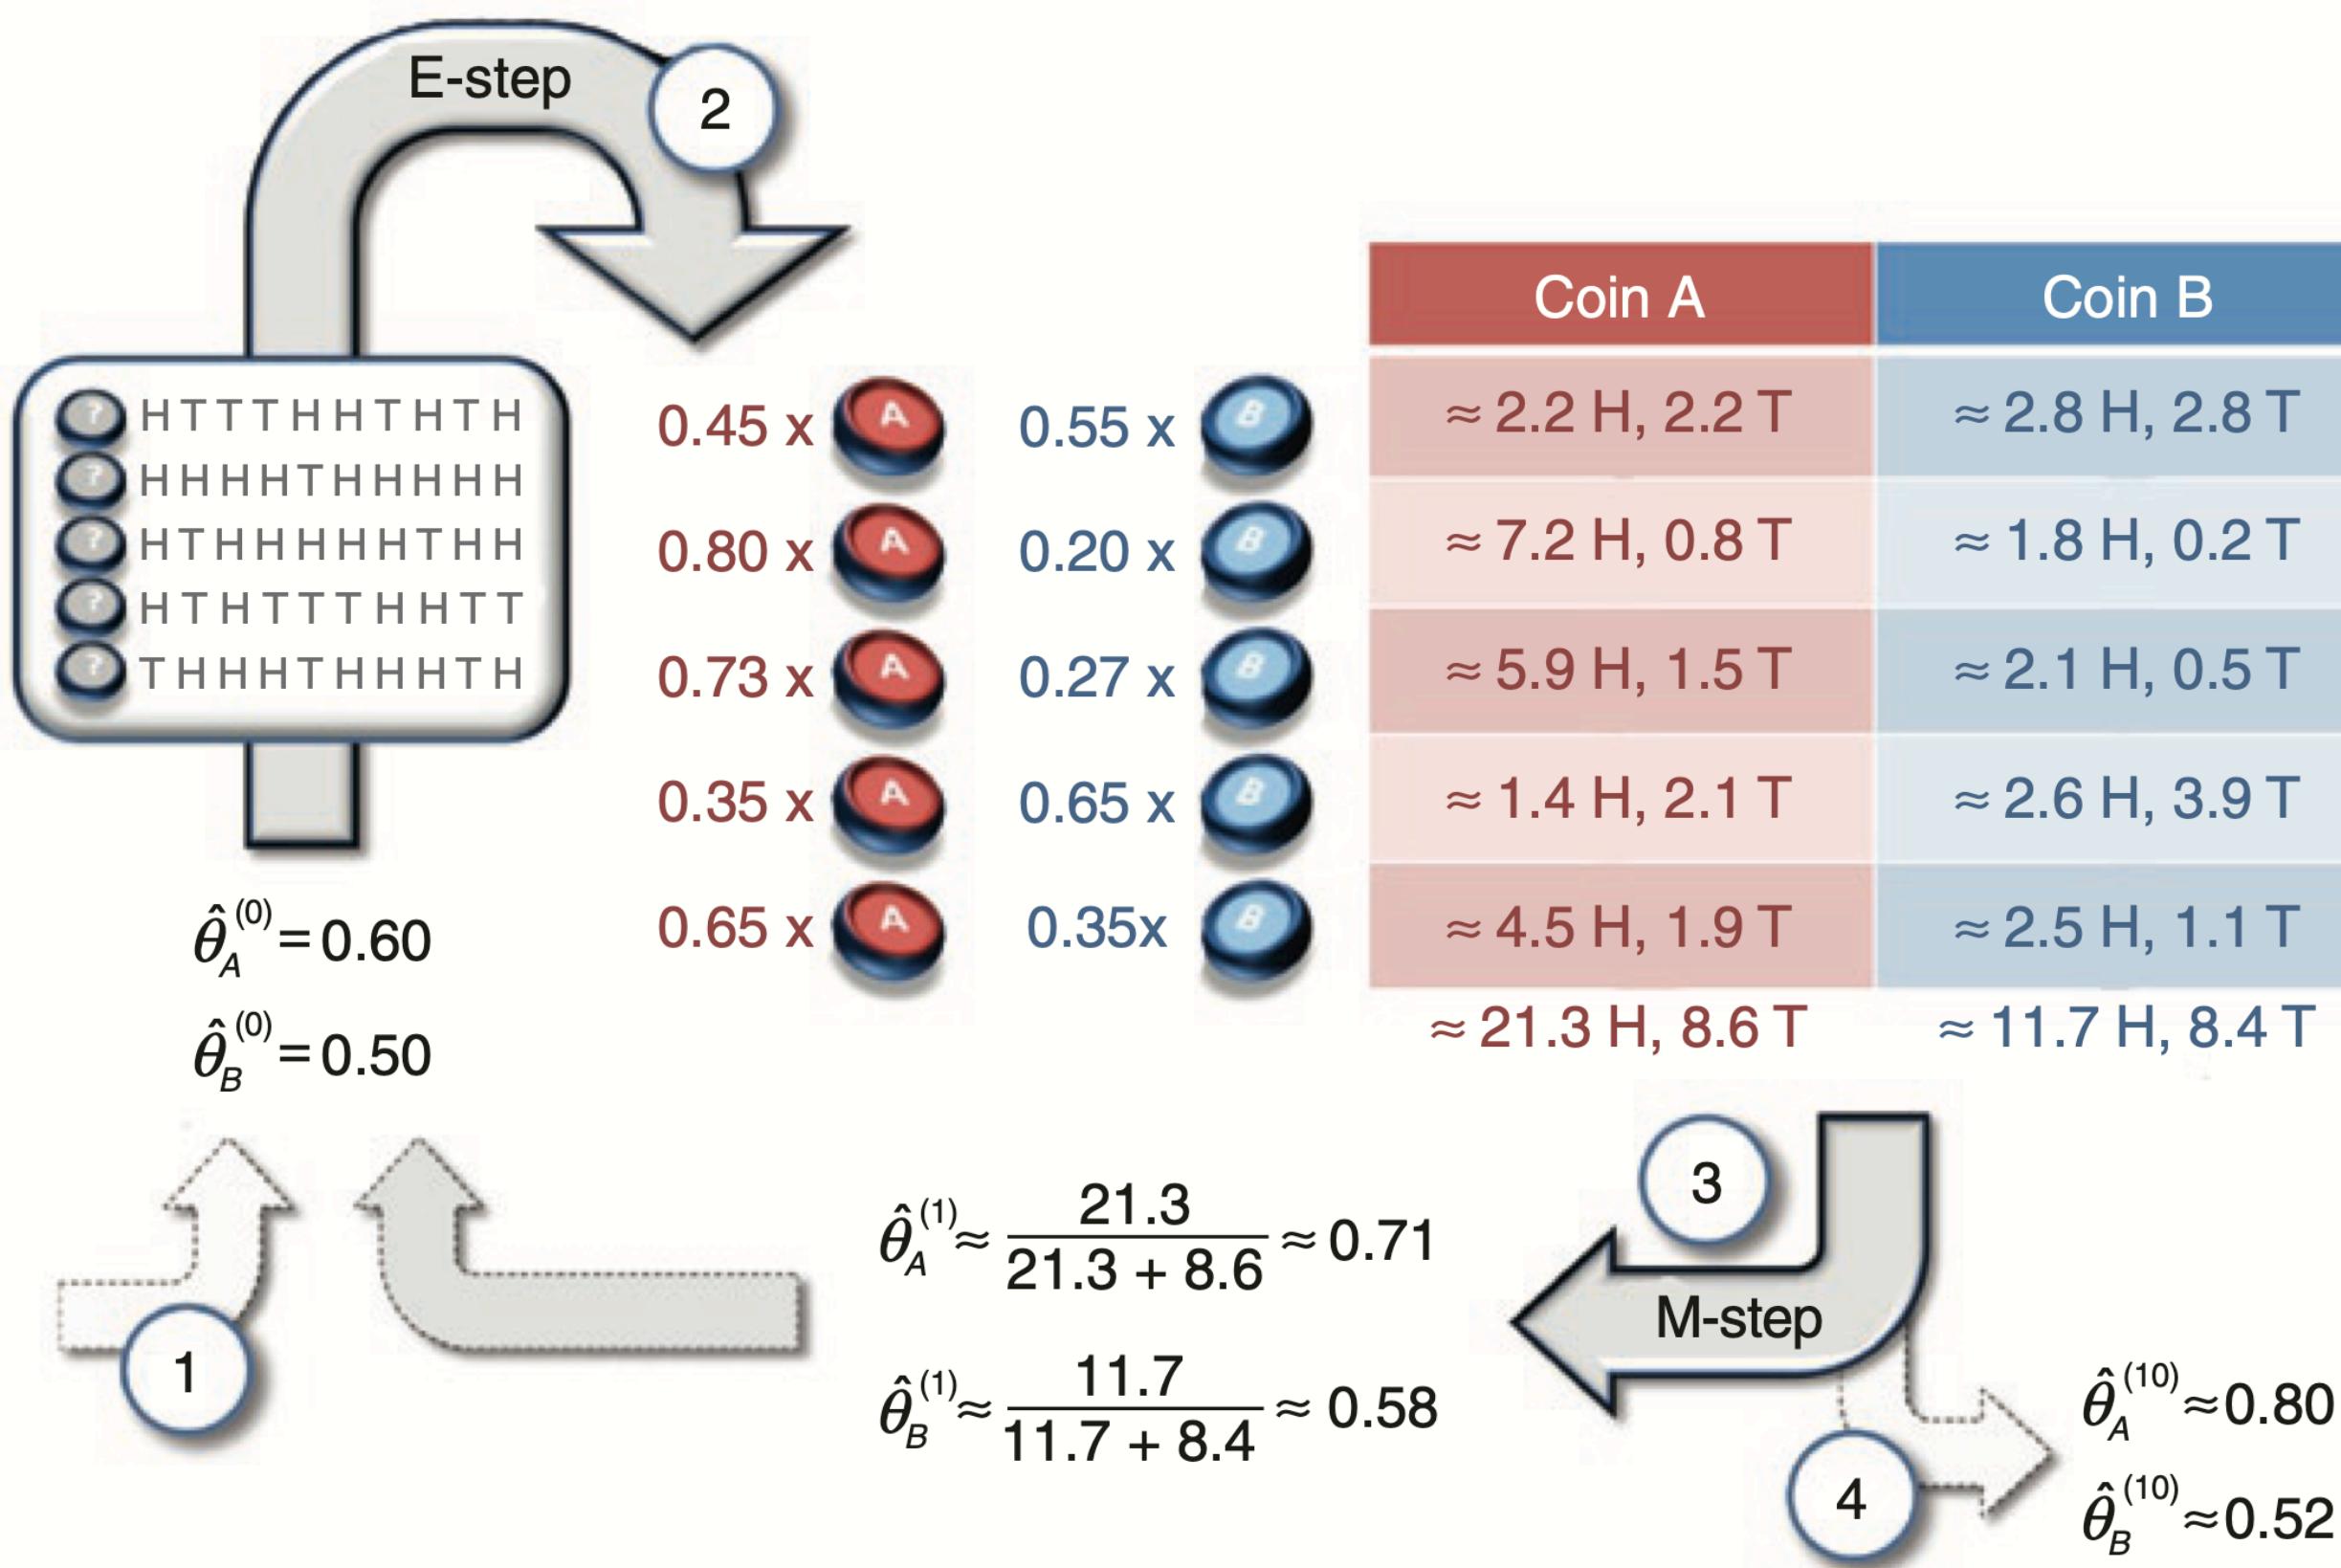
$$P(z = A|y_1, \theta) = \frac{P(z = A, y_1|\theta)}{P(z = A, y_1|\theta) + P(z = B, y_1|\theta)} = \frac{(0.6)^5 * (0.4)^5}{(0.6)^5 * (0.4)^5 + (0.5)^{10}} = 0.45$$

$$P(z = B|y_1, \theta) = 1 - P(z = A|y_1, \theta) = 0.55$$

计算出每个实验为硬币 A 和硬币 B 的概率，然后进行加权求和。

4.2.3 HMM模型学习问题

b Expectation maximization



M步：求出似然函数下界 $Q(\theta, \theta^i)$, y_j 代表第 j 次实验正面朝上的个数, μ_j 代表第 j 次实验选择硬币 A 的概率, $1 - \mu_j$ 代表第 j 次实验选择硬币 B 的概率。

$$\begin{aligned} Q(\theta, \theta^i) &= \sum_{j=1}^5 \sum_z P(z|y_j, \theta^i) \log P(y_j, z|\theta) \\ &= \sum_{j=1}^5 \mu_j \log(\theta_A^{y_j} (1 - \theta_A)^{10-y_j}) + (1 - \mu_j) \log(\theta_B^{y_j} (1 - \theta_B)^{10-y_j}) \end{aligned}$$

针对L函数求导来对参数求导, 例如对 θ_A 求导:

$$\begin{aligned} \frac{\partial Q}{\partial \theta_A} &= \mu_1 \left(\frac{y_1}{\theta_A} - \frac{10 - y_1}{1 - \theta_A} \right) + \cdots + \mu_5 \left(\frac{y_5}{\theta_A} - \frac{10 - y_5}{1 - \theta_A} \right) = \mu_1 \left(\frac{y_1 - 10\theta_A}{\theta_A(1 - \theta_A)} \right) + \cdots \\ &\quad + \mu_5 \left(\frac{y_5 - 10\theta_A}{\theta_A(1 - \theta_A)} \right) \\ &= \frac{\sum_{j=1}^5 \mu_j y_j - \sum_{j=1}^5 10\mu_j \theta_A}{\theta_A(1 - \theta_A)} \end{aligned}$$

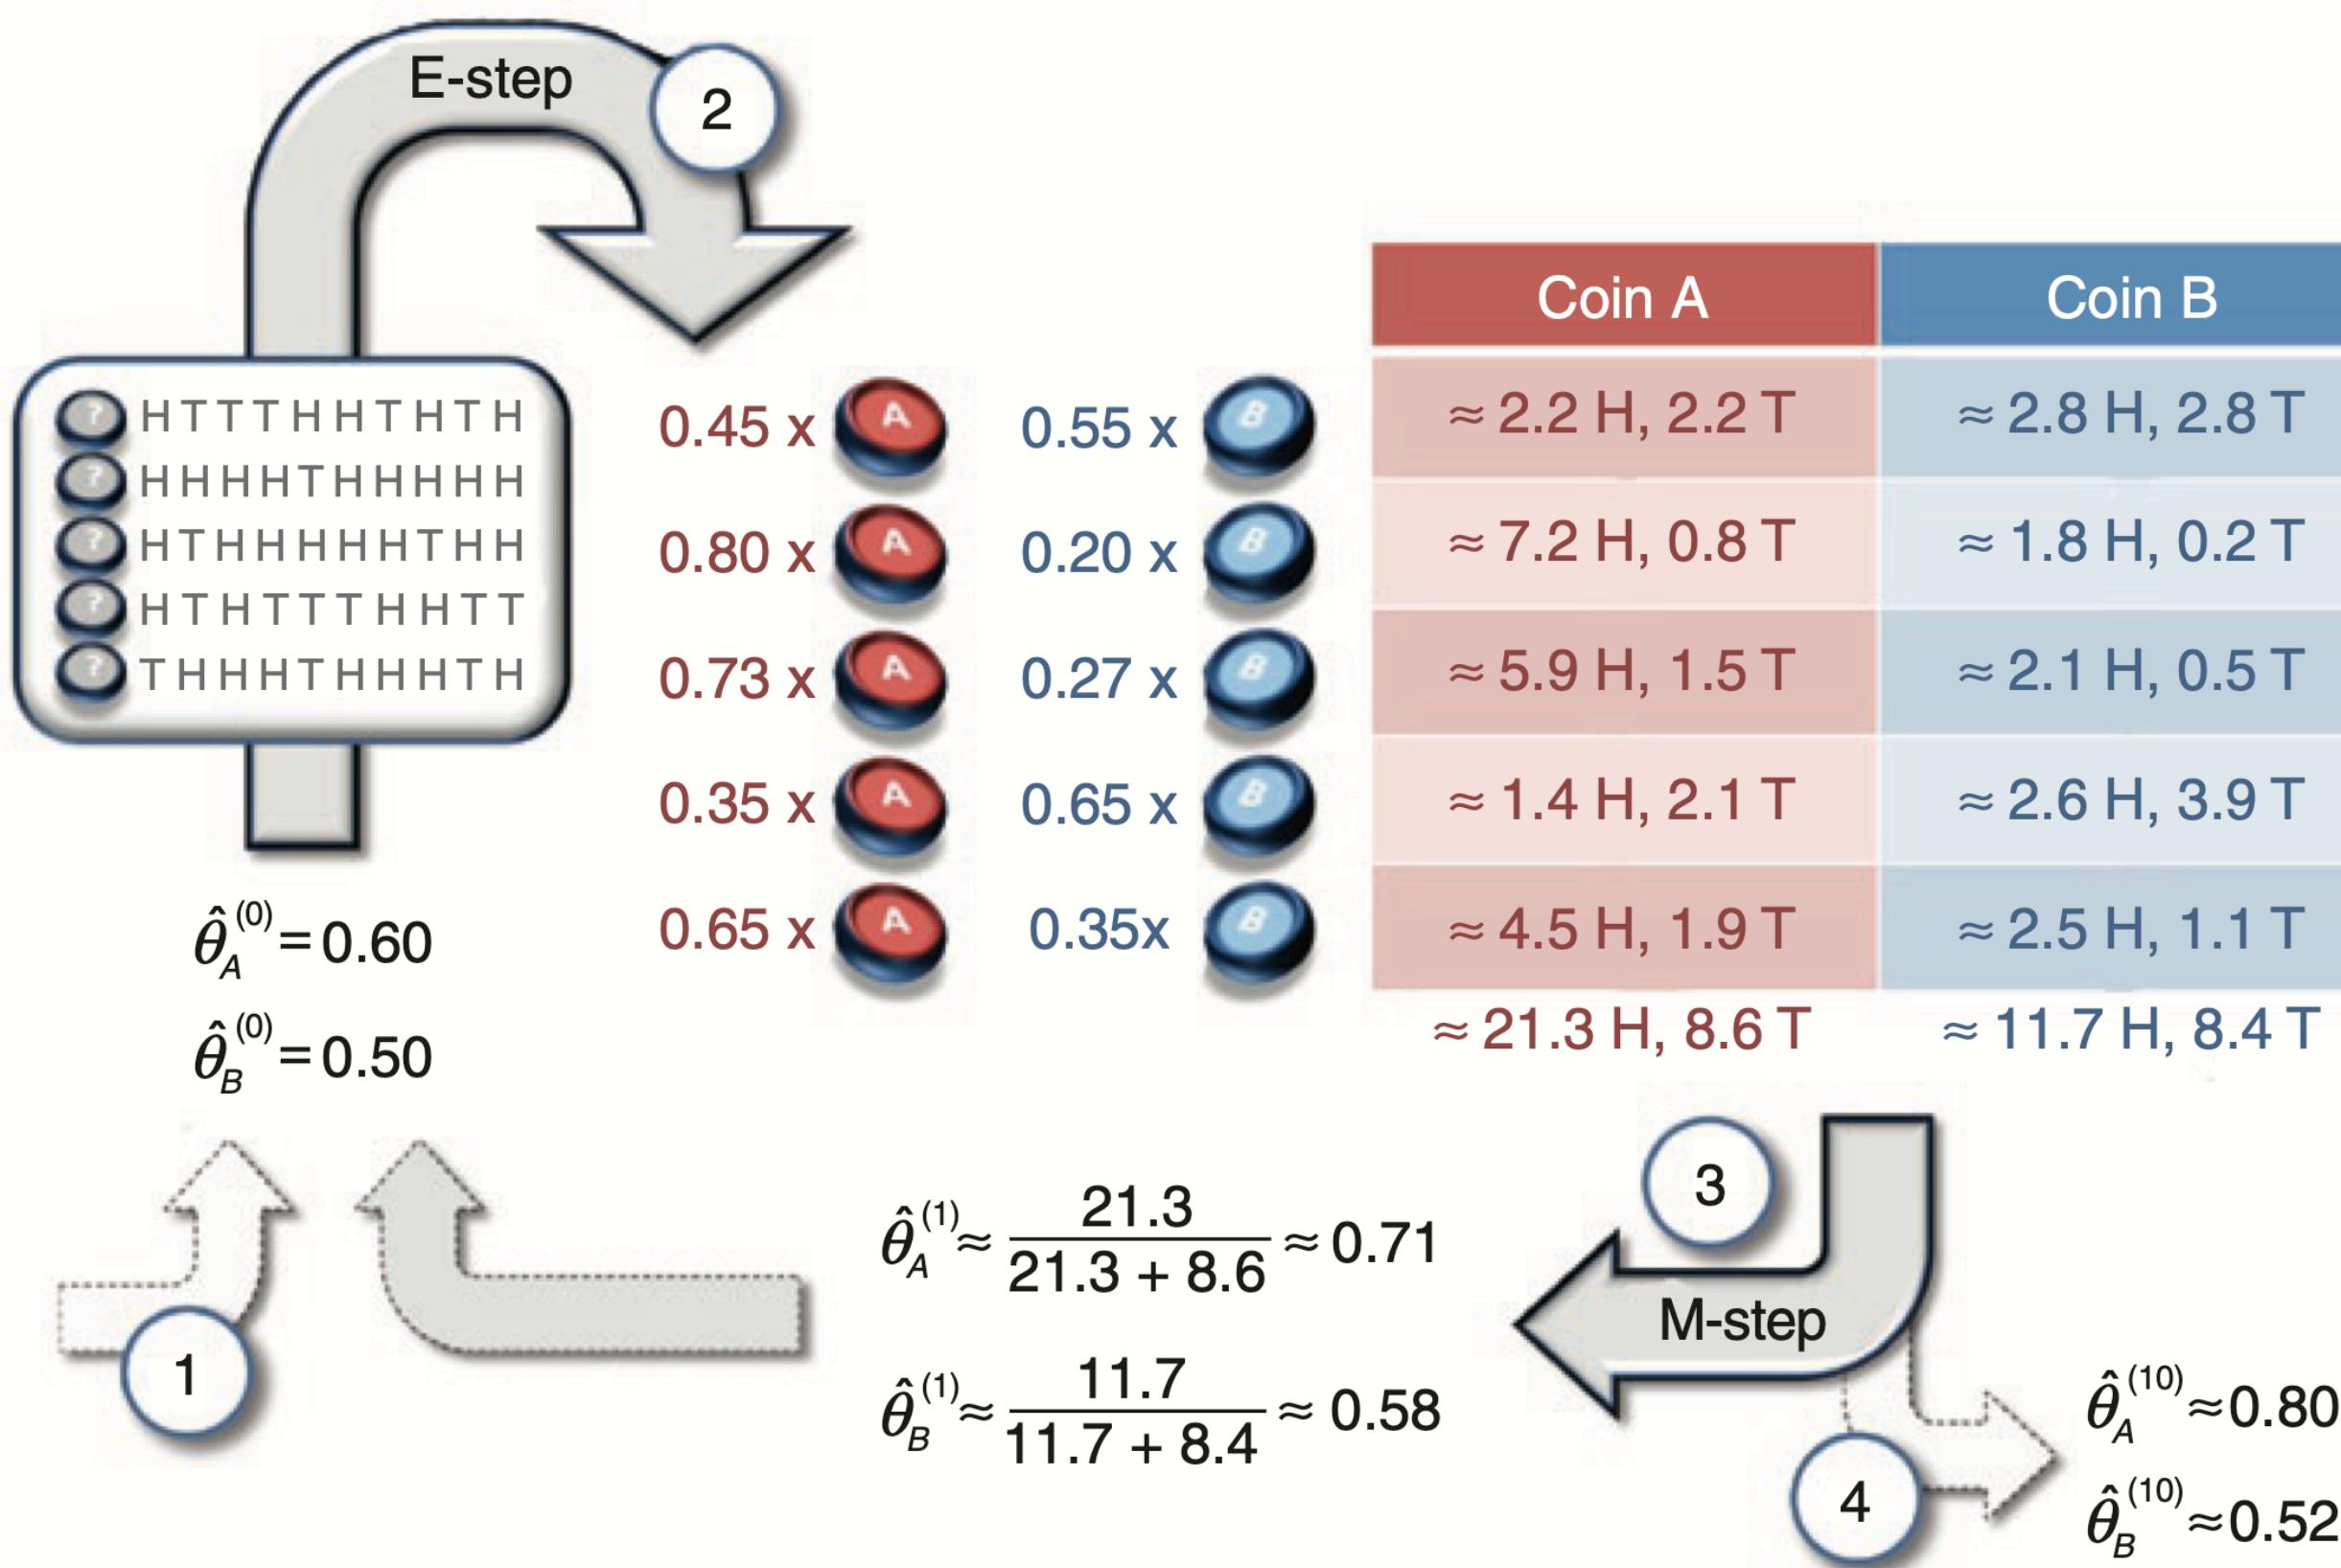
求导等于 0 之后就可得到图中的第一次迭代之后的参数值:

$$\hat{\theta}_A^{(1)} = 0.71$$

$$\hat{\theta}_B^{(1)} = 0.58$$

4.2.3 HMM模型学习问题

b Expectation maximization



第二轮迭代：基于第一轮EM计算好的 $\hat{\theta}_A^{(1)}, \hat{\theta}_B^{(1)}$ ，进行第二轮 EM，计算每个实验中选择的硬币是 A 和 B 的概率（E步），然后在计算M步，如此继续迭代……迭代十步之后
 $\hat{\theta}_A^{(10)} = 0.8, \hat{\theta}_B^{(10)} = 0.52$

4.3 朴素贝叶斯分类器

- 贝叶斯分类器

$$P(B_i | A) = \frac{P(AB_i)}{P(A)} = \frac{P(B_i)P(A | B_i)}{P(A)}$$

$$P(\text{类别} | \text{特征}) = \frac{P(\text{特征} | \text{类别})P(\text{类别})}{P(\text{特征})}$$

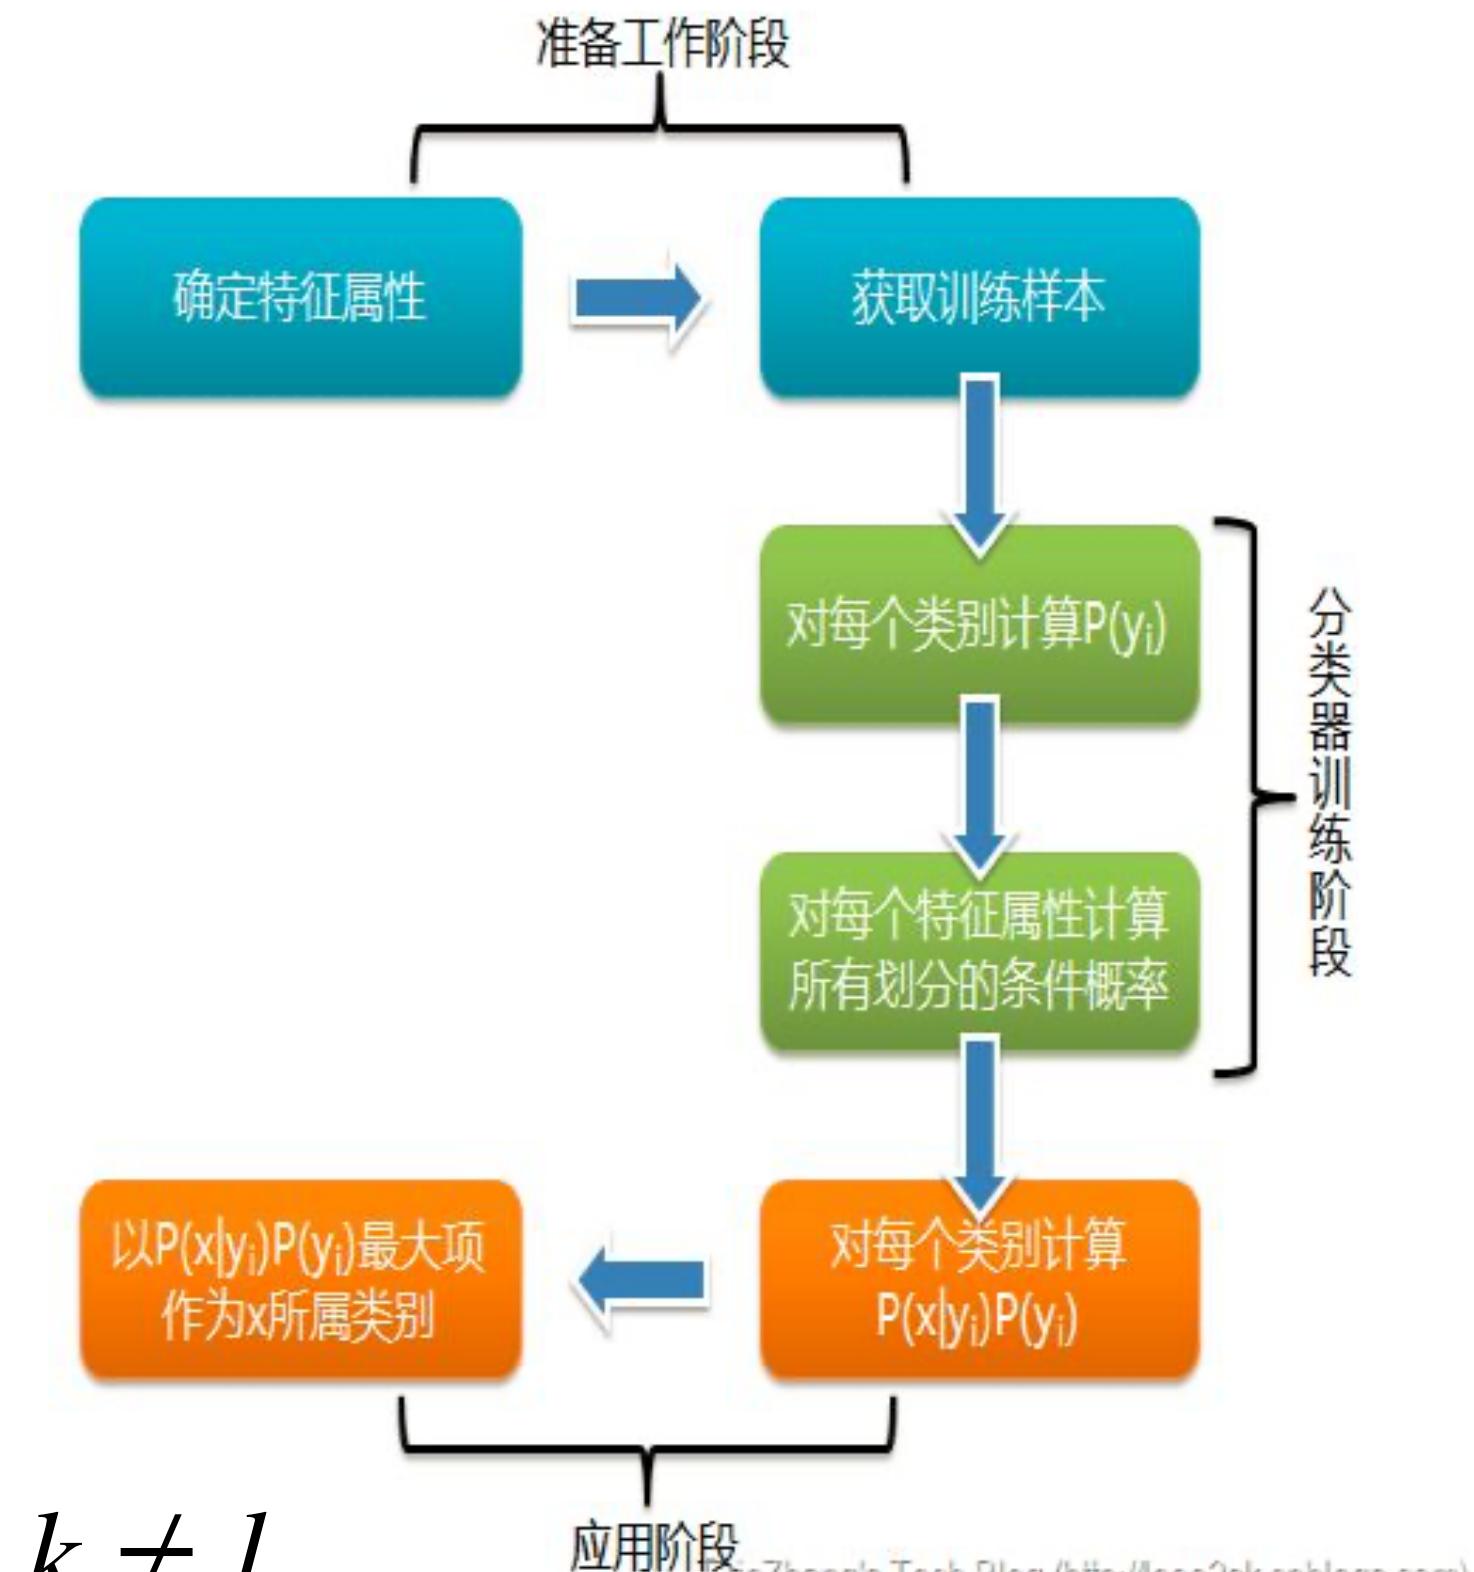
- 朴素贝叶斯分类器

- 假设各个特征取值只依赖类别标签，特征间互相独立：**朴素**

$$p(x_l x_k | \omega_i) = p(x_l | \omega_i)p(x_k | \omega_i), \quad l, k = 1, \dots, d, k \neq l$$

- 联合概率可以分解为

$$p(x_1, x_2, \dots, x_d, \omega_i) = p(x_1 | \omega_i)p(x_2 | \omega_i) \cdots p(x_d | \omega_i)p(\omega_i)$$



4.3 朴素贝叶斯分类器

- 朴素贝叶斯分类器

- 类别先验概率估计

$$p(Y = \omega_i) = \frac{\sum_{i=1}^N I(y_i = \omega_i)}{N}$$

- 特征的条件概率：参数的极大似然估计

$$p(x_j = v_i \mid Y = \omega_i) = \frac{\sum_{i=1}^N I(x_j^{(i)} = v_i, y_i = \omega_i)}{\sum_{i=1}^N I(y_i = \omega_i)}$$

4.3 朴素贝叶斯分类器

- 朴素贝叶斯分类器
 - 拉普拉斯平滑：对概率值平滑矫正，解决样本量少或者特征取值概率较低的情况

$$\rightarrow p(Y = \omega_i) = \frac{\sum_{i=1}^N I(y_i = \omega_i) + 1}{N + C}$$

$$\rightarrow p(x_j = v_i | Y = \omega_i) = \frac{\sum_{i=1}^N I(x_j^{(i)} = v_i, y_i = \omega_i) + 1}{\sum_{i=1}^N I(y_i = \omega_i) + S_j}$$